

基于 ISSMFA 与 LMPNN 算法的高光谱遥感影像分类

谢福鼎 盖虹羽 杨 俊

(辽宁师范大学 城市与环境学院 辽宁 大连 116029)

E-mail: 351521039@qq.com

摘要: 通过地理空间近邻关系改进半监督边际 Fisher 分析方法,并结合局部平均伪近邻(LMPNN)方法,提出一种高光谱遥感影像分类方法.首先在半监督边际 Fisher 分析的本征图构建中,融入地理空间位置的近邻信息,赋予更大的权重,从而增强空间邻域像元的紧密性,同时保持原高维空间中数据的类内结构和类间结构,将高光谱数据从高维空间映射到低维空间.然后充分考虑样本点周围多个近邻点的类别信息,利用 LMPNN 算法对低维空间中的数据进行分类识别.通过在 Indian Pine 数据集和 PaviaU 数据集上的实验,结果表明,本文提出的方法能够针对高光谱数据的空-谱特点,有效解决地物点的多分类问题,并且取得较高的分类结果.

关键词: 高光谱影像;半监督学习;伪近邻;分类

中图分类号: TP237

文献标识码: A

文章编号: 1000-1220(2018)04-0847-05

Hyperspectral Remote Sensing Image Classification Based on ISSMFA and LMPNN

XIE Fu-ding, GAI Hong-yu, YANG Jun

(College of Urban and Environment, Liaoning Normal University, Dalian 116029, China)

Abstract: By improving semi-supervised marginal Fisher analysis (ISSMFA) via spatial neighbor and integrating local mean-based pseudo nearest neighbor (LMPNN) rule, this paper proposes an algorithm for hyperspectral remote sensing image classification. The spatial neighbor and its weight are first considered while constructing manifold in SSMFA. The hyperspectral data are projected from a high-dimensional space to low-dimensional space. Classification is then performed by using of LMPNN algorithm in low-dimensional space under consideration of classification information of neighbors. The hyperspectral data sets Indian and Pavia U are chosen to test the performance of the proposal. Experimental results show that the proposed method can effectively improve classification accuracy of ground objects comparing with traditional spectral classification methods.

Key words: hyperspectral image; semi-supervised learning; pseudo nearest neighbor; classification

1 引言

高光谱遥感的最主要特点是图谱合一,其获取的地面空间图像能够融合地物的图像维和光谱维信息,得到每个地物的连续光谱信息,因此研究人员可根据获取的信息进行地物识别和分类.由于高光谱遥感数据的光谱维数高,相邻波段间的相关性强,传统的分类方法容易造成维数灾难,导致分类精度不高.同时光谱分辨率高,导致很多异物同谱的地物在高维空间中可能距离很近,呈云团状成簇分布,这些云团之间并不是呈线性分布的,这种非线性的结构被称为“流形”.因此,如何有效地提取出高光谱遥感数据中的地物特征,并且挖掘出其中蕴含的流形,是实现地物准确分类的关键.^[1-2]

在处理高维数据的研究中,国内外学者提出了一系列算法,传统的线性降维方法有主成分分析(Principal component analysis, PCA),线性判别分析(Linear discriminant analysis, LDA),多维尺度变换(Multidimensional scaling, MDS)^[3-5]等.其核心思想是找到一种线性特征变换将高维特征空间变换至

低维特征空间,并同时保持样本的某些特性不变.非线性流形算法有等距映射(Isometric feature mapping, Isomap),拉普拉斯特征映射(Laplacian eigenmaps, LE),局部线性嵌入(Locally-linear embedding, LLE),局部保持投影(Locality preserving projection, LPP)^[6-9]等.文献[10]提出了边际 Fisher 分析(Marginal Fisher Analysis, MFA),有效利用了数据的类别信息,基于图嵌入框架,通过两个图来描述类内的紧密型和类间的分离性,获得线性映射函数,将数据从高维空间投影到低维空间.但由于对遥感影像全部标记较为困难,文献[11]使用半监督算法对 MFA 进行改进,但并未考虑空间相邻像元间的关系.从物理意义上讲,地理空间上很近的像元在很大概率上属于同类地物,即图像域的空间一致性特点^[12].因此,研究人员开始将高光谱影像的空间信息融入到特征提取中,采用空-谱联合的方式,选取合适的地物特征对数据进行维约简.比如文献[13]将光谱角引入空谱联合稀疏表示图像分类理论中,设计空谱联合稀疏表示进行图像分割,有效提高复杂影像的分类精度.

收稿日期: 2017-10-31 收修改稿日期: 2018-01-12 基金项目: 国家自然科学基金项目(41471140; 41771178) 资助; 广东省数学与交叉科学普通高校重点实验室开放课题. 作者简介: 谢福鼎,男,1965年生,博士,教授,研究方向为模式识别、空间数据挖掘、复杂网络、高光谱图像分类; 盖虹羽,女,1993年生,硕士研究生,研究方向为高光谱影像分类、数据挖掘; 杨 俊,男,1978年生,博士,教授,博士生导师,研究方向为城市化与人居环境、城市空间增长模拟及其环境效应、复杂地学计算与模拟.

在众多分类方法中, KNN 分类法因具有简单有效、分类准确度高、鲁棒性好等优点, 被广泛用于模式识别领域. 基于该方法, 提出了加权投票方法的 KNN^[14, 15], 给越近的邻居分配更大的权重. 但是根据近邻点的距离越近, 分配权重越大不是绝对正确的, 有时一些更远的邻居的类别信息更为重要. 关于这个问题, 提出了自适应指标最近邻分类^[16]. 为克服离群点的负面影响, 提出了一个简单的非参数分类器, 局部平均 k 近邻^[17], 用每类 k 近邻的局部平均向量来分类待测样本. 伪近邻(pseudo nearest neighbor, PNN)^[18]则是在距离权重 k 近邻法(WKNN)^[14]和局部平均 k 近邻基础上提出来的, 搜寻每类的伪邻居点, 根据最近的伪邻居点的类别来分类. 局部平均伪近邻算法^[19]则是对 PNN 算法的推广, 用每类的 k 近邻求得 k 个局部平均向量, 来代替伪邻居点, 计算权重距离和, 待测点的类别由最近的局部平均伪近邻的类别决定. 相比 PNN 能代表更有效的类别信息, 从而提高分类性能.

基于以上分析, 本文提出了一种结合空间近邻关系的流形降维(ISSMFA)和局部平均伪近邻(LMPNN)的高光谱遥感影像分类方法. 首先在描述类间关系的本征图构建中, 融入地理空间近邻像元的信息, 设置权重, 使得同类或地理空间近邻的像元点更加聚集, 从而提取高光谱数据中有效的特征信息进行维数约简, 再对降维后的数据用 LMPNN 方法进行分类. Indian Pine 数据集和 PaviaU 数据集上的实验结果表明, 本文提出的方法能够针对高光谱数据的空-谱特点, 有效解决地物点的多分类问题, 并且取得较好的分类结果.

2 算法介绍

2.1 半监督边际 Fisher 分析(SSMFA)

MFA 是一种用于高维数据降维的线性流形学习算法, 利用局部几何关系和鉴别信息将不同类别的数据区分出来, 是一种监督学习算法. 假设高维空间 R^D 中一组含 n 个样本的数据集为 $X = \{x_1, x_2, \dots, x_n\}$, MFA 旨在找到一个映射函数 $Y = A^T X$ 将 X 投影到低维空间 R^d ($d \leq D$) 中, 得到低维构造点 $Y = \{y_1, y_2, \dots, y_n\}$. MFA 构造了两种图: 本征图 G 和惩罚图 G_p , 分别描述数据的类内紧密性 \widehat{S}_w 和类间分离性 \widehat{S}_p . 对于每个样本点, 将 k_1 邻域内与之类别相同的点相连, 构成本征图; k_2 邻域内, 与之类别不同的点连接, 构成惩罚图. 通过目标函数 A^* , 在最小化类内紧凑性的同时, 最大化不同类间的分离性. 描述如下:

$$A^* = \arg \min_A \frac{\widehat{S}_w}{\widehat{S}_p}, \quad (1)$$

$$\begin{aligned} \widehat{S}_w &= \sum_i \sum_{j \in N_{k_1}(i) \text{ or } j \in N_{k_1}(i)} \|A^T x_i - A^T x_j\|^2 \\ &= 2 \text{Tr}(A^T X (D - W) X^T A) \\ &= 2 \text{Tr}(A^T X L X^T A), \end{aligned} \quad (2)$$

$$\begin{aligned} \widehat{S}_p &= \sum_i \sum_{(i, j) \in P_{k_2}(c_i) \text{ or } (i, j) \in P_{k_2}(c_j)} \|A^T x_i - A^T x_j\|^2 \\ &= 2 \text{Tr}(A^T X (D^p - W^p) X^T A) \\ &= 2 \text{Tr}(A^T X L^p X^T A), \end{aligned} \quad (3)$$

其中 $N_{k_1}(i)$ 表示在样本 x_i 的 k_1 个最近邻中, 与其类别相

同的样本的集合; $P_{k_2}(c_i)$ 表示在 x_i 的 k_2 个最近邻中与其类别不同的样本的集合; Tr 表示矩阵的迹, $L = D - W$ 为拉普拉斯矩阵, W 是相似度矩阵, D 是对角矩阵, $D_{ij} = \sum_j W_{ji}$, A 为待求的投影向量. 相似度矩阵如下:

$$W_{ij} = \begin{cases} 1 & i \in N_{k_1}(j) \text{ or } j \in N_{k_1}(i) \\ 0 & \text{otherwise} \end{cases} \quad (4)$$

$$W_{ij}^p = \begin{cases} 1 & (i, j) \in P_{k_2}(c_i) \text{ or } (i, j) \in P_{k_2}(c_j) \\ 0 & \text{otherwise} \end{cases} \quad (5)$$

目标函数可转化为如下形式:

$$A^* = \arg \min_A \frac{\widehat{S}_w}{\widehat{S}_p} = \arg \min_A \frac{A^T X L X^T A}{A^T X L^p X^T A} \quad (6)$$

于是, 上述最优化问题可转化为方程的特征值求解:

$$X L^p X^T A = \lambda X L X^T A \quad (7)$$

解得上式的 d 个最大特征值 $\lambda = \{\lambda_0, \lambda_1, \dots, \lambda_{d-1}\}$, 所对应的特征向量 $\{a_0, a_1, \dots, a_{d-1}\}$ 即为所求的映射 $A = \{a_0, a_1, \dots, a_{d-1}\}$.

由于 MFA 需要标记全部数据的类别信息, 对于高光谱数据代价太大, 因此文献[11]对 MFA 改进, 提出了半监督边际 Fisher 分析(SSMFA), 利用少量标记的样本, 对高光谱数据进行维数约简. 与 MFA 不同的是, 为了同时利用有标签和无标签的样本, 定义 x_i 与近邻点 x_j 之间的权值为 $W_{ij} = e^{-\frac{\|x_i - x_j\|^2}{t}}$, 与其他点的权值为 $W_{ij} = 0$. 在邻域内如果两个样本点属于同类或者近邻, 则连起来构成本征图 G ; 如果两个样本点不属于同一类, 则连起来构成惩罚图 G_p . 利用公式(8)设置本征图的权重矩阵, 同时惩罚图的权重矩阵为公式(9), 通过公式(6)、公式(7)求得映射函数及低维构造点.

$$W_{ij}^l = \begin{cases} \beta \cdot W_{ij} & x_i \text{ 与 } x_j \text{ 属于相同类别} \\ W_{ij} & x_i \text{ 与 } x_j \text{ 近邻} \\ 0 & \text{其他} \end{cases} \quad (8)$$

$$W_{ij}^p = \begin{cases} W_{ij} & x_i \text{ 与 } x_j \text{ 属于不同类别} \\ 0 & \text{其他} \end{cases} \quad (9)$$


其中 β 为大于 1 的常数

2.2 结合空间近邻信息的半监督边际 Fisher 分析(ISSMFA)

SSMFA 考虑了只有少数样本有标签的情况, 进行了改进, 但直接运用 SSMFA 对高光谱数据降维, 仅能利用其光谱信息. 实际上高光谱影像区别于其他高维数据, 具有空-谱一致性的特点, 在地理二维空间上距离很近的像元极有可能属于同类地物, 仅仅利用现有流形算法中固定的流形结构不能全面的表达高光谱数据的特征信息, 导致选取的特征有误, 影响后续的分类效果. 本文提出的方法, 将地理空间近邻像元点加入到 SSMFA 本征图的构建, 赋予更大的权重, 从而增强地理空间邻域像元的紧密性, 同时保持原高维空间中数据的类内结构和类间结构.

给定一个像元 P_0 , 该像元在图像中的位置用 (i, j) 表示, P_0 的相邻像元的集合用 N_{p_0} 表示, 设邻域窗口大小为 $m \times m$ (m 为大于 1 的奇数). 当 $m = 3$ 时, 中心像元点 P_0 的邻近像元为 4 个或 8 个, 如图 1(a) 图 1(b) 所示. 同理可推 $m = 5$ 时,

它邻近像元为 12 个、20 个或 24 个...随着窗口增大,中心像元点的近邻像元数增多,可利用的类别信息增多,但同时导致计算量过大,因此本算法只取 3×3 窗口 8 个近邻像元点,通过滑动 3×3 窗口,不断把近邻关系加入到本征图中。



注: 图中深灰色点为中心像元点, 浅灰色点为中心像元点的近邻点

图 1 邻域窗口示意图

Fig. 1 Schematic of the neighborhood window

假设高维空间 R^D 中一组含 n 个样本的数据集为 $X = \{x_1, x_2, \dots, x_n\}$ 。对于点 x_i 与点 x_j , 如果属于同类, 或者互为地理空间邻近像元点, 或者互为 K 近邻, 则连起来构成本征图 G ; 如果属于不同的类, 则连起来构成惩罚图 G_p , 以保持样本点类间关系。通过公式 (10) (9) 获得本征图和惩罚图的权重矩阵, 再利用公式 (6) (7) 求得映射函数及低维构造点。

$$W_{ij}^l = \begin{cases} \beta \cdot W_{ij} & x_i \text{ 与 } x_j \text{ 类别相同或 } x_i \in N_{x_j} \text{ 或 } x_j \in N_{x_i} \\ W_{ij} & x_i \text{ 与 } x_j \text{ 近邻} \\ 0 & \text{其他} \end{cases} \quad (10)$$

其中 $W_{ij} = e^{-\frac{\|x_i - x_j\|^2}{2\sigma^2}}$ (σ 是参数) β 为大于 1 的常数, N_{x_i} 表示 x_i 的相邻像元的集合, N_{x_j} 表示 x_j 的相邻像元的集合。

2.3 局部平局伪近邻 (LMPNN)

LMPNN 首先计算每类第 j 个 ($1 \leq j \leq k$) 近邻点的局部平均向量, 然后采用 k 个局部平均向量去搜寻伪近邻, 预测类标签。假设 x 为待测样本, $T = \{x_n \in R^d\}_{n=1}^{N_i}$ 是一个训练集, 有 M 个类标签 $\omega_1, \omega_2, \dots, \omega_M$, $T_{\omega_i} = \{x_j^i \in R^d\}_{j=1}^{N_i}$ 为 T 中属于类 ω_i 的训练样本集, d 是特征维度。一个待测样本点的类标签由以下步骤产生:

1) 从每类 T_{ω_i} 中找到待测样本 x 的 k 个最近邻 $x_1^i, x_2^i, \dots, x_k^i$, 并且按与 x 的欧式距离从小到大排列。

2) 计算每类 ω_i 中 x 的前 j 个近邻点 ($1 \leq j \leq k$) 的局部平均向量 \bar{x}_j^i ,

$$\bar{x}_j^i = \frac{1}{j} \sum_{l=1}^j x_l^i \quad (11)$$

用 $\bar{T}_{\omega_i}^k = \{\bar{x}_j^i \in R^d\}_{j=1}^k$ 表示每类中根据 k 近邻点得到的 k 个局部平均向量集合, 它们到 x 的欧氏距离为:

$$d(x, \bar{x}_1^i), d(x, \bar{x}_2^i), \dots, d(x, \bar{x}_k^i) \quad (12)$$

注意: 第一个近邻点的局部平均向量就是它本身。

给每一类的 k 个局部平均向量分配不同的权值, 在类 ω_i 中第 j 个局部平均向量 \bar{x}_j^i 的权重 \bar{W}_j^i 定义为:

$$\bar{W}_j^i = \frac{1}{j}, j=1, \dots, k \quad (13)$$

3) 类 ω_i 中 x 的基于局部平均向量的伪近邻点, 表示为 \bar{x}_i^{PNN} 与 \bar{x}_i^{PNN} 的距离为:

$$d(x, \bar{x}_i^{PNN}) = (\bar{W}_1^i \times d(x, \bar{x}_1^i) + \bar{W}_2^i \times d(x, \bar{x}_2^i) + \dots + \bar{W}_k^i \times d(x, \bar{x}_k^i)) \quad (14)$$

4) 计算目标函数:

$$c = \arg \min_{\omega_i} d(x, \bar{x}_i^{PNN}) \quad (15)$$

将距离 x 最近的基于局部平均的伪近邻的类标签赋给 x 。(注意: 当 $k=1$ 时, LMPNN 等同于 NN, PNN, LMKNN)。

2.4 算法步骤

本文算法步骤如下:

输入: 高光谱数据集和类标签

输出: 低维构造点

Step 1. 从数据集中每类数据中随机选取一定数量的测试样本

Step 2. 构建本征图和惩罚图。对每一个数据点, 计算 k_1 近邻, 将其连接起来, 同时将其空间邻域 $m \times m$ 内的点也连起来, 构成本征图。同样每一个数据, 计算 k_2 近邻, 将不同类的点连接起来, 构成惩罚图。

Step 3. 根据公式 (10) (9) 构造权重矩阵

Step 4. 根据公式 (6) (7), 计算映射函数。

Step 5. 利用映射函数将高光谱数据从高维空间映射到低维空间, 得到低维构造点 Y 。

Step 6. 利用 LMPNN 算法对降维后的点进行分类。

3 实验结果与分析

本文选择 Indian Pines 数据集和 PaviaU 数据集进行实验。为验证 ISSMFA 算法的优越性, 同 LDA, MFA, SSMFA 等降维算法进行对比; 为验证 LMPNN 的分类效果, 与 KNN 分类器进行对比。实验中, 分别从数据集的每类样本中随机选取一定数量的训练样本, 剩余样本作为测试样本。首先用各特征提取算法对训练样本进行学习, 获得投影矩阵, 提取样本特征, 然后采用各分类算法对测试样本的特征数据进行分类。实验以总精度 OA 和 Kappa 系数量化分类效果, 为了降低随机性, 每个实验重复 10 次并取平均值作为实验结果。

本文中的参数如下: β 为当两个样本点属于同类或者空间位置近邻时的权重系数, k 为 KNN 分类器的近邻数, k^L 为 LMPNN 方法的近邻数, 根据各数据集中数据分布情况进行调整设定。

本文的实验环境为: 实验硬件平台为 Intel(R) Core(TM) i5-4210U CPU, 主频为 2.40 GHz, 内存为 4.00 GB, 编程环境为 MATLAB R2014a。

3.1 Indian Pines 数据集实验结果及分析

Indian Pines 数据集是 1992 年 6 月用 AVIRIS 传感器采集的美国印第安那州农场的遥感影像, 空间分辨率为 20m, 图像大小为 145×145 。去除几个受大气影响的波段, 剩余 200 个




图 2 Indian Pines 影像数据真实地物标记

Fig. 2 True markings of Indian Pines image data

光谱波段, 包含 16 类地物标记 (20 < 每类中样本点数 < 2455), 真实地物标记如图 2 所示。根据数据分布情况, 邻域大小定为 3×3 , $\beta=1.9$, $k=2$, $k^L=15$, 为比较不同训练样本下各算法的性能, 分别

从每类中随机选取 10% 20% 30% 作为训练样本. 表 1 给出了各算法在不同训练比例下的总体分类精度 (OA) 和 Kappa 系数. 和

训练 10% 时各算法的运行时间. 表 2 给出了本文方法与 SSMFA 在训练 20% 时, 每类地物的分类精度.

表 1 各算法在 Indian 数据集的分类结果

Table 1 Results of the algorithms in the Indian dataset

	10%		20%		30%		运行时间/s
	OA(%)	Kappa	OA(%)	Kappa	OA(%)	Kappa	
LDA + KNN	71.25	0.709 3	73.67	0.731 2	82.66	0.815 3	4.15
MFA + KNN	72.61	0.722 6	77.24	0.769 2	82.94	0.820 8	4.08
SSMFA + KNN	75.29	0.747 5	78.82	0.785 1	84.31	0.834 0	4.26
ISSMFA + KNN	83.07	0.825 5	86.21	0.856 5	88.06	0.872 7	4.11
LDA + LMPNN	73.94	0.731 1	78.19	0.779 4	84.59	0.836 6	5.04
MFA + LMPNN	75.13	0.748 4	80.40	0.796 6	85.95	0.841 7	4.91
SSMFA + LMPNN	76.81	0.766 2	82.68	0.812 9	86.02	0.856 4	6.88
ISSMFA + LMPNN	84.04	0.834 9	87.62	0.865 4	90.62	0.891 0	5.28

从表 1 可知, 随训练比例的提高, 各算法的精度均有提高, 这是因为训练比例提高, 可利用的类别信息增多. 当分类

表 2 Indian 数据集中各地物用不同算法分类后的结果

Table 2 Results of the classification of different materials in the Indian dataset

类别(16 类)	SSMFA + LMPNN	ISSMFA + LMPNN
Alfalfa(46)	0.695 7	0.421 6
Corn-notill(1428)	0.721 3	0.844 5
Corn-mintill(830)	0.713 3	0.743 4
Corn(237)	0.531 6	0.565 4
Grass-pasture(483)	0.898 6	0.869 6
Grass-trees(730)	0.949 3	0.990 4
Grass-pasture-mowed(28)	0.928 6	0.982 6
Hay-windrowed(478)	0.989 5	0.847 3
Oats(20)	1	1
Soybean-notill(972)	0.780 9	0.887 9
Soybean-mintill(2455)	0.811 0	0.857 0
Soybean-clean(593)	0.674 5	0.782 4
Wheat(205)	0.960 9	0.960 9
Woods(1265)	0.968 4	0.969 9
Buildings-Grass-Trees-Drives(386)	0.655 4	0.676 2
Stone-Steel-Towers(93)	0.860 2	0.860 2
总体分类精度(%)	82.68	87.62
Kappa 系数	0.812 9	0.865 4

器为 KNN 时, MFA 比 LDA 精度高, 因为 MFA 使用了图框架, 能挖掘出数据中的流形, 保持局部近邻结构不变, 加强了同类数据点的紧密性, 同时推远不同类数据, 使得分类更加准确. ISSMFA 比 SSMFA 高, 因为在相同训练比例下, ISSMFA 考虑了地理空间邻近像元的位置关系, 并把周围 8 个像元的类别信息用于构图, 使得特征提取更加准确. 使用 LMPNN 进

行分类的效果普遍比 KNN 分类器好, 是由于, LMPNN 考虑了每个类的近邻信息, 而不仅仅依据少数近邻点决定其类别, 加强了分类的准确性. 表 2 的数据表明, 在训练比例为 20% 时, ISSMFA 总体分类精度能达到 87.62%. 相比 SSMFA 方法, ISSMFA 对于各类地物均有较好的分类效果, Grass-trees, Grass-pasture-mowed, Wheat, Woods 精度均达到 0.90 以上, 其中 Grass-trees 地物的分类精度提高显著, 分类精度达到 0.99.

3.2 PaviaU 数据集实验结果及分析

PaviaU 数据集是 ROSIS 传感器在意大利南部拍摄的 Pavia University, 空间分辨率为 1.3m, 图像大小为 610 × 340,




图 3 PaviaU 影像数据真实地物标记

Fig. 3 True markings of PaviaU image data

去除噪声波段, 剩余 103 个光谱波段. 此地区共包含 9 种地物标记 (947 < 每类中样本点数 < 18649), 真实地物标记如图 3 所示. 设定 $\beta = 1.3$, $k = 2$, $k^L = 13$, 为比较不同训练样本下各算法的性能, 分别从每类中随机选取 10% 20% 30% 作为训练样本. 表 3 给出了各算法在不同训练比例下的总体分类精度 (OA) 和 Kappa 系数, 和训练 10% 时各算法的运行时间. 表 4 给出了本文方法与 SSMFA 在训练 20% 时, 每类地物的分类精度.

表 3 各算法在 PaviaU 数据集的分类结果

Table 3 Results of the algorithms in the PaviaU dataset

	10%		20%		30%		运行时间/s
	OA(%)	Kappa	OA(%)	Kappa	OA(%)	Kappa	
LDA + KNN	81.93	0.811 4	85.36	0.849 9	90.11	0.893 1	18.27
MFA + KNN	83.11	0.826 9	87.29	0.867 6	90.85	0.901 3	17.66
SSMFA + KNN	86.15	0.844 3	90.83	0.894 9	92.18	0.924 0	25.63
ISSMFA + KNN	89.44	0.886 2	92.88	0.920 3	95.91	0.950 8	20.92
LDA + LMPNN	84.69	0.832 0	87.93	0.871 6	90.56	0.899 0	19.22
MFA + LMPNN	85.98	0.845 1	89.51	0.886 7	91.23	0.909 8	18.42
SSMFA + LMPNN	87.43	0.862 3	91.69	0.907 8	93.79	0.935 0	42.36
ISSMFA + LMPNN	91.22	0.900 8	95.03	0.944 1	97.14	0.968 2	26.73

从表 3 可看出 PaviaU 数据集的总体分类精度比 Indian 数据集的总体分类精度高,这是由于这两个数据集的数据分布不同导致的,PaviaU 数据集中,同类别数据点聚集度较高,不同类别数据点距离较远,因此可分度高,分类精度高。随训

表 4 PaviaU 数据集中各地物用不同算法分类后的结果

Table 4 Results of the classification of different materials in the PaviaU dataset

类别(9 类)	SSMFA + LMPNN	ISSMFA + LMPNN
Asphalt(6631)	0.886 3	0.888 0
Meadows(18649)	0.891 4	0.950 7
Gravel(2099)	0.802 7	0.867 5
Trees(3064)	0.968 2	0.965 3
Painted metal sheets(1345)	0.997 7	0.999 2
Bare Soil(5029)	0.932 7	0.957 6
Bitumen(1330)	0.856 1	0.953 0
Self-Blocking Bricks(3682)	0.837 5	0.876 8
Shadows(947)	0.996 8	1
总体分类精度(%)	91.69	95.03
Kappa 系数	0.907 8	0.944 1

练比例增加,各算法精度均有提高,在训练 10%、20%、30% 时,ISSMFA 分别比 SSMFA 精度高了 3.79%、3.34%、3.35%,说明将地理空间邻近像元信息加入到流形构图中能取得更好的分类效果。表 4 中数据表明,在训练比例为 20% 时,分别使用 SSMFA 和 ISSMFA 相比,Bitumen 地物的分类精度提高显著,提高了 10%,ISSMFA + LMPNN 对每类地物的分类精度均在 85% 以上,其中 Painted metal sheets 与 Shadows 这两类的精度接近 100%,总体分类精度达到 95.03%。

4 结 论

高光谱影像在地理空间上距离很近的像元点极有可能属于同类地物,仅仅利用现有流形算法中固定的流形结构不能全面的表达高光谱影像数据的特征信息。因此,本文提出了一种结合地理空间邻近关系的流形降维(ISSMFA)和局部平均伪近邻(LMPNN)的高光谱遥感影像分类方法。为证明本文方法的有效性,同 LDA、MFA、SSMFA 这些降维方法进行对比实验,降维后分别使用 KNN 和 LMPNN 两种方法分类。从 Indian Pine 和 PaviaU 数据集上的实验可以看出,在各算法降维后,使用 LMPNN 进行分类要比 KNN 的分类效果好;在使用相同的分类方法时,相比 LDA、MFA、SSMFA 这些降维方法,本文提出的 ISSMFA 方法分类精度明显提高,在训练 20% 时,总体精度分别能达到 87.62%、95.03%。

References:

- [1] Xie Yao. Study on hyperspectral image classification based on spatially fitting sparse representation[D]. Shenzhen: Shenzhen University 2015.
- [2] Wei Feng, He Ming-yi, Shen Zhi-ming, et al. Multi-spectral data based on manifold semi-supervised feature selection[J]. Acta Photonica Sinica 2014, 43(6): 93-97.
- [3] Turk M. Pentland-"eigenfaces for recognition[J]. Journal of Cognitive Neuroscience 1991, 3(1): 71-86.
- [4] Belhumeur P, Hespanha J, Kriegman D. Face recognition: eigenfaces vs. fish-erfaces: recognition using class specific projection[J]. IEEE

- Trans Pattern Analysis & Machine Intelligence 1997, 19(7): 711-720.
- [5] Trevor C, Michael C. Multidimensional scaling [M]. London: Chapman&Hall, 1994.
- [6] Tenenbaum J, Silva D D, Langford J. A global geometric framework for nonlinear dimensionality reduction [J]. Science, 2000, 290(5500): 2319-2323.
- [7] Belkin M, Niyogi P. Laplacian eigenmaps for dimensionality reduction and data representation[J]. Neural Computation 2003, 15(6): 1373-1396.
- [8] Roweis S T, Saul L K. Nonlinear dimensionality reduction by locally linear embedding[J]. Science 2000, 290(5500): 2323-2326.
- [9] He X, Niyogi P. Locality preserving projections [C]. In Thrun S, Saul L, et al. Advances in Neural Information Processing System, Cambridge, MA: MIT Press 2004.
- [10] Yan Shui-cheng, Xu Dong, Zhang Ben-yu, et al. Graph embedding and extensions: a general framework for dimensionality reduction [J]. IEEE Trans. on Pattern Analysis and Machine Intelligence, 2007, 29(1): 40-51.
- [11] Wang Li-zhi, Huang Hong, Feng Hai-liang. Remote sensing image classification based on SSMFA and kNNS algorithm [J]. Acta Electronic Journal 2012, 40(4): 780-787.
- [12] Pu Han-ye, Wang Bin, Zhang Li-ming. Dimensional image based on a new algorithm for hyperspectral drop manifold learning [J]. Infrared and Laser Engineering 2014, 43(1): 232-237.
- [13] Wang Cai-ling, Wang Hong-wei, Hu Bing-liang, et al. Study on hyperspectral image classification based on neighborhood segmentation [J]. Spectroscopy and Spectral Analysis, 2016, 36(9): 2919-2924.
- [14] Dudani S A. The distance-weighted k-nearest neighbor rule [J]. IEEE Trans. Syst. Man Cybern, 1976, 6(4): 325-327.
- [15] Gou J, Du L, Zhang Y, et al. A new distance-weighted k-nearest neighbor classifier [J]. Journal of Information & Computational Science, 2012, 9(6): 1429-1436.
- [16] Domeniconi C, Peng J, Gunopulos D. Locally adaptive metric nearest-neighbor classification [J]. Pattern Analysis & Machine Intelligence IEEE Transactions on 2002, 24(9): 1281-1285.
- [17] Mitani Y, Hamamoto Y. A local mean-based nonparametric classifier [J]. Pattern Recognition Letters 2006, 27(10): 1151-1159.
- [18] Zeng Y, Yang Y, Zhao L. Pseudo nearest neighbor rule for pattern classification [J]. Expert Systems with Applications 2008, 36(2): 3587-3595.
- [19] Gou J, Zhan Y, Rao Y, et al. Improved pseudo nearest neighbor classification [J]. Knowledge-Based Systems 2014, 70(C): 361-375.

附中文参考文献:

- [1] 谢 瑶. 基于空谱融合稀疏表示的高光谱图像分类技术研究[D]. 深圳: 深圳大学 2015.
- [2] 魏 峰, 何明一, 申志明, 等. 高光谱数据基于流形的半监督特征选择[J]. 光子学报 2014, 43(6): 93-97.
- [11] 王立志, 黄 鸿, 冯海亮. 基于 SSMFA 与 kNNS 算法的高光谱遥感影像分类[J]. 电子学报 2012, 40(4): 780-787.
- [12] 普晗晔, 王 斌, 张立明. 基于流形学习的新高光谱图像降维算法[J]. 红外与激光工程 2014, 43(1): 232-237.
- [13] 王彩玲, 王洪伟, 胡炳梁, 等. 基于邻域分割的空谱联合稀疏表示高光谱图像分类技术研究[J]. 光谱学与光谱分析, 2016, 36(9): 2919-2924.