

引文格式:程志会,谢福鼎.基于空间特征与纹理信息的高光谱图像半监督分类[J].测绘通报,2016(12):56-59. DOI: 10.13474/j.cnki.11-2246.2016.0401.

基于空间特征与纹理信息的高光谱图像半监督分类

程志会,谢福鼎

(辽宁师范大学城市与环境学院 辽宁 大连 116029)

Semi-supervised Classification for Hyperspectral Image Based on Spatial Features and Texture Information

CHENG Zhihui, XIE Fuding

摘要:传统高光谱图像分类方法主要使用图像的光谱特征信息,没有充分利用高光谱图像的空间特性及样本的其他信息。本文提出了一种基于空间特征与纹理信息的高光谱图像半监督分类方法。首先,将高光谱图像每一像素的光谱特征与其邻域范围内的光谱特征进行结合,得到了这一像素的空-谱特征;然后用灰度共生矩阵提取了高光谱图像的纹理特征,并与空-谱特征进行了融合;最后,用基于图的半监督分类算法进行了分类。通过在 Indian Pines 数据集和 PaviaU 数据集上进行试验,结果表明本文提出的方法能取得较高的分类结果。

关键词:高光谱图像分类;灰度共生矩阵;半监督方法;空谱特征;纹理特征

中图分类号: P237

文献标识码: B

文章编号: 0494-0911(2016)12-0056-04

20 世纪末期兴起的高光谱遥感技术是遥感科学技术领域的一项重大进展。由于高光谱遥感图像具有较高的空间分辨率及丰富的光谱信息,为准确的地物识别提供了一种可能。目前已在地质勘探、精准农业和军事用途等领域中取得了成功的应用^[1]。许多学者对高光谱图像的准确分类作了大量研究,如贝叶斯模型、特征提取和特征约减、随机森林、神经网络、模糊聚类和支持向量机^[2-5]等方法。高光谱图像分类主要分为监督和无监督两种^[3]。在监督分类方法中,基于核方法的支持向量机取得了巨大的成功,支持向量机能够在样本量受限的方式下有效地处理大的输入维度和抑制噪声样本^[3]。在无监督分类方法中,模糊聚类因其无需使用标记样本,在缺少大量标记的高光谱图像分类中取得了巨大的成功。众所周知,监督方法的主要缺点是分类模型和分类准确度主要依赖于标签点的训练数据集数量,而获取大量的高光谱图像类别标记是一项耗时和耗成本的工作。非监督方法虽然对带标签样本不敏感,但是由于缺乏先验知识,对聚类类别和真实类别之间的联系是不确定的。

半监督学习由于其只需要少量的标记样本在高光谱图像分类中引起了研究者的高度关注^[1]。半监督学习将标签数据和无标签数据结合,以提高分类的准确度。常用的半监督方法有自训练^[6]、直推式支持向量机^[6]、生成式模型算法和基于图的方法^[7-8]。在高光谱图像应用中,提出了许多基于图的半监督方法,文献[9]提出了一种基于流行学习

构图的 LapSVM 算法,改进了传统的权值仅能反映数据点两两之间关系的问题,在典型的高光谱图像数据集上提高了分类的准确度,但其仅仅考虑了高光谱图像的光谱特征,没有考虑其丰富的空间信息。文献[1]将主动学习与图的半监督相结合,改进了已有标记数据随机选取的缺点,在一定程度上提高了分类的准确度。虽然基于图的半监督在高光谱图像应用中已取得很大成功,但仍有许多不足:现有的高光谱图像分类模型大部分在分类中只考虑了光谱特征信息,很少关注其空间特征,导致分类准确率不高。

针对上述问题,本文提出一种融合空间信息与光谱信息的半监督高光谱图像分类方法,流程如图1所示。首先,将光谱特征与其邻域内特征相结合,提出一种新的空-谱特征组合方法;然后利用灰度共生矩阵方法对图像的空间纹理特征进行提取,并与提出的空-谱特征组合方法进行结合,作为基于图的半监督分类器输入。

一、方 法

1. 高光谱图像特征提取

高光谱图像具有维数高、波段间相关性大、非线性等特点,容易出现维数灾难与数据冗余等问题。因此,在对高光谱图像进行空-谱特征提取之前,需要对图像进行降维处理。主成分分析(PCA)作为一种简单、成熟的降维方法,在高光谱图像降维中应用得最为广泛,因此首先使用 PCA 对高光谱数据进行降维处理^[10-11]。

收稿日期: 2016-04-07; 修回日期: 2016-07-15

作者简介:程志会(1990—),男,硕士生,主要从事空间数据挖掘方面的研究。E-mail: 811269090@qq.com

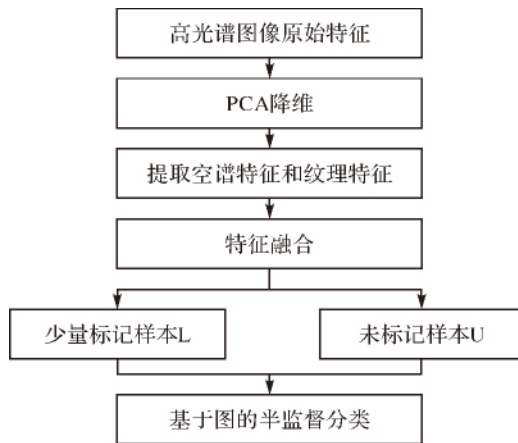


图1 本文算法流程

假设原始的高光谱图像使用 PCA 降维后包含的波段数为 b , 则高光谱图像中任意像素 x_i 的空-谱特征为

$$z_i = \{f_i, f_{i+1}, f_{i+2}, \dots, f_{(i+n) \times (i+n-1)}\} \in R^{b \times (k \times k)} \quad (1)$$

式中, f_i 为像素 x_i 的光谱向量; $f_{i+1}, f_{i+2}, \dots, f_{(i+n) \times (i+n-1)}$ 为像素 x_i 的 $k \times k$ 邻域内各个像素的光谱向量; k 为高光谱图像窗口的大小。这种方法不仅考虑了高光谱图像的光谱特征, 而且简单考虑了图像每个像素周边的空间信息, 弥补了单独利用光谱特征进行图像分类的不足; 将像素 x_i 的 $k \times k$ 邻域矩阵展开成一个 $1 \times k^2$ 的行向量, 作为像素 x_i 新的空-谱特征信息。

高光谱图像不仅包含丰富的光谱和空间特征, 而且含有丰富的纹理特征。纹理特征能够有效地表示高光谱图像中地物纹理分布信息, 在一定程度上抑制了高光谱图像分类中的同谱异物现象^[9]。纹理特征提取方法可以分为基于统计特征、基于结构和基于空间频率^[10]等方法。由于高光谱图像特有的性质, 目前对于纹理特征的提取, 一般都是基于统计的方法。统计方法中的灰度共生矩阵(GLCM) 通过计算高光谱图像中各像素点灰度之间的联合概率表示纹理, 反映了高光谱图像中像元之间的空间依赖性^[9]。

GLCM 描述了高光谱图像范围内, 两个距离为 d 、方向为 θ ($0^\circ, 45^\circ, 90^\circ, 135^\circ$) 的像素点在高光谱图像中出现的概率。通过改变 (d, θ) 值, 可以组合成不同的 GLCM 来分析图像的灰度空间分布格局。GLCM 提供了高光谱图像方向和幅度变化的信息, 但是不能直接提供区别图像的纹理信息。为了有效地利用共生矩阵描述纹理, Haralick 等在 GLCM 的基础上, 提出了 14 种特征对高光谱图像的纹理进行量化^[12]。本文选择文献中学者常用的 4 个特征去描述和区分纹理信息, 见表 1。

表1 GLCM 常用的 4 种纹理特征

GLCM 纹理统计测度	统计特性
对比度(contrast) $\text{con} = \sum_i \sum_j (i - j)^2 f(i, j)$	反映图像的清晰度和纹理沟纹深浅的程度
能量(energy) $\text{ene} = \sum_i \sum_j (f(i, j))^2$	反映图像灰度集中情况和纹理的粗细度, 纹理越粗, 能量越大
同质性(homogeneity) $\text{hom} = \sum_i \sum_j \frac{f(i, j)}{1 + (i - j)^2}$	反映图像的纹理相似性, 值越高, 局部区域越相似, 具有较小的灰度差异
相关性(correlation) $\text{cor} = \frac{\sum_i \sum_j ijf(i, j) - \mu_1 \mu_2}{\sigma_1 \sigma_2}$	反映 GLCM 在行或列向上的相似程度

根据表 1 提供的参数对降维后高光谱图像提取常用的 4 种纹理特征, 共得到 4 个方向的灰度共生矩阵, 因此得到 16 个纹理特征, 对 4 个矩阵相同参数的纹理特征取均值和方差, 得到 8 个纹理特征。

高光谱图像的光谱特征、空间特征和纹理特征提取后, 还需进行融合, 虽然已有文献提出了各种融合方法^[12-13], 本文为了简化处理, 选择最简单的处理方式, 即直接组合法。设高光谱图像光谱特征为 x_{spec} , 空-谱组合提取特征为 $x_{\text{spec-spat}}$, 纹理特征为 x_{text} , 因此直接组合后的特征为

$$r = [x_{\text{spec}} \ x_{\text{spec-spat}} \ x_{\text{text}}] \quad (2)$$

2. 基于图的半监督高光谱图像分类

高光谱图像的特征提取后, 将利用基于图的半监督方法对高光谱图像进行分类。该部分将介绍基于图的半监督中的局部和全局一致性(local and global consistency, LGC) 方法^[14-15]。假设有 $n = l + u$ 个样本 x_i ($1 \leq i \leq n$) 组成一个矩阵 $X = [x_1 \ x_2 \ \dots \ x_l \ x_{l+1} \ \dots \ x_{l+u}]$, 其中 l 为高光谱图像中带标签样本的数目; u 为高光谱图像中无标签样本的数目。 $y_i \in R^C$ 为第 i 个样本的标签向量, 如果样本 x_i 的标签属于第 j 类, 则 $y_{ij} = 1$; 否则 $y_{ij} = 0$ 。显然, $y_i = 0$ 意味着样本 x_i 的标签是未知的, 本文的目标即预测 u 个未标记样本的标签。LGC 的主要过程如下:

1) 通过 kNN 构建一个加权的图 G , 设 $W = [w_{ij}]_{n \times n}$ 是图 G 的邻接矩阵, w_{ij} 表示为

$$w_{ij} = \begin{cases} e^{-\frac{\|x_i - x_j\|^2}{2\sigma^2}} & x_j \in N_k(x_i) \\ 0 & \text{其他} \end{cases} \quad (3)$$

式中 σ 为高斯核宽, 控制 x_i 和 x_j 之间距离的衰变速率

度; $N_k(x_i)$ 为样本 x_i 的 k 近邻; w_{ij} 确保两个相近的样本有大的相似性和两个不相近的样本有小的相似性。

2) 对权重进行标准化处理

$$S = D^{-1/2} W D^{-1/2} \quad (4)$$

式中 D 为一个对角矩阵

$$D = \sum_{j=1}^n W_{ij} \quad i = 1, 2, \dots, n$$

3) 计算高光谱数据的样本标签预测函数

$$F = (1 - \alpha) (I - \alpha S)^{-1} Y \quad (5)$$

式中 α 为 $[0, 1]$ 之间的参数; F_{ij} 为样本点 x_i 被分为第 j 类标记的可能性大小; 输出 u 个未标记样本的预测标签为 $y_{ij} = \arg\max_{1 \leq j \leq c} F_{ij} \quad 1 \leq i \leq n$ 。

二、试验

为了验证本文方法的有效性,在两组高光谱图像数据集上进行试验。这两组高光谱图像数据集为 Indian Pines 数据集和 PaviaU 数据集。Indian Pines 数据集为 1992 年采用 AVIRIS 系统在美国印第安纳州的一个农场拍摄的航空数据,空间分辨率为 20 m,图像大小为 145×145 像素。去除水汽吸收波段,剩余 200 个光谱波段。此高光谱数据集中,由于有些作物标记样本较少,因此选择 9 种较多的地物类型进行分类处理,真实地物标记如图 2(a) 所示。PaviaU 数据集为 ROSIS 系统在意大利南部拍摄的 Pavia University,空间分辨率为 1.3 m,图像大小为 610×340 像素,去除噪声波段,剩余 103 个光谱波段,此地区共包含 9 种地物标记(946 < 每类中样本点数 < 18 650),如图 3(a) 所示。

首先对两组高光谱数据集进行主成分分析,选取前 3 个主成分进行空间特征和纹理特征提取,并对提取的特征进行组合处理,然后使用基于图的半监督方法预测未标记样本的标签。为了说明本文方法的性能,将其与 SVM 方法进行了比较。

为方便起见,在试验中所用的重要参数统一列在表 2 中。

表 2 试验中用到的重要参数

参数	意义
n	总的样本个数
C	需要分类的类别个数
α	样本邻域与初始标记比重
σ	高斯核宽

在本文试验中,每类随机选取 50 个样本进行标记,其余的作为未标记样本。 σ 和 α 两个参数分别取值 1 和 0.4,试验以总精度 OA 和 Kappa 系数两个参

数量化高光谱图像的分类效果,为了减少随机性,每个试验均重复 20 次,并对 20 次的结果取平均值。

1. Indian Pines 数据集试验结果与结论分析

该数据集共分为 16 类,其中有 7 类样本点数目较少(<400),因此选择其余 9 类进行分类处理(482 < 每类中样本点数 < 2456),每类随机选取 50 个样本标记(0.20% < 标记样本的比例精度 < 10.4%),分析比较了 2 种算法在不同的特征下的总精度 OA 和 Kappa 系数。分类结果见表 3。融合特征后的高光谱图像真实影像结果如图 2 所示。

表 3 Indian Pines 数据集分类结果

特征	k	总精度	SVM	LGC
x_{spec}	0	OA	0.648 8	0.655 9
		Kappa	0.601 2	0.599 9
$x_{\text{spec-spat}}$	5	OA	0.742 8	0.772 5
		Kappa	0.694 5	0.738 7
$x_{\text{spec-spat-text}}$	5	OA	0.783 2	0.822 3
		Kappa	0.739 9	0.783 6
$x_{\text{spec-spat}}$	7	OA	0.773 1	0.813 2
		Kappa	0.736 5	0.792 0
$x_{\text{spec-spat-text}}$	7	OA	0.802 1	0.856 4
		Kappa	0.775 6	0.823 5
$x_{\text{spec-spat}}$	9	OA	0.792 8	0.832 9
		Kappa	0.767 5	0.808 9
$x_{\text{spec-spat-text}}$	9	OA	0.834 1	0.873 2
		Kappa	0.803 0	0.841 0

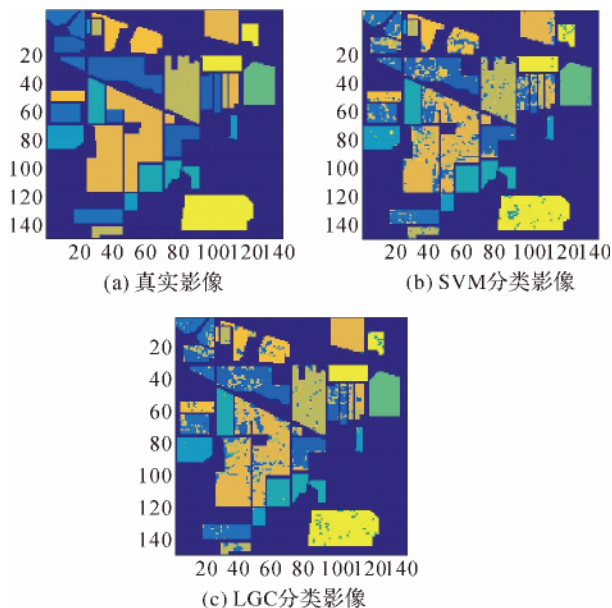


图 2 Indian Pines 数据集分类影像

真实地物标记如图 2(a) 所示,由表 3 和图 2 可知,结合高光谱图像光谱特征、空间特征和纹理特征的分类结果明显优于单一使用光谱特征进行分类的

效果; 并且随着纹理特征的加入, 精度提升了 3% ~ 4% 左右。随着窗口的增加, 分类精度得到显著提升, 说明本文提出的光谱特征和纹理特征的融合效果显著。从表 3 最后一列也可以看出, 基于图的半监督方法是优于 SVM 方法的, 精度都有约 4% 的提升, 说明结合空间特征与纹理特征高光谱图像, 应用图的半监督分类方法的分类精度较好。

2. PaviaU 数据集试验结果与结论分析

PaviaU 数据集中, 包含 9 种地物标记(946 < 每类中样本点数 < 18 650), 每类随机选取 50 个样本标记(0.027% < 标记样本的比例精度 < 0.52%), 分析比较了 3 种算法的总精度 OA 和 Kappa 系数, 分类结果见表 4。融合特征后的高光谱图像真实影像结果如图 3 所示。

表 4 PaviaU 数据集分类结果

特征	k	总精度	SVM	LGC
x_{spec}	0	OA	0.732 8	0.778 9
		Kappa	0.683 6	0.713 5
$x_{\text{spec-spat}}$	5	OA	0.803 2	0.849 9
		Kappa	0.755 6	0.792 5
$x_{\text{spec-spat-text}}$	5	OA	0.821 5	0.872 3
		Kappa	0.789 5	0.832 1
$x_{\text{spec-spat}}$	7	OA	0.856 9	0.892 8
		Kappa	0.813 2	0.865 2
$x_{\text{spec-spat-text}}$	7	OA	0.871 3	0.916 3
		Kappa	0.842 9	0.885 4
$x_{\text{spec-spat}}$	9	OA	0.892 5	0.931 5
		Kappa	0.864 5	0.917 8
$x_{\text{spec-spat-text}}$	9	OA	0.912 5	0.968 5
		Kappa	0.882 3	0.956 5

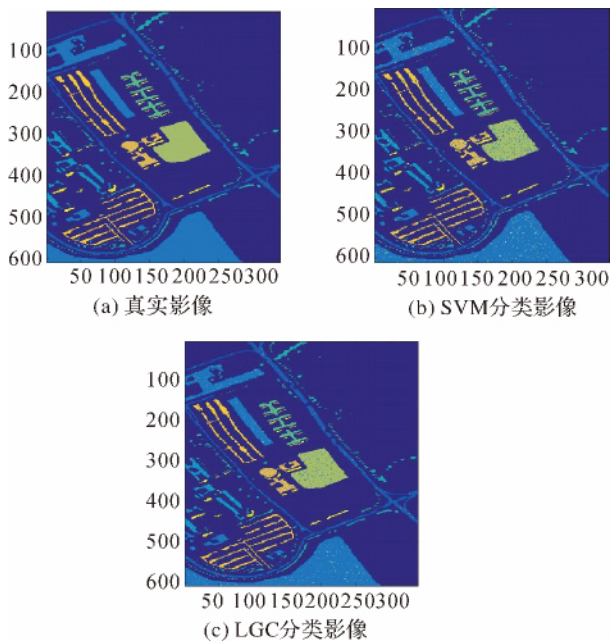


图 3 PaviaU 数据集分类影像

由表 4 和图 3 可知, 本文提出的纹理特征和光谱特征的结合改善了高光谱图像的分类结果, 要优于单一使用光谱特征或空间特征进行分类。随着窗口尺寸的增加, 分类精度得到显著提升, 说明高光谱图像具有包含空间信息的特性。从表 4 列向来看, 本文提出的基于图的半监督方法优于 SVM 方法, 说明融合空间特征和纹理信息的高光谱图像, 使用图的半监督分类方法的分类精度更高。

三、结论和展望

本文针对高光谱图像分类提出了一种基于空间特征信息和光谱特征结合的混合图半监督分类方法。首先对高光谱图像进行降维处理, 选取前 3 个主成分进行空-谱特征和纹理特征提取; 然后将这些光谱特征、空间特征和纹理特征进行特征融合; 最后将融合后的特征输入到基于图的半监督分类器中, 进行高光谱图像的分类。对两个实际的高光谱图像数据集进行试验表明: ①本文提出的空间特征和纹理特征结合的方法相较于传统的只利用光谱特征和单一空间特征进行图像分类, 精度得到很大提升; ②与传统的方法相比, 基于图的半监督方法不仅在精度上得到提高, 而且减少了输入的参数。本文得到的空-谱特征仅仅是考虑像素周边的邻域信息, 没有进行进一步的研究, 这是后期需要研究的方向; 并且光谱特征、空间特征仅仅是进行简单的融合, 将来可对更多的融合方式进行探讨。

参考文献:

[1] 田彦平, 陶超, 邹峥嵘, 等. 主动学习与图的半监督相结合的高光谱影像分类[J]. 测绘学报, 2015, 44(8): 919-926.

[2] 李慧, 王云鹏, 李岩, 等. 基于 SVM 和 PWC 的遥感影像混合像元分解[J]. 测绘学报, 2009, 38(4): 323-329.

[3] 金晶, 邹峥嵘, 陶超. 高分辨率遥感影像的压缩纹理元分类[J]. 测绘学报, 2014, 43(5): 493-499.

[4] 张伟, 杜培军, 张华鹏. 基于神经网络的高光谱混合像元分解方法研究[J]. 测绘通报, 2007(7): 23-26.

[5] 杜培军, 林卉, 孙敦新. 基于支持向量机的高光谱遥感分类进展[J]. 测绘通报, 2006(12): 37-40.

[6] DOPIDO I, LI J, MARPU P R, et al. Semisupervised Self-Learning for Hyperspectral Image Classification[J]. Geoscience & Remote Sensing IEEE Transactions on, 2013, 51(7): 4032-4044.

(下转第 73 页)

常规测图方法相比,三维激光扫描仪具有速度快、信息量大、精度高、实时性强、自动化程度高等优点,克服了传统测量仪器的局限性,能够直接获取高精度三维数据。特别是在人员难以到达的地区有着显著的优势。由于激光扫描仪获取的是海量的点云数据,同时点云数据中可能会包含大量的杂草和树木等数据,如何在不影响精度和建模需要的前提下实现自动、快速获取适当密度的点云数据成为制约其应用的关键问题,解决了这一问题必将使三维激光扫描技术在地形图测绘领域得到更广阔的应用。

参考文献:

- [1] 张春森,张卫龙,郭丙轩,等. 倾斜影像的三维纹理快速重建[J]. 测绘学报, 2015, 44(7): 782-790.
- [2] 马立广. 地面三维激光扫描仪的分类与应用[J]. 地理空间信息, 2005, 3(3): 60-62.
- [3] 余建伟,张攀攀,翁国康,等. 中海达 iScan-P 便携式移动三维激光测量系统概述[J]. 测绘通报, 2015(3): 140-141.
- [4] 王靖,师军良. 无棱镜全站仪在数字地形图测绘中的应用[J]. 黄河水利职业技术学院学报, 2008, 20(1): 46-48.
- [5] 江振治,王刃,胡海彦,等. 机载三维激光雷达系统误差分析及精度验证[J]. 测绘科学与工程, 2015(6): 41-46.
- [6] 周华伟. 地面三维激光扫描点云数据处理与模型构建[D]. 昆明: 昆明理工大学, 2011.
- [7] 陆亚. 三维激光扫描仪测量精度的室内准确性评价[J]. 城市建设理论研究(电子版), 2013(1).
- [8] 毕硕本,张国建,侯荣涛,等. 三维建模技术及实现方法对比研究[J]. 武汉理工大学学报, 2010(16): 26-30.
- [9] JÖNSSON P, EKLUNDH L. Seasonality Extraction by Function Fitting to Time-series of Satellite Sensor Data[J]. IEEE Geoscience and Remote Sensing, 2002, 40(8): 1824-1832.
- [10] 杜晓,王世新,周艺,等. 一种新的基于 MODIS 的地表含水量模型构造与验证 [I]. 武汉大学学报(信息科学版), 2007, 32(3): 205-208.
- [11] 张红卫,陈怀亮,申双和,等. 基于 MODIS 数据的农田浅层土壤湿度指数的构造与应用 [C]//第 26 届中国气象学会年会农业气象防灾减灾与粮食安全分会场论文集. 杭州: [s. n.], 2009.
- [12] SHEN R, YU P, YAN J, et al. Retrieving Soil Moisture by TVDI Based on Different Vegetation Index: A Case Study of Shanxi Province [C]//2012 International Conference on Computer Science and Electronics Engineering (ICCSEE). [S. l.]: IEEE, 2012: 418-422.
- [13] 严婧. 基于参数重建的土壤湿度遥感监测及系统研制[D]. 南京: 南京信息工程大学, 2013.
- [14] 李晓光. 基于 MODIS-NDVI 的内蒙古植被覆盖变化及其驱动因子分析[D]. 呼和浩特: 内蒙古大学, 2014.
- [15] 张学艺. 基于 EOS/MODIS 的几种植被指数[J]. 安徽农业科学, 2009(26): 12842-12845.
- [16] CAMPS-VALLS G, MARSHEVA T V B, ZHOU D. Semi-Supervised Graph-based Hyperspectral Image Classification[J]. Geoscience & Remote Sensing IEEE Transactions on, 2007, 45(10): 3044-3054.
- [17] LIU X, PAN S, HAO Z, et al. Graph-based Semi-supervised Learning by Mixed Label Propagation with a Soft Constraint [J]. Information Sciences, 2014, 277: 327-337.
- [18] 王小攀. 基于图的高光谱遥感数据半监督分类算法研究[D]. 北京: 中国地质大学, 2014.
- [19] 林晓峰. 基于纹理特征的遥感图像分类算法研究[D]. 大连: 大连理工大学, 2007.
- [20] 倪国强,沈渊婷,徐大琦. 一种基于小波 PCA 的高光谱图像特征提取新方法[J]. 北京理工大学学报, 2007, 27(7): 621-624.
- [21] 王增茂,杜博,张良培,等. 基于纹理特征和形态学特征融合的高光谱影像分类法[J]. 光子学报, 2014(8): 1-7.
- [22] 樊利恒,吕俊伟,于振涛,等. 基于核映射多光谱特征融合的高光谱遥感图像分类法[J]. 光子学报, 2014(6): 93-98.
- [23] KLAUS B, KLIJN F. Local and Global Consistency Properties for Student Placement [J]. Journal of Mathematical Economics, 2011, 49(3): 222-229.
- [24] ZHOU D, BOUSQUET O, JAL T N, et al. Learning with Local and Global Consistency [J]. Advances in Neural Information Processing Systems, 2004, 17(4): 321-32.