

基于谱 - 空 - 纹特征融合的高光谱影像分类方法^{*}

姚 烧 谢福鼎

(辽宁师范大学城市与环境学院, 大连 116029)

摘要 文章提出了一种融合光谱信息, 空间信息和纹理信息的高光谱影像分类方法. 首先采用主成分分析降低高光谱影像的维度, 然后利用灰度共生矩阵从各主成分提取纹理信息, 并根据数学形态学特征和光谱信息定义了一种融合谱 - 空 - 纹的相似度距离, 最后通过伪近邻 (pseudo nearest neighbor, PNN) 分类器对影像地物进行分类. 为了说明所提出方法的有效性, 文章对两个常用的具有不同空间分辨率和光谱分辨率的真实高光谱影像数据集进行了相应的实验, 试验结果和比较结果表明, 利用所提出的方法可以得到较高的分类精度.

关键词 谱 - 空 - 纹, 特征融合, PNN 分类器, 高光谱分类.

MR(2000) 主题分类号 62H30, 68T10

Classification for Hyperspectral Images by Fusing Spectral-Spatial-Texture Features

YAO Rao XIE Fuding

(Department of Urban and Environmental Science, Liaoning Normal University, Dalian 116029)

Abstract A classification method for hyperspectral images is proposed by fusing spectral-spatial-texture features. The principal component analysis is first used to reduce the dimension of hyperspectral image, and then the texture is extracted by gray-level co-occurrence matrix (GLCM) from the obtained principal components. At last, the classification results are obtained by using of PNN classifier. To demonstrate the validity of the proposed method, two real hyperspectral images with the different spatial and spectral resolutions are fed to the proposal. The experimental and comparative results indicate that it is important to consider spectral-spatial-texture features to classify remote sensing images.

^{*} 国家自然科学基金 (41771178, 61772252) 和广东省数学与交叉科学普通高校重点实验室开放课题资助课题.

收稿日期: 2017-10-12.

通信作者: 谢福鼎, Email: xiefd@lnnu.edu.cn.

编委: 贾晓红.

Keywords Spectral-spatial-texture, multi-features fusion, PNN classifier, hyper-spectral image classification.

1 引言

高光谱遥感影像具有光谱范围广, 光谱分辨率高, 光谱曲线连续等优点, 在各个领域有着广泛的应用. 高光谱影像分类是遥感领域研究的基本问题. 一般来说, 分类器的性能会随着维数的增加而降低^[1,2]. 为了达到良好的分类性能, 有必要对数据进行降维处理. 作为分类的预处理方法, 降维技术将高维数据以一种包含关键信息的低维形式表示. 常见的降维方法可以分为无监督和监督的. 无监督的降维方法在不使用任何标签信息的情况下, 揭示低维数据结构, 例如: 主成分分析, 局部保持投影和近邻保持投影^[3]等. 有监督的降维方法使用标记的样本来判别预测样本, 如线性判别分析^[4], 非参数加权特征提取^[5], 局部 fisher 判别分析^[6]等. 这些基于谱的降维方法, 利用光谱域的欧氏距离来度量样本之间的相似性. 然而, 两种具有较小光谱距离的像元也可能具有较大的空间像元距离, 因此对于高光谱影像来说, 光谱域的相似性不足以揭示不同像元之间的内在关系. 因此, 在度量像元相似性和寻求判别投影时, 还应考虑像元的空间相关性.

空间结构信息已经被证明对改善高光谱影像的表示和提高分类精度有一定的参考价值. 采用空间信息的方法可分为空间滤波方法和特征提取技术. 文 [7] 利用基于小波和各向异性偏微分方程平滑原始高光谱数据的空间信息, 并结合平滑后和原始的高光谱图像光基于图分类. Kang 等人^[8]提出了一种基于边缘保留滤波的光谱空间分类框架, 在滤波概率映射后, 根据最大概率选取每个像元的类别. 特征提取技术包括基于数学形态学的提取和图像分割. 马尔可夫随机场技术^[9], 通过建模空间相邻像元相关性, 将空间信息融入概率框架中. 文 [10] 构造了一种结合多光谱和空间信息的支持向量机集成模型.

已有的方法仅仅考虑了光谱信息或空间的位置信息, 并未充分利用数据中隐含的纹理信息. 因此, 本文在融合了谱信息, 空间信息和纹理信息的的基础上, 定义了一种新的衡量像素间相似度的函数, 并利用 PNN 分类器, 提出了一种高光谱影像分类方法. 我们用本文方法在高光谱数据集 Indian Pines 和 PaviaU 上进行了分类实验, 这两个遥感领域经典的数据集经常被用来测试高光谱影像的分类效果. 为了验证本文方法的有效性, 我们进行了多组对比实验, 结果表明本文方法可以有效地提高分类精度.

2 基于谱 - 空 - 纹的特征提取

2.1 基于灰度共生矩阵的纹理特征提取

纹理是相邻像素或相邻区域的几何位置关系的表示, Haralick^[11]提出了灰度共生矩阵 (gray level co-occurrence matrix, GLCM) 以来, 目前已成为图像纹理分析的主要工具之一. 灰度共生矩阵是一种通过对图像中相隔一定距离的两像元间的灰度关系, 即图像中灰度的空间相关特性进行统计, 从而用联合条件概率密度表明图像纹理结构的统计学方法^[12]. Haralick^[11]通过 GLCM 提取了 14 种特征, 本文选取了角二阶矩, 对比度, 熵, 逆差矩等 4 种常用于描述图像的属性进行纹理提取.

2.2 基于数学形态学的空间特征提取

数学形态学的空间特征提取, 旨在通过一组已知的形状和大小的结构元素来分析像素之间的空间关系, 提取后的形态特征包括原始光谱信息和空间信息. 定义以 x_i 为中心, 开一个大小为 $p \times p$ 的窗口 P_i , 其中 p 为正奇数, P_i 称为 x_i 的空间域. 定义 x_i 和 x_j 两点的谱 - 空相似度距离为

$$d_{\text{spat-spec}} = \min(d_{\text{spat}}(x_i, P_j), d_{\text{spat}}(x_j, P_i)), \quad (1)$$

其中 P_i 和 P_j 分别是以像元 x_i 和 x_j 为中心对应的空间域, $d_{\text{spat}}(x_i, P_j)$ 是像元 x_i 到空间域 P_j 的距离, 计算公式为

$$d_{\text{spat}}(x_i, P_j) = \frac{\sum_{q=1}^{p^2} v_{jq} \|x_i - x_{jq}\|}{\sum_{q=1}^{p^2} v_{jq}}, \quad x_{jq} \in P_j, \quad (2)$$

其中 v_{jq} 表示空间域 P_j 中的像元 x_{jq} 到中心像元 x_j 的权重, 计算方法采用 RBF 核函数

$$v_{jq} = \exp\left(-\frac{\|x_j - x_{jq}\|^2}{2\sigma_1^2}\right), \quad (3)$$

权值大小反映了光谱信息相关性与像元间的影响程度. 通过这种方式提取的空间信息, 不仅弥补了以往传统方法中只单一考虑光谱信息的不足, 同时有效地增大了同类地物的相关性, 使得同类地物作为近邻的概率增加, 提高了分类效果.

2.3 融合谱 - 空 - 纹的相似度距离

本文提出了一种同时融合光谱信息, 空间信息和纹理信息的相似度距离 d_{sst} , 让这些信息同时协同测度. 在本文中, 两个像元 x_i 和 x_j 的相似度距离 d_{sst} 采用权重的方法进行计算, 定义为

$$d_{\text{sst}} = \mu \cdot d_{\text{spat-spec}} + (1 - \mu)d_{\text{text}}, \quad (4)$$

其中 $d_{\text{spat-spec}}$ 是基于空间特征提取的谱 - 空距离, d_{text} 是基于 GLCM 提取的纹理相似度; μ 是权重因子, 目的是调节 $d_{\text{spat-spec}}$ 和 d_{text} 在相似度距离中的比重, 其中 $\mu > 0$.

3 谱 - 空 - 纹伪近邻分类器

3.1 伪近邻分类器

k 近邻 (k -nearest neighbor, KNN) 规则作为数据挖掘中常用的算法之一^[13], 在模式分类领域得到了广泛的研究和应用. 伪近邻 PNN^[14] 规则是一基于距离加权 k 近邻和局部均值的 k 近邻 (local mean-based k -nearest neighbor, LMKNN)^[15] 的分类器. 与经典的 KNN 不同的是, PNN 不再是寻找距离样本点最近的邻居点, 而是引入伪近邻的概念, 首先给每个类的 k 个最近邻加权, 然后, 计算所有类间距离加权之和, 将最小值所对应的伪最近邻的类标号分配给待测点.

给定一个待测样本 x 和训练集 T , 待测样本 x 的类标号通过以下步骤来确定.

步骤 1 在训练集 T 的每类 ω_s 中搜索距离待测样本 x 最近的 k 个邻居点, 这些邻居点称为 x 的伪近邻, 用 x^{PNN} 表示. 这些伪近邻组成集合 T_{ω_s} .

$$T_{\omega_s}^k = \{x_t^i \in R^n\}_{t=1}^k,$$

然后将它们所对应的欧氏距离 d 按递增顺序排列.

步骤 2 根据 d 的大小分别给 k 个邻居点加权, 距离越小的权重越大, w_t^s 表示在类 T_{ω_s} 中第 t 个邻居 x_t^s 的权值, 计算公式为

$$w_t^s = \frac{1}{t}, \quad t = 1, 2, \dots, k. \quad (5)$$

步骤 3 计算待测样本 x 与每类伪近邻的加权距离之和

$$d(x, x_s^{\text{PNN}}) = w_1 \times d(x, x_1^s) + w_2 \times d(x, x_2^s) + \dots + w_k \times d(x, x_k^s). \quad (6)$$

步骤 4 将待测样本 x 分为所有类中与伪近邻距离 $d(x, x_s^{\text{PNN}})$ 最小的类别中.

根据以上步骤可以看出, 当 $k = 1$ 时, PNN 的计算规则等价于 KNN 和 LMKNN 的计算规则.

3.2 基于谱 - 空 - 纹的伪近邻分类器 (SSTPNN)

本文提出的方法对分类器 PNN 进行了改进, 改进后的分类器称为谱 - 空 - 纹的伪近邻分类器 (spectral-spatial-texture-based pseudo nearest neighbor, SSTPNN). 首先用谱 - 空 - 纹的相似度距离 d_{sst} 代替了欧氏距离对两个样本进行相似度测量, 找到与待测样本最近的 k 个邻居点, 并分别计算与这些邻居点的权重, 最后将其归为类间距离加权之和最小值所对应的伪最近邻所在类别. 具体步骤如下

步骤 1 根据 (4) 式计算出高光谱影像中每个待测样本点 x 的 k 个伪近邻 x_s^{PNN} , 并将它们的距离 d_{sst} 按递增顺序排列.

步骤 2 为了加大同类样本的相似性, 将空间域 P_i 引入到权值的计算中, 当 x_j 为 x_i 的局部伪近邻且 x_i 属于 P_j 或 x_j 属于 P_i 时, 加大权值. 因此权值 W 的更新公式为

$$W_t^s = \begin{cases} \exp\left(-\frac{d_{\text{sst}}(x_i, x_j)}{2\sigma_2^2}\right) \cdot w_t^s, & x_i \in x_{j_s}^{\text{PNN}}, x_i \in P_j \text{ 或者 } x_j \in x_{i_s}^{\text{PNN}}, x_j \in P_i, \\ w_t^s, & x_i \in x_{j_s}^{\text{PNN}} \text{ 或者 } x_j \in x_{i_s}^{\text{PNN}}. \end{cases}$$

步骤 3 计算待测样本 x 与每类伪近邻的加权距离之和

$$d_{\text{sst}}(x, x_s^{\text{PNN}}) = W_1^s \times d_{\text{sst}}(x, x_1^s) + W_2^s \times d_{\text{sst}}(x, x_2^s) + \dots + W_k^s \times d_{\text{sst}}(x, x_k^s). \quad (7)$$

步骤 4 将待测样本 x 分为所有类中与伪近邻距离 $d_{\text{sst}}(x, x_s^{\text{PNN}})$ 最小的类别中.

4 实验结果与分析

4.1 实验数据

为了说明提出方法的有效性, 本文采用了在高光谱分类中广泛使用的 Indian Pines 和 PaviaU 数据集进行测试.

1) 美国印第安纳州测试地 (indian pines) 高光谱影像数据集是通过 AVIRIS 传感器获取的. 该数据共 220 个波段, 空间分辨率为 20m, 图像大小为 145×145 , 波长覆盖范围 $0.4 \sim 2.5 \mu\text{m}$. 除去水汽和噪声吸收较为明显的波段, 剩下的 200 个波段用于特征提取和分类研究. 该数据包括 16 个地物类型, 本文采取每个类别随机选取 10% 的标记样本作为训练集. 图 1(a) 为测试影像的参考图及包含的各类地物像素数.



图 1 两个数据集的标准分类结果参考图

(Figure 1 The reference images of standard classification results of two data sets)

2) 意大利帕维亚大学 (PaviaU) 高光谱影像数据集是通过 ROSIS-3 传感器获取的. 该数据原始波段 115 个, 空间分辨率 1.3m, 图像大小为 610×340 , 波长覆盖范围 $0.43\text{--}0.86\mu\text{m}$. 除去水汽和噪声吸收较为明显的 12 个波段, 选择其余 103 个波段进行特征提取和分类. 该数据包括 9 类地物, 每类随机选取 1% 的标记样本作为训练集. 图 1(b) 为测试影像的参考图及包含的各类地物像素数.

4.2 实验参数

实验中 σ_1 取 0.01, σ_2 取 0.1, μ 取 0.2. PCA 降维取累计贡献率大于 85% 的主成分, 其中 Indian Pines 数据集选取前 5 个主成分, PaviaU 数据集提取的维数为 4. 每个算法实验 10 次求取均值作为最终结果. 这里采用总体分类精度 (overall accuracy, OA) 以及 Kappa 系数 (Kappa coefficient, KC) 两个指标对分类精度进行评价. 由于分类效果随着空间域窗口大小 p 和邻居个数 k 的大小而变化, 因此针对两个参数的数值不同, 本文进行了多次试验, 图 2 分别是 Indian Pines 和 PaviaU 两个数据集在不同空间域大小 p 和邻居个数 k 下的总体分类精度 OA, 其中 Indian Pines 的 k 值取值范围是 $[1, 8]$, p 值取值范围是 $[3, 9]$, PaviaU 的 k 和 p 的取值范围分别是 $[1, 10]$ 和 $[3, 11]$.




图 2 两个数据集在不同 p 和 k 下的总体分类精度: (a) Indian Pines 数据集 (b) PaviaU 数据集
(Figure 2 Overall accuracy with different p and k on two data sets. (a): Indian Pines. (b): PaviaU)

由图 2 可以看出, 就 Indian Pines 数据而言, 在 $k = 2$, $p = 5$ 时, 总体分类精度最高; 然而

对于 PaviaU 数据, 当 k 和 p 分别取 3 和 7 时, 分类效果最好. 分类精度随着 k 和 p 两个参数的数值变化起伏不定, 说明数据间的拟合依靠这两个值的平衡才能达到稳定, 但当这两个数值过大时, 分类精度降低说明过大的数值会导致过拟合.

4.3 实验评价

为了验证本文算法的有效性, 本文进行了多组实验. 首先, 为了验证本文所提出的融合相似度距离 d_{sst} 的有效性, 分别从不同特征数量和不同提取方法两方面进行了多组不同特征提取方法进行分类比较, 实验证明, 本文提出方法的分类效果要好于其他方法.

为了证明所提出的融合谱 - 空 - 纹的特征提取方法的有效性, 本文进行了多次实验, 分别对两个数据集只利用谱特征 (spectral, spec) 分类, 提取谱 - 空特征 (spectral-spatial, spec-spat) 和提取谱 - 纹特征 (spectral-texture, spec-text) 进行分类实验, 并进行比较, 实验结果如表 1 所示.

表 1 采用不同特征在 Indian Pines 和 PaviaU 数据集上的分类结果
(Table 1 The classification results for Indian Pines and PaviaU data sets with different features)

数据集	类别	PNN	Spec-Spat+PNN	Spec-Text+PNN	SSTPNN
Indian Pines	OA/(%)	68.58	84.51	78.01	91.27
	KC	0.62	0.81	0.74	0.89
PaviaU	OA/(%)	79.88	84.01	86.09	94.13
	KC	0.76	0.81	0.84	0.93

通过表 1 可以得出, 在不同特征组合下分类精度不同, 同时提取光谱信息, 空间信息和纹理信息使得数据中的信息得以充分利用, 所利用的信息更为丰富, 进而使得分类精度提高. 提取空间信息后的分类精度高于单纯利用光谱信息进行分类, 这是由于融合了谱 - 空信息后, 空间信息被考虑, 提高了分类器的鉴别性能, 使得分类效果更好. 但相比之下, 同时提取 SST 信息, 在考虑纹理信息的同时, 有保留了样本点到邻域关系, 有效地增加了同类地物的关联性, 提高了分类器的性能.

对原始波段进行特征提取后分类结果相对于原始波段均有不同程度的提高, 但只利用光谱信息进行分类, 其他信息并没有被充分利用, 导致分类结果较差, 但是随着所提取的特征丰富, 总体分类精度也在变化. SSTPNN 算法的分类精度相对于其他方法有着显著的优势, 这是因为 SSTPNN 算法在提取纹理信息的同时又结合了空间邻域信息, 同时用谱 - 空 - 纹 3 个特征融合的相似度距离代替传统的欧氏距离, 有效地解决了同类地物中差异性较大的点被分错的问题, 并通过给空间域的邻居点加权, 增强了空间域对分类的影响, 进而提高了分类效果.

下面我们将本文提出的 SSTNN 方法和 SRC^[16], EMP^[17], MLR-LORSAL^[18] 3 种不同的特征提取方法的分类精度进行比较. 从表 2 容易看出, 本文提出的 SSTNN 算法的精度优于其他 3 个算法, 说明 SSTNN 算法对 3 种特征的融合在一定程度上提高了分类器的性能, 达到了较好的分类精度.

表 2 4 种不同的算法在 Indian Pines 和 PaviaU 数据集上的分类结果
(Table 2 The classification results for Indian Pines and PaviaU data sets by four different algorithms)

algorithms	Indian Pines		PaviaU	
	OA/(%)	KC	OA/(%)	KC
SRC	68.34	0.64	77.81	0.7
EMP	90.49	0.88	91.58	0.89
MLR-LORSAL	79.51	0.77	88.26	0.84
SSTPNN	91.27	0.89	94.13	0.93

5 结 论

针对在传统特征提取时并未将高光谱影像的其他信息如空间信息, 形状信息及纹理信息等充分利用, 本文提出了一种基于谱 - 空 - 纹特征融合的高光谱影像分类策略. 所提出的方法不仅考虑到了高光谱数据的光谱信息, 融合了空间和纹理信息, 改进了 PNN 分类器的相似度距离, 实现了谱 - 空 - 纹合一. 实验结果表明, 本文得到的分类结果优于其他只利用光谱信息或谱空信息算法得到的结果. 但是本文在提取特征的过程中, 改变了某些特征原本的属性, 如何不对特征进行映射或变化, 而是进行特征选择, 直接从原始波段中选取一定数目最具代表性的波段, 不进行变换, 使得地物信息得以保留, 这是一个值得进一步研究的问题.

参 考 文 献

- [1] Plaza A, Benediktsson J A, Boardman J W, et al. Recent advances in techniques for hyperspectral image processing. *Remote Sensing of Environment*, 2009, **113**(1): S110-S122.
- [2] Bruce L M, Koger C H, Li J. Dimensionality reduction of hyperspectral data using discrete wavelet transform feature extraction. *IEEE Transactions on Geoscience & Remote Sensing*, 2002, **40**(10): 2331-2338.
- [3] He X, Niyogi P. Locality preserving projections. *Advances in Neural Information Processing Systems*, 2003, **16**(1): 186-197.
- [4] Bandos T V, Bruzzone L, Camps-Valls G. Classification of Hyperspectral images with regularized linear discriminant analysis. *IEEE Transactions on Geoscience & Remote Sensing*, 2009, **47**(3): 862-873.
- [5] Alipour Fard T, Arefi H. Dimensionality reduction of hyperspectral images by combination of non-parametric weighted feature extraction and modified neighborhood preserving embedding. *International Archives of the Photogrammetry Remote Sensing & S*, 2014, **XL-2/W3**(2): 31-34.
- [6] Sugiyama M. Dimensionality reduction of multimodal labeled data by local fisher discriminant analysis. *Journal of Machine Learning Research*, 2007, **8**(1): 1027-1061.
- [7] Velasco-Forero S, Manian V. Improving hyperspectral image classification using spatial preprocessing. *IEEE Geoscience & Remote Sensing Letters*, 2009, **6**(2): 297-301.

-
- [8] Kang X, Li S, Benediktsson J A. Spectral-spatial hyperspectral image classification with edge-preserving filtering. *IEEE Transactions on Geoscience & Remote Sensing*, 2014, **52**(5): 2666–2677.
 - [9] Jackson Q, Landgrebe D A. Adaptive Bayesian contextual classification based on Markov random fields. *IEEE Transactions on Geoscience & Remote Sensing*, 2002, **40**(11): 2454–2463.
 - [10] Huang X, Zhang L. An SVM ensemble approach combining spectral, structural, and semantic features for the classification of high-resolution remotely sensed imagery. *IEEE Transactions on Geoscience & Remote Sensing*, 2012, **51**(1): 257–272.
 - [11] Haralick R M. Statistical and structural approaches to texture. *Proc. IEEE*, 2005, **67**(5): 786–804.
 - [12] Cover T, Hart P. Nearest neighbor pattern classification. *IEEE Transactions on Information Theory*, 1967, **13**(1): 21–27.
 - [13] Wu X, Kumar V, Quinlan J R, et al. Top 10 algorithms in data mining. *Knowledge & Information Systems*, 2007, **14**(1): 1–37.
 - [14] Zeng Y, Yang Y, Zhao L. Pseudo nearest neighbor rule for pattern classification. *Expert Systems with Applications*, 2009, **36**(2): 3587–3595.
 - [15] Mitani Y, Hamamoto Y. A local mean-based nonparametric classifier. *Pattern Recognition Letters*, 2006, **27**(10): 1151–1159.
 - [16] Benediktsson J A, Palmason J A, Sveinsson J R. Classification of hyperspectral data from urban areas based on extended morphological profiles. *IEEE Transactions on Geoscience & Remote Sensing*, 2005, **43**(3): 480–491.
 - [17] Chen Y, Nasrabadi N M, Tran T D. Hyperspectral image classification using dictionary-based sparse representation. *IEEE Transactions on Geoscience & Remote Sensing*, 2011, **49**(10): 3973–3985.
 - [18] Li J, Bioucas-Dias J M, Plaza A. Spectral-spatial classification of hyperspectral data using loopy belief propagation and active learning. *IEEE Transactions on Geoscience & Remote Sensing*, 2013, **51**(2): 844–856.