

分类号: _____


学校代码: 10165

密 级: _____

学 号: 201711010807

遼寧師範大學

博/硕士学位论文



高光谱影像降维与谱-空分类方法研究

Research on Dimensionality Reduction and Spectral-Spatial

Classification Methods for Hyperspectral Image

作者姓名: 雷存款

学科、专业: 地图学与地理信息系统

研究方向: 遥感数据智能计算

导师姓名: 谢福鼎 教授

2020 年 5 月

学位论文独创性声明

本人承诺：所呈交的学位论文是本人在导师指导下所取得的研究成果。论文中除特别加以标注和致谢的地方外，不包含他人和其他机构已经撰写或发表过的研究成果，其他同志的研究成果对本人的启示和所提供的帮助，均已在论文中做了明确的声明并表示谢意。

学位论文作者签名：_____

学位论文版权的使用授权书

本学位论文作者完全了解辽宁师范大学有关保留、使用学位论文的规定，及学校有权保留并向国家有关部门或机构送交复印件或磁盘，允许论文被查阅和借阅。本文授权辽宁师范大学，可以将学位论文的全部或部分内容编入有关数据库并进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文，并且本人电子文档的内容和纸质论文的内容相一致。

保密的学位论文在解密后使用本授权书。

学位论文作者签名：_____ 指导教师签名：_____

签名日期：_____ 年 月 日

本论文承

_____项目_____，（项目编号：_____）的资助。

摘要

高光谱影像(Hyperspectral Image, HSI)由于其具有精细的光谱分辨率和良好的地面分辨率的优势,已经成为人类在认识世界和改造世界过程中不可或缺的数据载体。HSI 通常具有数十甚至数百个特征波段且有几米甚至亚米级别的地面分辨率。一般来说,较高的光谱分辨率可以增强对复杂地物的区分能力;较高的地面分辨率能够更加细致地刻画地物复杂多变的细节。然而,随着光谱分辨率和地面分辨率的增加,各种地物在特征空间中的数据分布规律也变得异常复杂,这给利用高光谱遥感技术准确识别地物带来了巨大的困难。同时,HSI 的高维特征不但容易导致 Hughes 现象的发生,而且也增加了分类的计算成本;HSI 的大数据特征要求我们提出快速准确的分类方法,以便于遥感技术在实际问题中的应用。

HSI 的高维特征和大数据特征,使得通过传统的目视解译方法来获得地物的分布变得更加困难。因此,利用人工智能的方法对 HSI 进行分类,成为了近年来遥感领域研究的热点之一。已有的研究表明,直接使用经典的人工智能方法进行 HSI 分类,不能获得满意的分类结果。如何在保证分类精度的同时,进行 HSI 的降维计算,以及如何有效融合谱-空信息,提出快速准确的谱-空分类方法,仍是十分值得进一步研究的问题。

本文针对上述问题,开展了如下的研究工作。

(1) 针对 HSI 的高维特征问题,基于模糊 C-均值算法,子空间分解技术,极大熵原则,灰狼优化算法等,本文提出了无监督的波段选择方法。所给出的降维方法能够在原始的波段中选择出具有较好地物识别能力的波段子集,有效地降低了所选波段之间的冗余性,避免了 Hughes 现象的发生。在保证分类性能的同时,减少了分类算法的计算时间。在三个标准测试集上的运算结果证明了所提出方法的有效性。

(2) 为了减少噪音点对分类结果的影响,基于不连续松弛方法和超像素技术,本文提出了一个有效的谱-空分类框架。在所提出的分类框架中,利用不连续松弛方法以及像素的空间信息,在预处理中有效地平滑了噪音像素。在后处理中,超像素技术的使用可以较好地起到改善分类结果的作用。另外,我们改进了流行的简单线性迭代聚类超像素分割方法(SLIC),改进后的 SLIC 算法是一个无参数的方法,且可以直接适用于具有任意维数的 HSI 超像素分割。在同样的标记比例下,实验结果和比较结果肯定了所提出的方法优于其他几个流行的谱-空分类方法。

(3) 虽然超像素分割为 HSI 分类提供了有力的工具,但由于超像素的自适应大小和形状的特点,在超像素水平上对 HSI 进行分类仍然是一个具有挑战性的问题。另外,HSI 的大数据特征无疑会增加分类的计算时间。为了部分解决这一问题,本文尝试性地

介绍了一种新的超像素级的半监督谱-空分类方法。基于局部平均伪近邻方法，我们定义了两个超像素之间的相似度。然后通过 K 近邻方法，实现了超像素级的分类。实验结果表明，所提出的超像素级的分类器性能好于其他几个有代表性的像素级的谱空分类方法。

本文在实验中采用了 Indian Pines、Pavia University 和 Salinas 三个国际通用的标准高光谱数据集，这三个数据集被广泛地用来测试高光谱数据分类算法的性能。三个数据集来源于 http://www.ehu.es/ccwintco/index.php/Hyperspectral_Remote_Sensing_Scenes。

关键词：高光谱影像；降维；超像素；半监督谱-空分类；算法

Research on Dimensionality Reduction and Spectral-Spatial Classification Methods for Hyperspectral Image

Abstract

Hyperspectral Image (HSI) has become an indispensable data carrier in the process of understanding and transforming the world, thanks to its fine spectral resolution and good ground resolution. HSI usually has dozens or even hundreds of bands and has a ground resolution of several meters or even sub-meter levels. Generally speaking, higher spectral resolution can enhance the ability of classifier to distinguish complex ground objects. Higher ground resolution makes it possible to detect the complex and changeable ground objects in more detail. However, with the increase of spectral resolution and ground resolution, the law of data distribution of various ground objects in feature space becomes extremely complex. This brings great difficulties to the accurate identification of ground objects by using hyperspectral remote sensing technology. Meanwhile, the high-dimensional features of HSI not only easily lead to the occurrence of Hughes phenomena, but also increase the computational cost of classification. The big data features of HSI require us to propose fast and accurate classification methods to facilitate the application of remote sensing technology in practical problems.

The high-dimensional feature and big data feature of HSI make it more difficult to obtain the distribution of ground objects by traditional visual interpretation methods. As a result, classifying HSI by using artificial intelligence has been one of the popular topics in the field of remote sensing in recent years. Existing research results show that satisfactory classification result cannot be obtained by using classical human intelligence methods directly. Therefore, it is still worthy of further study how to reduce the dimensionality of HSI while ensuring the classification accuracy, and how to develop fast and accurate spectral-spatial classification methods by effectively fusing the spectral and spatial information.

To address the problems mentioned-above, the following works have been investigated in this dissertation.

- (1) Based on fuzzy c-mean algorithm, subspace decomposition technology, maximum entropy principle, gray wolf optimization algorithm, an unsupervised band selection methods is proposed to deal with the problem of high-dimensional HSI. The proposed dimensionality reduction method can select informative band subsets from the original bands, which effectively reduces the redundancy between the selected bands and avoids the occurrence of Hughes phenomena. In addition, the computing time of the classification algorithm is reduced while ensuring the classification performance. Experimental results on three standard test datasets demonstrate the effectiveness of the proposed method.

- (2) To reduce the influence of noisy pixels on the classification results, an effective spectral-spatial classification framework is proposed based on superpixel and discontinuity preserving relaxation. In the proposed classification framework, the discontinuity preserving relaxation and the spatial information of pixels are used to smooth the noisy pixels effectively in preprocessing. In post-processing, the application of superpixel can better improve the classification results. Moreover, a popular superpixel segmentation method, simple linear iterative clustering (SLIC) is improved. The improved SLIC algorithm is parameter-free and can be directly applied to segment HSI with arbitrary dimensions into superpixel. Experimental and comparative results confirm that the proposed method is superior to the other popular spectral-spatial classifiers for the same labeled ratio.
- (3) Although superpixel segmentation provides powerful tools for HSI classification, classifying HSI at superpixel level remains a challenging problem, due to the characteristics of adaptive size and shape of superpixels. Also, big data feature of HSI will undoubtedly increase the computation time of the classification. In order to partially tackle with this problem, a novel superpixel-level semi-supervised spectral-spatial classification method is introduced in this dissertation. The similarity between two superpixels is first defined based on the local average pseudo-nearest neighbor. Then superpixel-level classification is realized by k-nearest neighbor method. Finally, experimental results show that the proposed superpixel-level classifier performs better than the other several representative spectral-spatial classification methods.

Three standard hyperspectral data sets, Indian Pines、Pavia University and Salinas, are used in our experiments. These three datasets are widely used to test the performance of HSI classification algorithms. It can be found by browsing [the webpage](#).

Key words: Hyperspectral image; Dimensionality reduction; superpixel; semi-supervised spectral-spatial classification; Algorithm

目 录

摘要.....	I
Abstract.....	III
1 绪论.....	1
1.1 研究背景及意义.....	1
1.2 高光谱遥感.....	1
1.3 国内外高光谱影像分类研究现状.....	3
1.4 主要研究内容及结构.....	6
1.4.1 主要研究内容.....	6
1.4.2 文章结构安排.....	7
1.5 实验数据说明.....	8
1.5.1 Indian Pine 数据集.....	8
1.5.2 Pavia University 数据集.....	8
1.5.3 Salinas 数据集.....	8
2 基于 FCM 和灰狼优化算法的无监督波段选择方法.....	10
2.1 基于 FCM 的特征子集划分.....	10
2.3 灰狼优化算法.....	11
2.3.1 最大熵原理.....	12
2.3.2 狼群算法优化器.....	12
2.4 实验设置与结果分析.....	13
2.4.1 实验设置说明.....	13
2.4.2 实验结果与分析.....	14
2.4.3 实验参数分析.....	19
2.5 本章小结.....	20
3 基于超像素和不连续保持松弛的高光谱图像分类方法.....	22
3.2 不连续保持松弛算法.....	22
3.3 超像素切割方法.....	23
3.3.1 原始的超像素切割方法 SLIC.....	23
3.3.2 改进的 SLIC 切割方法.....	23
3.4 本章分类框架说明.....	25
3.5 实验设置与结果分析.....	25
3.5.1 实验设置说明.....	25
3.5.2 实验结果分析.....	26
3.5.3 实验参数分析.....	32
3.6 本章小结.....	34
4 一种新的超像素级高光谱图像的光谱-空间分类方法.....	35
4.2 改进的无参超像素.....	35
4.3 局部平均伪近邻.....	36
4.4 所提出的 SSC-SL 算法.....	36
4.5 实验设置与结果分析.....	37
4.5.1 实验设置说明.....	37
4.5.2 实验结果与分析.....	37

4.5.3 实验参数分析.....41

4.6 本章小结.....43

5 总结与展望.....44

5.1 工作总结.....44

5.2 展望.....44

参考文献.....46

攻读硕士学位期间发表学术论文情况.....51

致 谢.....52

1 绪论

1.1 研究背景及意义

高光谱影像是由高光谱传感器在不接触观测对象的状态下，对地物反射、辐射或发射的可见与红外光谱区域内的电磁波能量进行数字化而形成的数百幅连续窄波段影像^[1,2]。正是其优越的光谱分辨率和精细的空间分辨率^[3]使得高光谱在地物分析^[4,5]、精准农业^[6,7]、环境监测^[8,9]、城市扩张^[10,11]以及军事防御^[12,13]等众多领域得到了广泛的应用。但是，高光谱遥感领域在“享受”其较高的光谱分辨率和空间分辨率带来的便利的同时，也承受着光谱特征冗余^[14,15]、样本容量大且维度高^[15]、噪音点众多^[16]、标记代价高^[17]和“同谱异物与同物异谱现象^[18,19]”等问题。

综上所述，高光谱影像蕴藏着大量的地物信息，虽然目前在多个领域中取得了成功的应用，但仍然面临着巨大的挑战。因此，如何从海量的样本数据中较好地“学习到”其自身在特征空间与支撑空间中的分布规律，并尽可能地降低该过程的计算成本等问题^[20]，一直是国际高光谱影像研究领域的一个热点。

1.2 高光谱遥感

高光谱遥感也叫“高光谱分辨率遥感”。其成像原理与我们常见的多光谱极其相似，如图 1.1。




图 1.1 高光谱成像原理图

Fig 1.1 Schematic diagram of hyperspectral remote sensing

众所周知，不同的物种都具有不同的原子构造，且都有对外反射、辐射、吸收或发射电磁波的可能。而高光谱遥感正是利用这一原理实现了对目标物体不接触地“感知”，最后数字化形成数以百计的狭窄而又连续的特征波段。通常，这种收集外界物体反射，辐射或发射的能量的装置我们叫做传感器。传感器又通常会部署在卫星、飞机、飞行器等诸多设备上，这使得数据的获取变得更加灵活和高效。也正是综合了这些优势，高光谱遥感被越来越多的领域所青睐，例如：农业植被研究、大气环境研究、地质矿产研究、海洋研究与军事侦察等^[21]。

高光谱影像通常可以被直观地看作是形如图 1.2 的一个数据立方体，其中，不同的波段一般被视为不同的特征维度。因此针对每个样本像元 x_i 都可以用一个有序的向量 $(x_{i1}, x_{i2}, \dots, x_{iB})$ 表示，其中 i 表示影像中的第 i 个样本， B 表示该影像的特征波段数，如果把该向量的各个分量按照波段序号依次在二维空间中连线可视化出来，就能够得到一条近乎连续的光谱曲线。正是因为高光谱影像其光谱分辨率之高、所覆盖的光谱范围之广、以及地面分辨率之高等诸多优势，而区别于传统的多光谱影像，从而能够进行更加精细的地物识别而非简单的“粗分类”。但同样不容忽视的是：高维样本集在其有效的特征空间中的分布规律也随之变得极其复杂和难以理解，因为高维空间中样本的分布主要集中在超球体的表面，而不再是传统的二维或三维空间中的近似团状的有序分布。这就意味着高维空间下的模型参数更加敏感，也正是如此，一些经典的计算机视觉领域的算法并不能直接应用到高光谱影像中去。例如：简单线性迭代聚类(SLIC)，边缘检测(edge detection)等。

因此，如何构建一个模型框架，使其能够自适应地学习到数据样本的深层次内在规律，在提升影像的解译精度的同时，尽可能地降低运算的成本和保持良好的泛化性，满足解决实际问题的需求，一直以来都是高光谱遥感领域研究的热点问题。




图 1.2 高光谱数据立方体
Fig 1.2 Hyperspectral data cube

1.3 国内外高光谱影像分类研究现状

自从高光谱遥感问世以来，凭借其优越的“地物辨别能力”，使得定性分析的遥感向定量或半定量遥感的转化成为了可能^[21]。但高光谱影像无法避免“数据样本维度高、数据冗余、类间可分离性错综复杂、以及标记成本高”等缺点。因此，围绕这些挑战，国内外研究学者们提出了一系列的解决措施。这些方法作用在高光谱影像智能解译方面大致可以归结为框架 1.3。

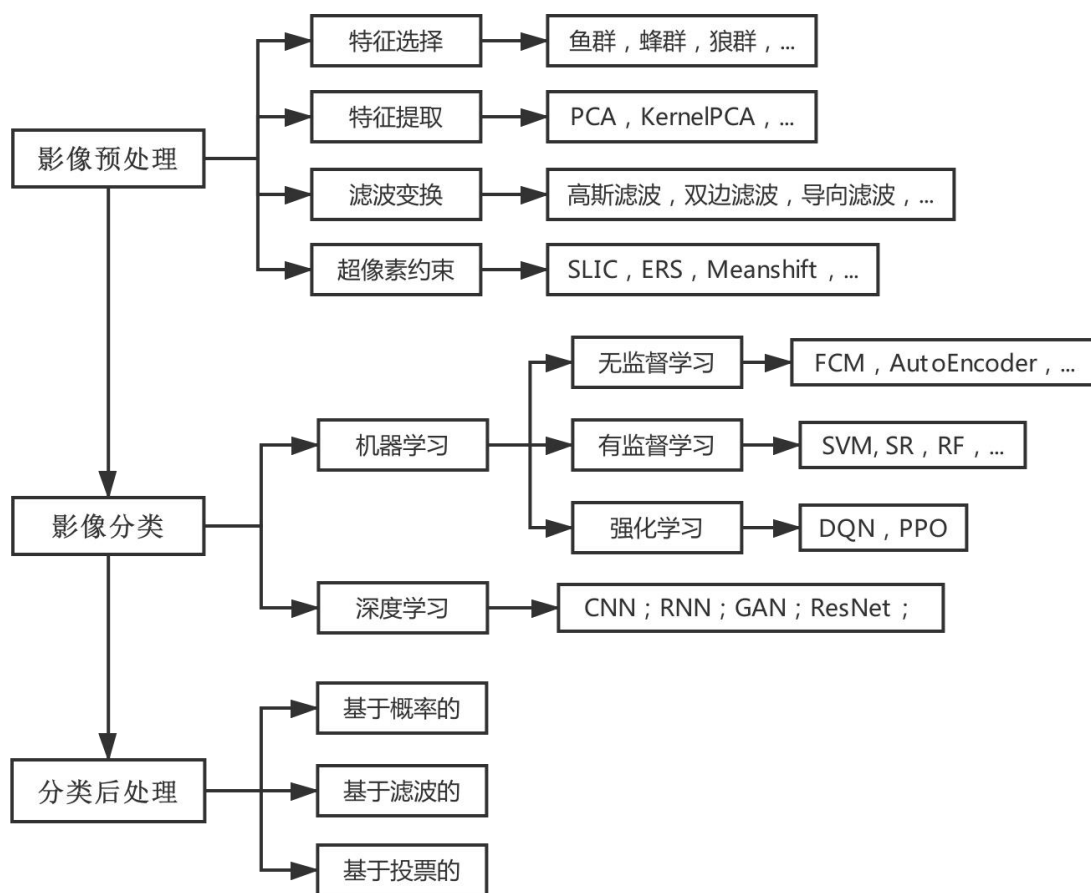


图 1.3 影像分类流程示意图

Fig 1.3 Schematic diagram of image classification process

为了解决高光谱影像“冗余波段”所导致的“Hughes 现象”和训练模型时的低效性。围绕“高光谱降维”而展开的工作不胜枚举，大致可以将这些工作划分为特征提取和特征选择^[22]两个方面，如图 1.4。

在特征提取中，由于主成分分析法（PCA）是无监督降维方法的一种，无需样本标签、无需参数且具有较低的算法复杂度等优势，而被广泛应用在高光谱影像降维邻域^[23]。然而，PCA 是一种常见的线性变换方式，其原理主要是计算原始数据的协方差矩阵及其对应的特征值与特征向量，并选择特征值最大（常被认为是包含信息量最多的指标^[24]）

的前 k 个特征值所对应的特征向量组成的矩阵来对原始数据进行线性变换。然而，在高维特征空间中由于样本分布的复杂性，往往类与类之间并不是简单的线性可分关系，而是趋向于线性不可分或非线性可分的复杂状态。因此，基于核的主成分分析法（Kernel PCA）被逐渐应用到高光谱影像降维中。该方法主要是利用核函数技术，例如：高斯核、多项式核等，将低维空间投影到更高的空间维度，试图解决低维空间中的线性不可分问题。实验结果表明，相同的参数配置下，Kernel PCA 在相应的标准数据集上的降维效果要优于原始 PCA^[24]。近年来，随着深度学习领域的日渐成熟，自编码器（AutoEncoder）凭借其无需参数和非线性全局保持等优势而成为一种较新型的高光谱降维方法^[25-27]。

与特征提取不同的是，特征选择主要是根据某一准则（通常称为适应度函数、或目标函数），从原始的特征集合中不经任何变换地筛选出若干个特征而组成的一个新的特征子集。根据在选择特征的过程中是否使用真实地物标签，又可以划分为有监督特征选择^[28,29]和无监督特征选择^[30,31]。特征选择主要包括选择的准则依据和选择的方法策略^[32]两部分。其中，准则依据主要起导向作用也被称为目标函数，通常会将特征所包含的信息量或特征之间的冗余量等指标作为参考。而选择的方法策略则主要决定了能否逼近潜在最优解和怎样逼近潜在最优解的问题。因此，根据选择策略的方式不同，大致可以分为穷举式搜索和启发式搜索^[33]。前者使用穷举的方式产生特征子集。例如：从 N 个特征中选择出 M 个特征时，将会有 C_N^M 种潜在解，因此对于计算来讲，将会是巨大的灾难。在此背景下，受自然界现象或行为的启发，而被模型化表达的启发式搜索策略似乎备受青睐。大致可将其分为以下三类：基于物理模型的模拟退火算法^[34]，其主要是通过引入随机因素来接受一个比当前状态差的值，并以一定的概率逃出局部最优解从而逼近全局最优解的过程；而基于生物进化的遗传算法^[35]，则主要依据群体在进化的过程中基因的复制，交叉和变异等行为，不断地进行迭代进化最终保留优秀的个体，但值得注意的是变异行为是按照指定的概率（通常会比较小，例如：0.05）发生的，用于防止算法陷入局部最优解；最后，基于仿生智能群体的蜂群算法、狼群算法与粒子群算法等^[36-38]，则分别依据蜂群、狼群、鸟类等在觅食的过程中所触发的探索发现行为、聚集捕食行为、再探索行为等直到个体逼近潜在全局最优解为止。总的来说，启发式搜索策略可以理解作为一种既具有随机性又具有导向性的方法，因此其具备快速逼近潜在最优解的特点。

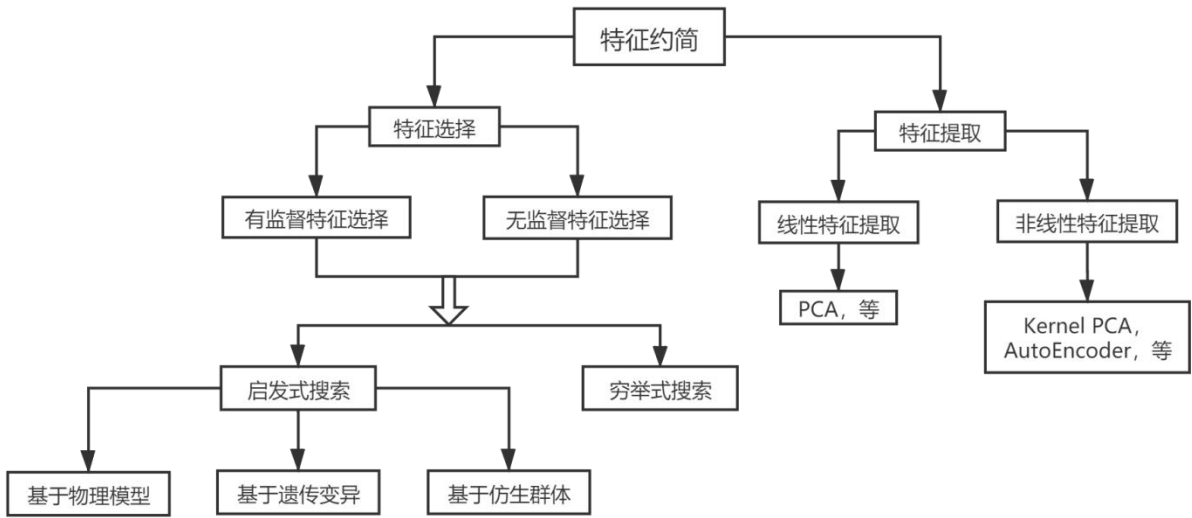


Fig 1.4 Schematic diagram of dimensionality reduction

虽然特征选择和特征提取能够有效地降低特征维度。但是，该类方法仅使用到了光谱特征而忽略了图像所特有的空间特征。因此，为了进一步解决高光谱影像的“椒盐现象”，提升模型的分类性能，以“利用影像的空间信息”为核心的数据预处理方法被不断地提出和改进。例如因简易而被广泛应用的中值滤波器、低阻滤波器和高阻滤波器等。但是这些滤波器仅仅是基于单特征维度的、独立的、局部的基础统计，并未对影像的深层特征进行理解和提取。故而针对传统滤波器的缺陷，基于高斯分布的滤波器更受欢迎，因为二维高斯分布离散化后所得的滤波权重算子能较好地体现“地理学第一定律”的思想。但尽管如此，很多情况下对空间局部的样本数据进行“高斯分布假设”是不太合理的。例如：小斑块地物、近乎线状地物、地物种类繁多且变化剧烈的区域等，这些区域可能不仅不符合高斯分布，而且对高斯窗口的选择也很挑剔。因此，以上的“各向同性滤波”在处理真实复杂的影像的时，可能并不能带来实质性的提升。

与“各向同性滤波”所不同的是“保边滤波”在平滑影像的过程中，试图尽可能地保持地物的边缘信息使之不被破坏，在迭代优化的过程中不断地拉大类间距离缩小类内距离以达到显著提升模型效能的目的。例如：双边滤波、导向滤波和不连续保持松弛等方法。其中，双边滤波的核函数由空间核与像素核共同构成，在影像梯度变化小的区域，空间核权重算子起主要作用，而在影像梯度变化大的区域（不同地物的边界处），像素核权重算子的作用增强，从而尽可能地保持了地物的边缘信息；导向滤波，顾名思义是需要具备导向图，然后通过求解局部范围内原始影像与导向图之间的线性关系，最后根据这种关系将原始样本数据进行扭曲变形从而得到输出影像；而不连续保持松弛算法则先用边缘检测算子计算出整幅影像的梯度，然后在固定窗口下，使用邻居像素的特征值和反梯度权值对中心像素在各个维度上进行平滑和保留。

虽然“保边滤波”相对于“各向同性滤波”而言，具有更加灵活的特点，即使在较复杂的影像中也能取得较好的识别效果；但是，它们都属于固定窗口下的移动平滑技术，这种硬性的窗口规定很有可能导致空间信息无法充分利用。因为，很多情况下，中心像素并不一定仅受其摩尔邻居的影响，而趋向于其邻域不规则范围内的样本的共同影响。在此背景下，“超像素”的概念逐渐从计算机视觉方向迁移到高光谱影像领域。通常情况下，超像素可以被理解为局部空间上近邻且光谱特征相似的样本像元的集合。而根据生成超像素的方式不同，又可以大致地将该类方法分为以下三种：基于图生成的超像素、基于梯度生成的超像素和基于聚类生成的超像素。在这诸多方法中，简单线性迭代聚类（SLIC）和基于图的熵率超像素（ERS）由于其边缘召回率高和切割速度快等优势而被广泛应用。然而，这些经典的切割算法仍旧处于低维度特征下的预处理阶段。例如：Jiang 等人^[65]提出的 Super-PCA 先使用 PCA 技术将高光谱影像降维，并基于降维后的第一主成分做 ERS 切割，最后分别对每个超像素掩膜下的原始影像再次进行 PCA 降维并使用 SVM 进行分类。Zhang 等人^[40]则认为 Kernel-PCA 对非线性可分的样本数据有更好的降维效果，因此提出了 Superpixelwise-KPCA。此外，为了更进一步地利用影像的空间特征，结合投票机制的多尺度超像素技术能够得到更佳的结果。

尽管这些方法常被称为是“超像素级别”的，但本质上这些分类技术仍然是“像素级别”的。因为，该类方法仅仅是使用了超像素去约束数据预处理的尺度范围和矫正分类结果或对原始数据进行变换，并未提出真正意义上的超像素块与超像素块之间的相似度度量。而针对像素级别分类策略的低效不稳定性和不均衡性，Lu 等人^[73]提出了样本集合距离度量。该方法先使用 PCA 技术将高光谱降维，并基于其第一主成分做 ERS 切割，然后分别对各个超像素掩膜下的原始数据进行“仿射包变换”，最后利用半监督的思想计算未知超像素块到标记超像素块的最短距离来确定最终的分类结果。实验结果证明，该分类体系较传统的像素级别分类方法的优越性。

综上可知，运用高光谱影像的“谱-空”信息并结合超像素技术对影像进行预处理和后处理的分类框架^[74,75]一般都要优于普通的像素级别的光谱信息分类方法^[50,51]。实际上，在众多的“谱-空”分类框架当中，“空间信息”的使用主要体现在数据的预处理阶段和分类后处理阶段，正如空间滤波，超像素技术等；而对“谱信息”的使用则体现在各种分类器上，如稀疏表示^[76,77]、支持向量机^[58]、极限学习机^[60]和卷积神经网络^[78]等。在各个实验中也表明了“谱-空”分类方法相对于传统的光谱分类器的优势。

1.4 主要研究内容及结构

1.4.1 主要研究内容

高光谱影像相对于普通遥感影像蕴藏了更为丰富的信息，但对这些信息的高效使用依然面临维数高、噪音多、数据量大等挑战。传统的分类方法在处理该场景数据时很容易达到瓶颈。因此，本文对高光谱影像分类框架进行了一系列的研究并针对性地提出了

以下三种方法：首先，针对高光谱影像的特征维度高和近邻特征冗余显著等问题，一种基于无监督的子空间聚类 and 特征波段选择技术被提出；其次，为了降低高光谱影像的“椒盐”现象或局部范围内“谱-物互异”的影响，一种新的无参超像素切割技术和不连续保持松弛算法被进入到数据预处理与后处理中；最后，利用局部平均伪近邻作为超像素块之间的距离度量来弥补“像素级别”分类的不均衡性与低效性的方法被提出。根据本研究在上述三个方面做的大量仿真实验的结果表明，本文所提出的方法在指定的标准高光谱影像数据集上相对于已有的主流分类算法具有更好的识别效果。

1.4.2 文章结构安排

本文内容组织如下：

第 1 章：绪论。这一部分首先阐述了一下本文的研究背景及意义；其次简单地介绍了一下什么是高光谱遥感影像及其与多光谱遥感影像的区别与联系；随之概括了目前高光谱研究领域面临的挑战及国内外研究状况；最后讲述了本研究所使用的标准高光谱影像数据集。

第 2 章描述了我们提出的一个基于 FCM 和灰狼优化算法的无监督高光谱影像特征选择方法。首先介绍了基于 FCM 的无监督子空间聚类划分，以极大熵为目标函数的灰狼优化算法；其次在三个标准数据集测试了所提出方法的性能，并在相同的实验参数下，与目前主流的一些特征提取和特征选择进行比较；最后分析和讨论了实验结果和实验中所涉及的参数。

第 3 章介绍了一个新的基于不连续松弛和超像素的谱-空分类器。首先通过考虑谱曲线之间的相关性，定义了一种像素间的相似度函数，并通过谱相似性和空间距离分别排序策略，改进了 SLIC 算法。改进后的 SLIC 方法是一个无参数的超像素分割方法，且不需要预先使用 PCA 直接将具有任意维数的 HSI 分割为超像素。在预处理中使用 DPR 技术和在后处理中使用超像素技术，可以起到有效减少噪音像素对分类结果的影响。大量的实验结果和比价结果证明了所提出分类框架的有效性。

第 4 章描述了一个新的超像素级的高光谱图像半监督谱-空分类方法。我们将计算点到集合距离的 LMPNN 方法扩展到计算集合与集合间距离的情形，然后定义出超像素之间的距离。基于所定义的距离和 KNN 方法，给出了一个新的超像素级的分类方法。所提出的超像素级的分类方法，是为提高分类速度而在像素方面进行数据约简的一种有效尝试。实验结果和比较结果肯定了所提出方法的有效性。

第 5 章总结和分析了我们已经取得的结果，然后在如何提升影像的识别效率和精度方面，给出了需要进一步解决的问题和展望。

1.5 实验数据说明

为了证明本研究所提出的方法的有效性，三个国际通用的高光谱影像数据集被作为本次研究的核心对象。各个数据集的具体情况如下：

1.5.1 Indian Pine 数据集

该数据集是由 AVIRIS 传感器，于 1992 年 6 月 12 日在印第安纳州西北部的 Indian Pines 测试场收集的。共包含了 145×145 个样本像元和 224 条波段，波长范围为 400nm~2500nm，空间分辨率为 20m。移除受大气影响较大的波段后，数据集的尺度为 $145 \times 145 \times 200$ 。为了方便研究，根据当时的实际地面覆盖现状，影像被人为地指定成 16 个类别（但彼此之间并不都是相互排斥的）。

1.5.2 Pavia University 数据集

该数据集是由 ROSIS 传感器，在意大利北部的 Pavia 上空进行一次飞行拍摄的。共包含了 610×340 个样本像元和 115 条波段，波长范围为 430~860nm，空间分辨率为 1.3m。移除受外部成像环境影响较大的波段后，数据集的尺度为 $610 \times 340 \times 103$ 。为了方便研究，根据当时的地面覆盖状态，该数据集被人为地划分成 9 个类别。

1.5.3 Salinas 数据集

该数据集是由 AVIRIS 传感器，在加利福尼亚州萨利纳斯山谷拍摄的。共包含了 512×217 个样本像元和 224 条波段，波长范围为 400nm~2500nm，空间分辨率为 3.7m。移除受外部成像环境影响较大的 20 条波段后，数据集的尺度为 $512 \times 217 \times 204$ 。为了方便研究，根据当时的地面覆盖状态，该数据集被人为地划分成 16 个类别。

为了方便更多读者的研究，本文所涉及的全部影像数据都可以在以下的网站获得：http://www.ehu.eus/ccwintco/index.php/Hyperspectral_Remote_Sensing_Scenes。此外，为了让更广大的读者对本研究所使用的数据集有个更加直观的认识，相关简介如表 1.1。相关的程序源代码均可在[本人主页](#)处获得。


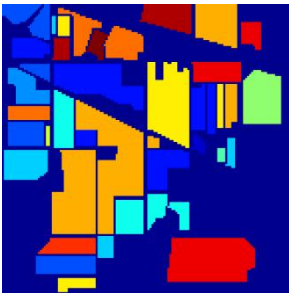

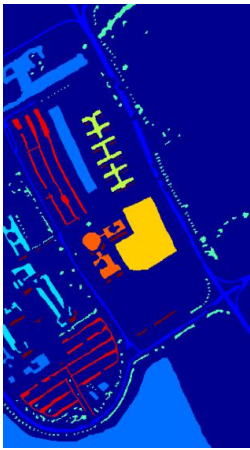
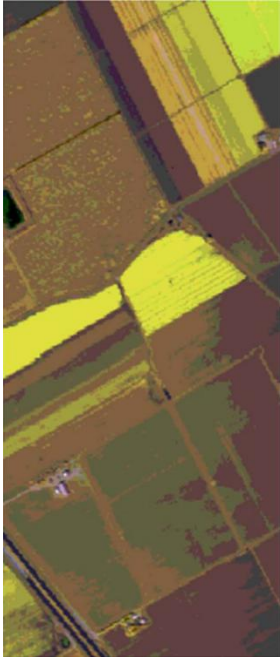
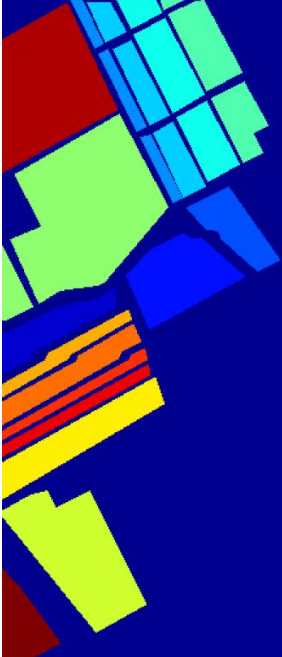
表 1.1 三个标准数据集的概况

Tab.1.1 Overview of the three standard data sets

	Indian Pines	Pavia University	Salinas
类别数	16	9	16
波段数	200	103	204
影像尺寸	145×145	610×340	512×217
传感器	AVIRIS	ROSIS	AVIRIS
分辨率	20m	1.3m	3.7m
可用样本容量	10249	42776	54129

表 1.2 三个标准数据集的假彩色合成及其对应的真实地物标签

Tab.1.2 False color synthesis and corresponding ground labels of three standard data sets

数据集名称	假彩色合成图	真实地物参考图	图例
Indian Pines			<ul style="list-style-type: none"> Alfalfa Corn-notill Corn-mintilla Corn Grass-pasture Grass-trees Grass-pasturemowed Hay-windrowed Oats Soybean-notill Soybean-mintill Soybean-clean Wheat Woods Building-grass-trees Stone-steel-towers
Pavia University			<ul style="list-style-type: none"> Brocoligreenweed1 Brocoligreenweed2 Fallow Fallowroughplow Fallowsmooth Stubble Celery Grapesuntrained Soilvinyarddevelop
Salinas			<ul style="list-style-type: none"> Brocoligreenweed1 Brocoligreenweed2 Fallow Fallowroughplow Fallowsmooth Stubble Celery Grapesuntrained Soilvinyarddevelop Cornsenescedgreen Lettuceroomaine4wk Lettuceroomaine5wk Lettuceroomaine6wk Lettuceroomaine7wk Vinyarduntrained Vinyardvertical

2 基于 FCM 和灰狼优化算法的无监督波段选择方法

高光谱图像具有数百个窄的连续光谱波段，为区分各种土地覆盖提供了大量的信息。然而，冗余特征/波段的存在不仅导致计算时间的增加，而且干扰了高光谱图像的分类结果。显然，如何从原始波段中选择一个有效的特征子集来降低高光谱数据集的维数是一个非常具有挑战性的问题。本章介绍了一种新的无监督特征选择方法，通过特征子空间分解和波段组合优化来去除 HSI 的冗余特征。首先通过模糊 c-均值(FCM)算法实现波段子空间分解；然后基于灰狼优化器(GWO)和最大熵原理选择出最优的特征子集。为了评价该方法的有效性，在三个公开的高光谱数据集，Indian Pines, Pavia University 和 Saliansa 进行了实验，并选择了其他 5 种先进的特征选择和提取的方法与所提出的方法进行比较。根据三个分类精度指标，总体精度(Overall Accuracy, OA)、平均精度(Average Accuracy, AA)和 Kappa 系数(κ)，实验结果证明了我们的方法优于其他算法。

2.1 基于 FCM 的特征子集划分

聚类的本质在于将样本数据集(DS)按照特征相似的程度，尽可能地划分在彼此不相交的簇中使得各个簇内的样本尽可能地相似，各个簇之间的样本尽可能地相异^[41,42]。通常情况下，我们可以用如下公式进行表达：

$$DS = C_1 \cup C_2 \cup \dots \cup C_p, C_i \cap C_j = \emptyset, i \neq j, i, j = 1, 2, \dots, p \quad (1.1)$$

这里 C_i 表示第 i 个簇。

在众多的聚类算法中，FCM 得益于其软聚类的优势而被广泛地应用[43]。对于一个给定的 q 维空间下 n 个样本点的数据集 $DS = \{x_1, x_2, \dots, x_n\}$ ，FCM 可以根据目标函数(1.2)将整个数据集划分成 p 个簇。

$$\text{Min:} \begin{cases} J(U, V) = \sum_{j=1}^p \sum_{i=1}^n \mu_{ij}^m (x_i - v_j)^2 \\ \mu_{ij} \in [0, 1], \sum_{j=1}^p \mu_{ij} = 1 \end{cases} \quad (1.2)$$

这里的 $U = (\mu_{ij})_{n \times p}$ ，表示隶属度矩阵， μ_{ij} 表示第 i 个样本属于第 j 个簇的隶属度。此外， $V = (v_1, v_2, \dots, v_p)_{q \times p}$ ，是簇心矩阵， m 是个模糊因子常数（通常被设为 2）。显然，上述的模型优化问题可以通过拉格朗日方法求解，其具体更新求解如公式（1.3）和（1.4）。

$$\mu_{ij} = \left[\sum_{k=1}^p \left(\frac{(x_i - v_j)^2}{(x_i - v_k)^2} \right)^{\frac{1}{m-1}} \right]^{-1} \quad (1.3)$$

$$v_j = \frac{\sum_{i=1}^n \mu_{ij}^m x_i}{\sum_{i=1}^n \mu_{ij}^m} \quad (1.4)$$

本文针对高光谱影像的光谱特征进行聚类，因此，我们可以将高光谱影像的每个特征波段看作是对应高维度空间下的一个样本点。例如：高光谱影像的尺度为 $H \times W \times B$ ，

其中 H 表示影像的高度, W 表示影像的宽度, B 表示影像的波段数, 则该影像可以看作是 $H \times W$ 维下的 B 个样本点, 对 B 个样本点进行 p 个簇的划分过程如下图:

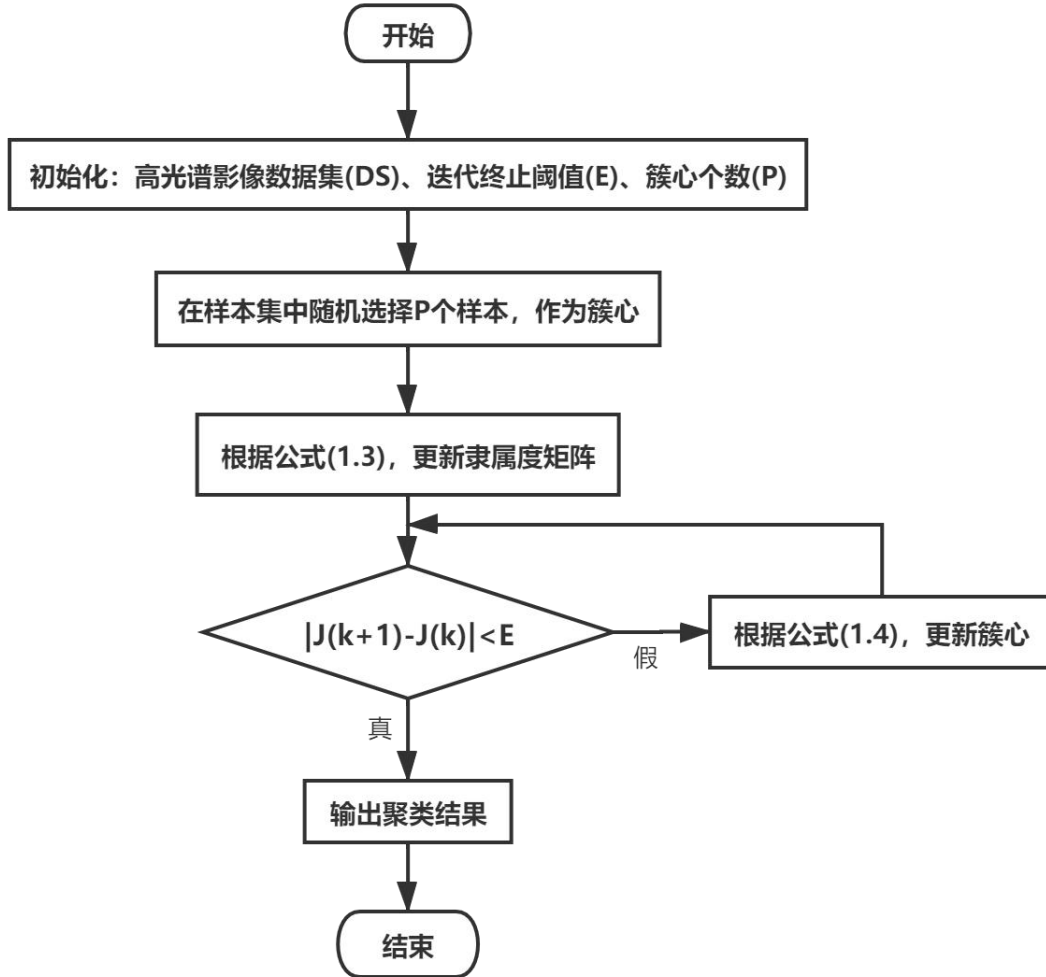


图 2.1 FCM 算法流程图

Fig 2.1 FCM algorithm flow chart

2.3 灰狼优化算法

狼群算法本质上是一种寻优的方法, 该方法与蜂群算法、鱼群算法等类似, 都是根据自然界中的某种动物的行为, 如: 捕猎行为或求偶行为等, 而抽象出来并数学化表达的仿生智能群体模型, 这些仿生模型在现实生活中的多峰多谷数据分布求极值中被广泛应用。而高光谱影像的波段选择正好满足该条件。例如, 对于一个包含 B 个波段的影像, 如果我们将它降至 K 维, 则会产生 C_B^K 个潜在解, 这些潜在解所包含的信息量正好对应多峰多谷问题。通过下文的最大熵目标函数与狼群搜索算法就能很好地逼近潜在最优解, 从而达到降维的效果。

2.3.1 最大熵原理

为了筛选出最具辨别能力的波段组合，最大熵原理被作为本次研究的目标函数。在信息论里，熵被当作是一种衡量信息量多少的单位。在本文中，熵值的大小表征着光谱特征的优劣，并认为熵值越大信息量越大，该特征也就越具备区分能力，因此该假设被用作优化的目标函数。通常情况下，对于任意一个随机变量 X ，它的熵定义如下：

$$E(X) = -\sum_i p(X_i) \log_2 p(X_i) \quad (2.1)$$

其中， $E(X)$ 表示随机变量 X 的熵， $p(X_i)$ 表示随机变量 X 中的第 i 个分量在该事件中出现的频率。考虑到运行速度，我们将原始的高光谱影像的反射值映射到 $[0,255]$ ，然后基于直方图的方法被用于求解各个 $p(X_i)$ 。同时，为了使降维后的特征子集整体表现最优，以获得尽可能好的识别效果，最大组合熵被用于本实验的目标函数，公式如下：

$$\frac{1}{s} \sum_{i=1}^s E(X_i) \quad (2.2)$$

$E(X_i)$ 表示高光谱影像的第 i 个波段对应的信息熵，可由公式（2.1）计算得出。基于公式(2.2)定义的目标函数，接下来便是构建一个求解目标函数的优化器。

2.3.2 狼群算法优化器

在众多的仿生优化算法当中，狼群算法由于具备快速收敛、尽可能逼近潜在全局最优解，而不会陷入局部最优而被广泛应用。Mirjalili 等人^[44]基于狼群的觅食行为过程，对狼群算法做了进一步的增强。在整个狼群中，各个成员的等级和分工是明确的，并且可以将狼群分为以下 4 个部分： α 狼、 β 狼、 δ 狼和 ω 狼。其中 α 狼可以理解为整个狼群的狼王，负责指挥整个狼群的行为，具有唯一性，因此总会处于整个群体中的最佳位置； β 狼与 δ 狼通常各由一只或少量的若干只组成，时刻与狼王进行通信，负责信息的分析和辅助决策等（本文 β 狼与 δ 狼各由一只组成）； ω 狼是由狼群的剩余部分构成的，主要负责在捕猎的过程中，寻觅猎物、跟踪猎物、围捕猎物等。因此，在算法迭代终止时， α 狼总是处于最佳的位置，也即是优化过程中的最优解， β 狼属于次优解， δ 狼属于再次优解，而 ω 狼则属于候选解。

狼群围捕猎物的过程，可以用如下的数学公式进行模拟表达：

$$D = |C \cdot X_p(t) - X(t)| \quad (2.3)$$

$$X(t+1) = X_p(t) - D \times A \quad (2.4)$$

这里的 t 表示当前迭代次数； D 表示猎物与灰狼的距离； A 与 C 表示系数向量； X_p 表示猎物所在的位置向量， X 表示一个狼群成员的位置向量，“ \times ”表示两个向量对应位置元素求乘积。

A 与 C 系数向量可由公式（2.5）—（2.6）表达：

$$A = 2a \cdot r_1 - a \quad (2.5)$$

$$C = 2 \cdot r_2 \quad (2.6)$$

此处的 r_1 与 r_2 表示与狼群成员同型的、 $(0,1)$ 之间的随机向量， a 是 $[0,2]$ 之间的线性

衰减因子，每次狼群更新时 a 就会发生一次衰减。以上的过程，会迫使狼群整体往猎物所在的位置前进。在逼近猎物后，要进一步缩小包围圈，并袭杀猎物，该过程可由公式 (2.7) - (2.9) 表达：

$$D_\alpha = |C_1 \cdot X_\alpha(t) - X|; D_\beta = |C_2 \cdot X_\beta(t) - X|; D_\delta = |C_3 \cdot X_\delta(t) - X| \quad (2.7)$$

$$X_1 = X_\alpha - A_1 \times D_\alpha; X_2 = X_\beta - A_2 \times D_\beta; X_3 = X_\delta - A_3 \times D_\delta \quad (2.8)$$

$$X_{(t+1)} = \frac{X_1 + X_2 + X_3}{3} \quad (2.9)$$

重复迭代 (2.3) - (2.9) 直到达到终止条件，最终得到的狼王 α 所在的位置向量就是本次优化求解的结果，也就是降维所对应的波段序号。对于整个狼群算法的运作过程，可以概括为如下步骤：

第一步：初始化狼群 $X_i (i = 1, 2, \dots, N)$ 、衰减系数 a 、最大迭代次数；

第二步：根据公式 (2.1) 从狼群中筛选出 α 狼、 β 狼、 δ 狼；

第三步：根据公式 (2.9) 更新每一个狼群成员；

第四步：计算公式 (2.3) - (2.8)，若未达到终止条件，则进入第二步；

第五步：输出狼王 α 的位置向量，优化求解结束。此时 α 狼位置向量的各个分量就是优化求得的降维波段的编号。

2.4 实验设置与结果分析

2.4.1 实验设置说明

该章主要是针对高光谱影像维数高、近邻波段冗余等现象而提出的一种降维方法。为了验证该方法的有效性，我们需要使用一个统一的分类器对基于不同降维方法得到的结果进行分类评价。在众多的半监督分类算法中，支持向量机 (SVM) 得益于其严谨的数学理论推导和高效性而被广泛地使用在高光谱领域^[45-46]。因此，本章的对比试验是基于不同降维方法下的同一分类器 (SVM) 进行的评估，这样可以有效地避免由于使用不同分类器而造成的分类误差影响。同时，为了对比的完善性，本章实验及比较对象如下表：

表 2.1 本章实验与对比试验框架说明

Tab.2.1 Description of experimental and comparative test framework in this chapter						
	特征提取		特征选择			
降维方法	PCA ^[48]	KPCA ^[24]	OCF ^[30]	ONR ^[49]	ISD_ABC ^[50]	FCM_GWO
分类方法	统一使用支持向量机 (SVM)					
实验参数	[P]	[P, σ]	[P]	[P]	[P]	[P, a]

根据我们先前的研究工作^[51]，折衷程序运行结果的稳定性和运行时间成本等问题，本章实验及对比实验都将数据集均降至 30 维，即 $P=30$ 。不同的降维方法在三个数据集上的标记比例分别是：Indian Pines 数据集标记 10%、Pavia University 数据集标记 10%、

Salinas 数据集标记 1%，对于各个标记的样本集使用 5 层交叉验证 SVM 进行训练。同时，为了避免模型训练时偶然性因素的影响，所有程序均独立运行 10 次，取其平均值和标准差来表征最终的分类结果。

2.4.2 实验结果与分析

本章实验，对 Indian Pines、Pavia University 和 Salinas 三个数据集分别利用 FCM 划分了 5 个、3 个和 6 个子空间；其次，利用 GWO 分别从每个子空间中选择 k 个特征，构成最终的降维波段数；最后，使用 SVM 对降维后的特征波段进行分类，分类结果如表 2.2。

表 2.2 本章实验在 3 个数据集上不同降维尺度下使用 SVM 标记 10% 分类结果

Tab.2.2 The experiment in this chapter uses SVM to label 10% classification results under different dimensionality reduction scales on three data sets

Indian Pines			Pavia University			Salinas		
波段	OA	κ	波段	OA	κ	波段	OA	κ
5	69.91±0.2	65.45±0.2	6	81.00±0.2	74.12±0.3	6	88.16±0.2	86.79±0.2
10	76.78±0.5	73.43±0.6	12	84.61±0.1	79.31±0.1	12	89.19±0.2	87.94±0.2
15	78.75±0.4	75.67±0.4	18	89.37±0.1	85.76±0.2	18	89.48±0.3	88.26±0.3
20	79.36±0.5	76.34±0.5	24	90.90±0.2	88.13±0.2	24	89.57±0.4	88.36±0.4
25	80.22±0.5	77.36±0.6	30	91.99±0.1	89.31±0.1	30	89.66±0.4	88.46±0.4
30	80.45±0.4	77.60±0.4	36	92.40±0.1	89.85±0.1	36	89.70±0.4	88.51±0.5
35	80.83±0.3	78.05±0.4				42	89.73±0.5	88.54±0.5
40	80.98±0.4	78.26±0.5						
45	81.17±0.6	78.46±0.7						

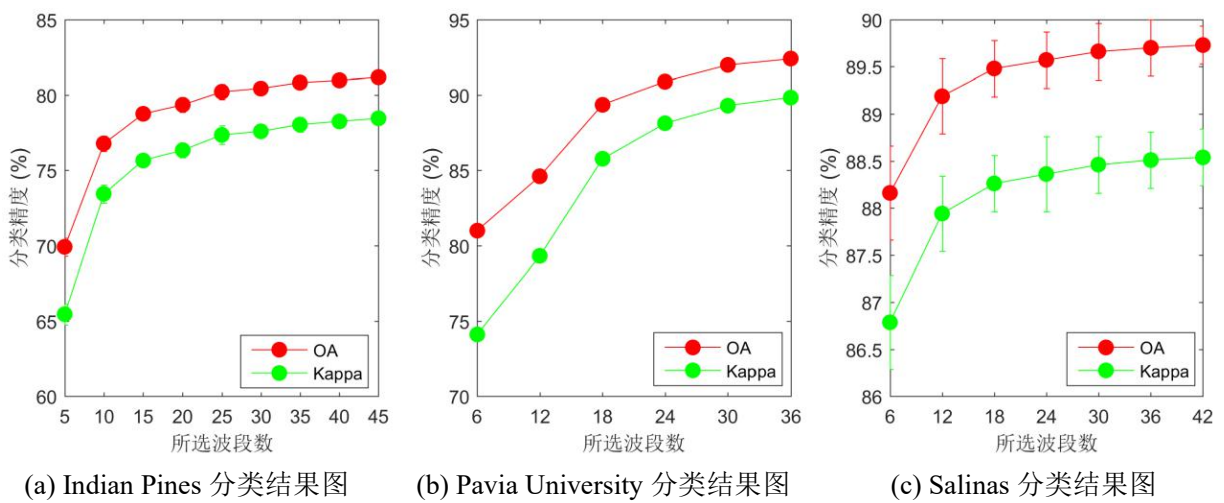


图 2.2 三个数据集的分类精度随降维尺度的变化关系

Fig 2.2 The relationship between OA of the three data sets and the dimension reduction scale

如表 2.2 与图 2.2a - 2.2c, 本章提出的降维算法在三个数据集上均表现出随着降维波

段的增加, 分类精度在逐渐上升的趋势。但是, 这种趋势并不是简单的线性增长关系。因为, 当降维的波段数达到一定程度时, 分类的正确增加率就变得异常缓慢。例如, 在 Indian Pines 数据集和 Pavia University 数据集上, 当原始数据集被降至 30 维后, 若继续增加维度则总体分类精度增加不会超过 0.5%; 在 Salinas 数据集上, 当原始数据集被降至 30 维后, 若继续追加维度总体分类精度的提升不会超过 0.1%。由此可以看出, 在原有的波段中的确存在大量的冗余特征, 因为在达到一定的特征维度时, 继续增加样本的特征维度并不会带来明显的分类精度的提升。同时, 巨大的样本特征维度不仅会极大地消耗计算机的资源。为了证明本章方法的有效性, 所有的对比试验均将维度降至 30 维, 并使用 5 层交叉检验支持向量机对三个数据集进行训练, 最终的测试精度将作为评价各模型性能的依据。具体的测试如下:

表 2.3 6 个实验在 Indian Pines 数据集上的分类结果
Tab.2.3 Classification results of 6 experiments on Indian Pines dataset

类别	训练/测试	特征提取		特征选择			
		PCA ^[48]	KPCA ^[24]	OCF ^[30]	ONR ^[49]	ISD_ABC ^[50]	FCM_GWO
1	5/41	37.56±9.2	68.29±9.3	46.59±21.2	43.05±17.0	35.60±13.9	47.14±7.4
2	143/1285	66.08±3.2	67.76±3.2	69.79±3.4	66.06±2.8	70.42±3.2	73.66±3.5
3	83/747	47.63±3.8	61.04±3.2	51.45±1.9	51.05±3.3	62.55±5.3	62.81±3.9
4	24/213	33.19±5.9	56.87±5.6	30.89±14.1	27.14±14.2	48.08±7.3	56.73±7.5
5	49/434	84.53±3.5	81.77±3.1	84.53±3.6	84.84±2.8	85.16±2.9	85.19±5.2
6	73/657	93.49±1.4	93.18±2.4	93.91±2.5	95.41±1.9	95.17±1.8	95.52±1.1
7	3/25	62.0±10.4	57.20±15.9	72.20±5.6	72.80±7.0	71.54±8.5	72.30±6.3
8	48/430	95.35±2.5	96.14±1.8	95.95±1.7	95.35±1.1	96.02±2.1	96.15±1.8
9	2/18	23.3±13.6	46.11±16.4	6.67±12.4	8.06±8.5	48.06±26.4	50.00±8.8
10	98/874	60.17±3.4	68.66±3.9	54.32±4.2	53.38±6.2	76.24±4.0	76.30±4.3
11	246/2209	77.62±2.4	81.23±2.2	84.27±2.3	82.11±2.1	83.38±2.2	84.67±2.4
12	60/533	50.60±4.5	65.55±2.2	58.15±5.9	38.15±5.3	68.78±3.1	69.44±1.8
13	21/184	91.79±4.7	96.20±2.0	95.41±2.0	95.43±2.9	95.87±3.7	97.62±1.1
14	127/1138	94.39±1.7	93.46±1.7	95.88±0.9	95.63±0.9	95.28±1.2	95.68±1.5
15	39/347	45.82±3.3	44.58±6.5	37.22±4.6	46.08±5.5	46.27±5.9	51.72±4.2
16	10/83	80.49±3.3	81.39±3.6	81.80±4.5	81.86±4.9	82.08±6.9	81.43±5.4
OA	—	72.49±1.0	76.86±0.5	74.78±0.1	72.75±0.1	79.06±0.8	80.46±0.4
AA	—	65.25±4.8	72.46±5.2	66.19±5.7	64.78±5.4	72.53±6.2	74.77±4.2
κ	—	68.43±0.1	73.82±0.1	71.06±0.1	68.62±0.1	76.25±0.1	77.60±0.4

如表 2.3, 在 Indian Pines 数据集上, 在相同的降维尺度(都降至 30 维)和相同的训练比例下(每类均标记 10%, 独立运行 10 次)本章所提出的方法的总体分类精度(OA)都优于各个对比试验。从 OA 指标来看, 经典的 PCA 特征提取方法在 Indian Pine 数据集上获得了最低分类精度 72.49。这种现象与该数据集样本自身的复杂性是不可分离的。

因为原始的 PCA 技术只是一种简单的线性变换，它不能够很好地处理线性不可分状态的数据样本。而在第一章的数据集介绍中，已经明确了该数据集中各个类别之间并不是彼此排斥的，也就是说每类地物的可分离性并不好。与 PCA 所不同的是，KPCA 加入了“核变换”的思想，通过将原始数据投影到更高的特征维度，再从更高的特征维度中试图找到可分的属性特征，这种性质当然对 Indian Pines 数据集是很有意义的，因此 KPCA 相对了 PCA 方法显著提高了 4.37 个百分点；与 OCF、ONR 特征选择方法相比，本章算法分别提高了 5.68 和 7.71 个百分点，这种现象可能是由于该算法并未能最大程度地解决特征冗余问题，从而导致降维后的特征子集的区别性仍然不强；而相对于同等框架的 ISD_ABC 来说，本章算法仅略高出了 1.4 个百分点，这点影响一方面可能是来自于分类器的随机偏差，另一方面可能是来自于子空间划分策略不同所导致的。但我们不难发现的是，所提框架的分类结果均高于其他对比实验。如图 2.3 展示了各个实验的分类结果：

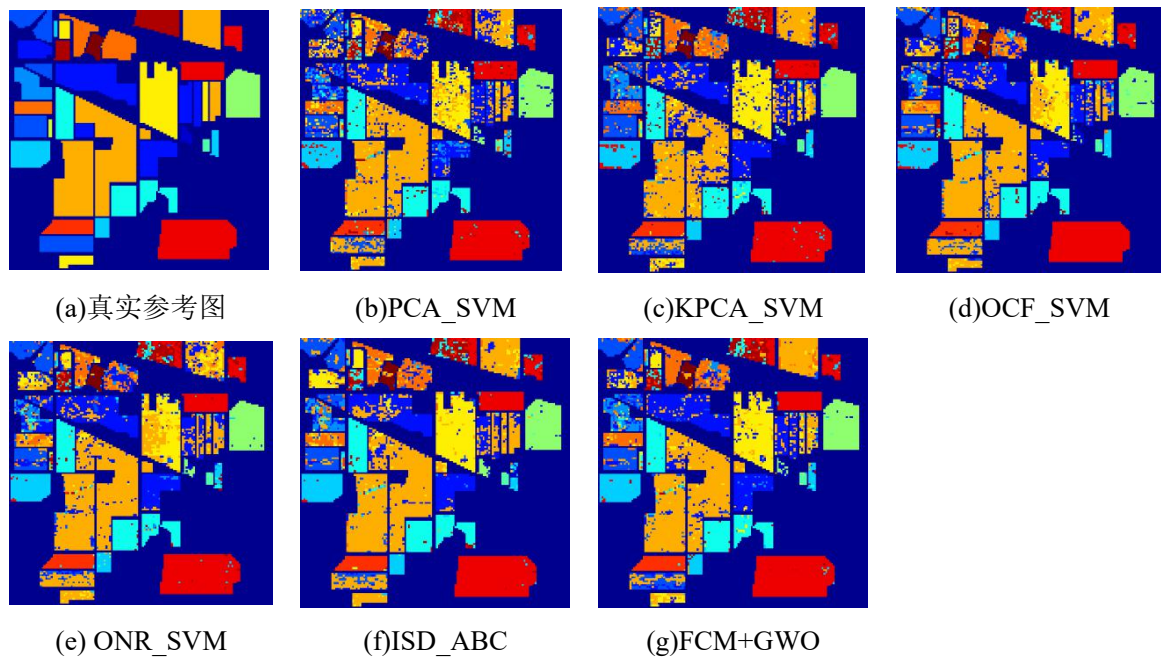


图 2.3 几个算法在 Indian Pines 数据集上的分类结果图

Fig 2.3 The classification results of 6 algorithms on the Indian Pines dataset

表 2.4 是各个实验在 Pavia University 数据集上独立运行 10 次的结果。从总体分类精度上看，本章所提出的方法，依然略优于其他的比较算法。与传统的 PCA 相比，本章算法提高 1.61%；而相对于 OCF 与 ONR 等特征选择方法，则分别高出了近 2.01 和 2.23 个百分点。总体上看，各个算法的分类精度相差并不大。尤其是 PCA 与 KPCA 的最终分类结果相差甚微，不到 0.57%，这主要是 Pavia University 数据集其自身的数据分布相对于 Indian Pines 而言较为简单。因为 Pavia University 数据集仅有 9 个类别，且各个类别之间几乎是相互排斥的。也就是说，每类地物之间的光谱曲线的可分离性是较好，

因此擅长处理低维线性不可分的 KPCA 并未起到显著的作用。而 OCF 与 ONR 算法选择的特征波段之间可能仍有冗余或未能将更优的波段子集从原始的特征空间中分离而表现出略低的分类结果。ISD_ABC 由于框架与 FCM_GWO 相似，因此也表现出较好的分类结果。具体的分类情况如图 2.4

表 2.4 6 个算法在 Pavia University 数据集上的分类结果
Tab.2.4 Classification results of 6 algorithms on the Pavia University dataset

类别	训练/测试	特征提取		特征选择			
		PCA ^[48]	KPCA ^[24]	OCF ^[30]	ONR ^[49]	ISD_ABC ^[50]	FCM_GWO
1	664/5967	91.03±0.5	91.72±0.3	90.5±0.5	90.64±0.5	90.9±0.5	92.56±0.7
2	1865/16784	94.45±0.2	96.37±0.2	96.94±0.3	96.64±0.3	95.55±0.2	97.15±0.2
3	210/1889	77.24±1.6	69.52±2.0	68.21±2.8	65.15±1.8	73.37±1.8	77.27±1.4
4	307/2757	89.99±1.0	91.45±1.0	91.37±0.8	91.92±1.0	89.19±1.1	91.97±0.8
5	135/1210	97.85±0.3	98.59±0.2	98.9±0.2	99.16±0.3	99.17±0.4	99.14±0.5
6	503/4526	80.61±1.3	80.62±1.1	71.76±1.5	72.67±1.7	80.07±1.3	80.10±0.7
7	133/1197	80.88±1.4	80.32±1.4	80.63±1.4	80.01±1.4	82.87±1.6	80.92±2.4
8	369/3313	88.23±1.0	88.11±1.5	87.98±1.6	87.45±1.2	88.56±1.3	88.85±1.2
9	95/852	99.53±0.1	95.23±1.5	98.54±0.5	96.29±1.2	99.88±0.2	99.88±0.1
OA	—	90.39±0.2	90.96±0.1	89.99±0.1	89.77±0.1	90.68±0.2	92.00±0.1
AA	—	88.87±0.8	87.99±1.0	87.2±1.1	86.66±1.1	88.84±0.9	89.76±0.9
κ	—	88.46±0.1	88.28±0.1	86.63±0.1	86.51±0.1	88.49±0.1	89.31±0.1

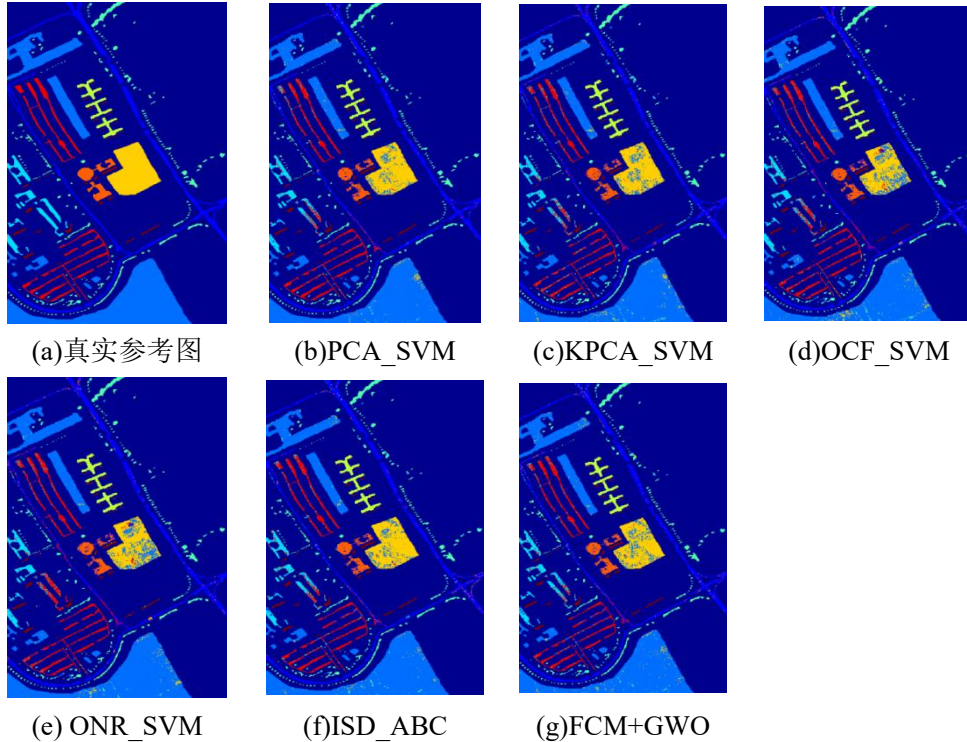


图 2.4 6 个实验在 Pavia University 数据集上的分类结果图

Fig 2.4 Classification results of 6 experiments on the Pavia University dataset

表 2.5 6 个实验在 Salinas 数据集上的分类结果

Table 2.5 Classification results of 6 experiments on the Salinas dataset

类别	训练/测试	特征提取		特征选择			
		PCA ^[48]	KPCA ^[24]	OCF ^[30]	ONR ^[49]	ISD_ABC ^[50]	FCM_GWO
1	21/1988	96.93±1.0	95.18±2.3	97.11±0.7	97.23±0.9	97.15±1.9	97.25±0.8
2	38/3688	96.83±0.2	97.99±1.5	98.78±0.3	98.72±0.2	98.65±0.8	99.24±0.3
3	20/1956	92.38±3.8	96.32±6.3	83.25±6.7	83.6±3.9	96.63±2.6	97.61±2.7
4	14/1380	98.62±0.5	98.85±1.0	98.81±0.3	98.82±0.4	98.69±1.2	98.83±0.6
5	27/2651	95.77±0.9	95.48±0.7	96.05±1.2	96.32±1.2	96.74±2.0	96.74±1.2
6	40/3919	97.58±0.2	99.11±1.0	99.51±0.2	99.58±0.2	99.13±0.7	99.55±0.1
7	36/3543	96.36±0.2	99.19±0.2	99.11±0.2	99.21±0.2	99.23±0.2	99.25±0.1
8	113/11158	85.51±2.6	87.2±1.6	87.13±2.4	88.54±2.5	85.54±2.9	85.13±3.0
9	63/6140	98.18±0.1	98.61±0.8	98.02±0.8	98.38±0.8	98.65±0.6	98.92±0.4
10	33/3245	87.22±2.5	86.53±6.8	84.49±4.8	87.99±4.7	85.92±2.7	87.47±2.6
11	11/1057	93.47±2.0	90.78±5.5	91.4±3.0	90.87±2.8	87.07±4.6	84.82±8.6
12	20/1907	99.11±1.0	99.59±0.3	99.66±0.5	99.75±0.2	98.98±0.9	99.7±0.2
13	10/906	97.79±0.6	98.06±0.7	97.75±0.6	97.43±0.5	97.63±1.0	97.82±0.6
14	11/1059	90.01±2.4	90.56±2.0	91.15±3.0	92.85±1.7	90.16±3.8	89.85±3.4
15	73/7195	59.05±4.0	57.57±4.7	55.82±4.6	53.39±6.3	57.59±4.4	61.98±3.8
16	19/1788	91.48±1.1	91.43±6.5	94.64±4.3	94.23±3.2	94.13±3.5	94.14±3.4
OA	—	88.55±0.4	89.14±1.0	88.52±0.1	88.79±0.1	88.94±0.5	89.65±0.4
AA	—	92.27±1.4	92.65±2.6	92.04±2.1	92.31±1.9	92.62±2.1	93.02±2.0
κ	—	87.57±0.1	87.93±0.1	87.13±0.1	87.69±0.1	87.86±0.1	88.46±.45

表 2.5 展示了不同的特征降维方法，对原始 Salinas 高光谱影像数据降维至 30 波段后，并对每类地物标记 1%作为训练集的 10 次独立重复实验的结果。不难发现，无论是从总体分类精度(OA)上看，还是从平均分类精度(AA)或是卡帕系数(κ)，各个实验的精度几乎相当，极差不超过 1.13%。这种现象可能与该数据集的空间分布规整和样本在特征空间中具有较好的可分离性是分不开的。因此，无论是特征选择、还是特征提取方法，最终的降维结果在其各自的特征空间中都有较好的可分离性。从一定程度上讲，这种良好的性质对于“谱信息”分类器的 SVM 是很有利的。各种方法的分类结果如图 2.5:




图 2.5 6 个实验在 Salinas 数据集上分类结果图

Fig 2.5 Classification results of 6 experiments on the Salinas dataset

2.4.3 实验参数分析

在本章及其对比实验中，各个降维方法都将原始数据集降至 30 维，即 $P=30$ ，这主要是考虑到实验的稳定性和用时两方面因素。因为，当 $P=30$ 时，各个数据集的最终分类精度变化并不大，波动也非常小。此外，本章算法涉及的参数还有子空间划分的个数，也即 FCM 中的 C ，该参数主要是根据光谱的先验知识确定的；狼群算法中还涉及到狼群大小 N ，最大迭代次数 K_{max} ，这些参数是需要我们自己指定的超参数（在本章实验

中 $N=30$, $K_{\max}=100$), 它们对实验并不起本质的影响但会影响到寻优的速度。与这些超参数所不同的是, GWO 算法中的线性衰变因子 a 在实验中扮演着重要的角色。因为 a 的作用类似于深度学习中的“动量因子”, 是专门为了防止寻优的过程陷入“局部最优解”, 也是模仿狼群正在一步步有效地逼近猎物的过程。该因子在 Indian Pines 数据集上的影响如下图:




图 2.6 线性衰变因子 a 对分类精度的影响

Figure 2.6 Effect of linear decay factor a on classification accuracy

根据图 2.6, 我们可以得知当 $a = 1.5$ 的时候, 总体分类精度达到最大。该图是通过 10 次独立重复实验得到的, 从而尽可能地避免了因随机标记而产生的影响。但值得注意的是 a 的取值并不是一成不变的, 上图仅能说明在本章其他超参数确定的情况下 a 的最佳选择是 1.5。

2.5 本章小结

本章主要提出了 FCM_GWO 算法, 用于解决高光谱维度较高所导致的波段冗余以及算法复杂度高等问题。实验证明了, 原始的高光谱影像的确存在高度的冗余, 因为当维度降至 30 维以后, 分类精度的增加是异常缓慢的, 甚至增长率为零, 呈现出在某一分类精度瓶颈处上下小幅度波动的趋势。而与其他经典的方法相比较, 本章提出的算法在精度上均占些许的优势。尤其是在 Indian Pines 数据集上, 本章提出的降维算法结合最终分类效能有显著的提高, 这与该数据集在其特征空间中的复杂分布是分不开的; 而在 Pavia University 和 Salinas 数据集上, 则略微高于各对比试验。由于本章所使用的分类器皆为 SVM, 虽然这种严格的控制变量思想很有利于我们研究本章的“数据预处理”

方法，但 SVM 终归属于“像素级别”的分类器，且仅仅使用了样本的光谱信息而并未对其空间信息进行充分并利用。为了获得更优的分类结果，下一章我们将详细地研究空间信息与光谱信息共同作用对地物识别精度的影响。

3 基于超像素和不连续保持松弛的高光谱图像分类方法

高光谱图像分类是遥感领域最活跃的课题之一。然而，由于 HSI 总是存在大量的噪声像素、物体空间结构的复杂性和不同物体之间的光谱相似性，因此准确地对高光谱数据进行分类仍然是一项重要的任务。本章提出了一种基于超像素和不连续保持松弛(DPR)的高光谱图像的有效分类方案去识别感兴趣的土地覆盖。提出了一种测量 HSI 中一对像素相似性的技术，以改进简单的线性迭代聚类(SLIC)。改进后的 SLIC 算法是无参数的，因此可以直接、方便地将 HSI 分割成超像素，而无需事先使用 PCA。该方案首先采用 DPR 策略来解决原始高光谱数据去噪的问题，同时保持从 HSI 中提取的不连续性。然后，使用具有五重交叉验证的支持向量机在像素级别上对预处理的 HSI 进行分类。最后，作为后处理过程，利用改进的 SLIC 方法得到的超像素，提高了像素级的分类结果。在三个公共真实高光谱数据集上验证了该方法的有效性，总体精度(Overall Accuracy, OA)、平均精度(Average Accuracy, AA)和 Kappa 系数(κ)等评价指标表明了该方案的优越性。

3.2 不连续保持松弛算法

在高光谱影像中，同谱异物与同物异谱的现象常常以“噪音”的形式一直干扰着模型的训练与预测。此外，成像环境的复杂性（例如：水蒸气、云层等）也可能导致同种地物反射的电磁波能量在终端接收器上呈现出“趋异”的性状。因此，以去噪为目的的一系列方法被逐渐应用到高光谱影像分类中去以获得更好的分类效果^[52-56]。这些平滑去噪的方法，虽然可以使大面积地物内部更加平滑，但同时也跨越了地物的边界从而使空间上相邻但不同类别的地物在边界处呈现“趋同”的现象。对于这个问题，不连续保持松弛算法给了一个很好的解决方案，因为该算法在平滑影像的同时兼顾了地物边界问题。

作为数据预处理过程，我们可以将不连续保持松弛算法表达如下：

$$\gamma = e^{-(\sum_{i=1}^B Roberts(b_i))} \quad (3.1)$$

这里 B 表示高光谱影像的波段总数， b_i 表示该影像的第 i 个波段， $Roberts$ 为边缘检测算子。对影像进行平滑纠正的过程可由公式 (3.2) 表达。

$$\tilde{x}_{i,b}^{(t+1)} = \frac{(1-\beta)x_{i,b} + \beta \sum_{x_j \in N(x_i)} \gamma_j \tilde{x}_{j,b}^{(t)}}{(1-\beta) + \beta \sum_{x_j \in N(x_i)} \gamma_j}, \quad b = 1, 2, \dots, B \quad (3.2)$$

此处的 $\tilde{x}_{i,b}^{(t)}$ 是第 i 个样本像元的第 b 个波段在第 t 次迭代时的光谱值， $N(x_i)$ 表示像元 x_i 的摩尔邻居，可由公式 (3.3) 表示。

$$N(x_i) = \{x_j : |p_i - p_j| \leq 1 \text{ and } |q_i - q_j| \leq 1\} \quad (3.3)$$

(p_i, q_i) 表示样本像元 x_i 的空间坐标。

3.3 超像素切割方法

3.3.1 原始的超像素切割方法 SLIC

超像素的本质在于利用影像的空间信息和光谱信息，将现有的图像分割成为均质而又不重叠的“小块”。其最先应用在计算机视觉领域，但随着超像素生成的方式不同，该类方法在不断地演变并逐渐地被推广到高光谱领域中去。在诸多方法当中，“简单线性迭代聚类（SLIC）”得益于其惊人的分割速度与可观的边缘召回率而被广泛地应用。实际上，我们可以理解为 SLIC 主要是通过比较种子点与其搜索域内各个像元的相似度来给影像重新编码的，这种相似度可以表示如下：

$$d = \sqrt{\left(\frac{d_c}{N_c}\right)^2 + \left(\frac{d_s}{s}\right)^2} \quad (3.4)$$

这里 d_c 与 d_s 分别表示种子像元与搜索域内某一像元的颜色距离和就空间距离， N_c 表示最大颜色距离， s 表示切割的尺度。而不同图像之间的色差是多变的，这对 N_c 的确定是不便的，为了解决这一问题，我们可以将公式（3.4）转变为公式（3.5）。

$$d = \sqrt{(d_c)^2 + m^2\left(\frac{d_s}{s}\right)^2} \quad (3.5)$$

m 是一个调节空间距离与颜色距离作用强度的一个超参数，通常情况下为了获得更佳的切割效果，原始的 RGB 色彩空间被转换到 CIELAB 空间。根据计算机视觉研究领域的经验知识，发现 m 的取值范围在[1,40]时，往往能够获得理想的切割图，这为后期的应用推广提供了极大的便利。

3.3.2 改进的 SLIC 切割方法

在原始的 SLIC 中，我们不难发现切割的效果主要受权重 m 和切割尺度 s 的影像。而 s 通常可以由遍历法确定，因此我们只需要在[1,40]中略微调节一下 m 便可以获得较为满意的切割图。这套方法在 RGB 图像上可能是没有问题的，但是把它推广到遥感影像上，尤其是高光谱影像上可能面临着诸多问题。虽然在 SLIC 的原文中^[39]，作者在最后谈到了该算法是可以推广到“超体”的，但是并未对如何推广做详细的介绍。此外，低维空间下的参数 m 也将不再适用于高维空间中。

基于对现有的高光谱数据的光谱曲线的考察，如图 3.1。我们不难发现即使是同一地物类型，其光谱反射值也是相差很大的，并不像我们想象中的那样集中，但其曲线形状是相似的。因此，笔者考虑如果仅仅使用欧氏距离和空间距离去度量高光谱数据样本的相似度可能是欠佳的。同时，为了避免高维空间下的参数 m ，笔者借鉴了“集成学习”的思想，提出了“组合决策无参相似度模型”。该模型的核心思想在于：首先使用“曼哈顿距离”度量样本对（由种子像元与其搜索域内的任意一像元构成）之间的总体差异性；其次使用“相关系数距离”度量样本对之间的光谱曲线的形状差异性；再其次使用空间距离，限制其搜索域；最后，如果样本对所构成的 3 种距离满足以上 2 种就将该像元编码

与其种子像元保持一致。我们可以用公式 (3.6) - (3.8) 来表示这 3 种距离。




图 3.1 Pavia University 数据集第 5 类地物的光谱曲线图

Fig 3.1 Spectral curve of the fifth feature in Pavia University dataset

$$d_{spec}(x_i, x_j) = \sum_{h=1}^B |x_{i,h} - x_{j,h}| \quad (3.6)$$

$d_{spec}(x_i, x_j)$ 表示样本对的光谱距离，用来度量样本对的总体相似度。其中， B 表示总的波段数。

$$d_{spat}(x_i, x_j) = \sqrt{(p_i - p_j)^2 + (q_i - q_j)^2} \quad (3.7)$$

$d_{spat}(x_i, x_j)$ 表示样本对的空间距离。其中， (p_i, q_i) 表示样本像元 x_i 的空间坐标。

$$\rho(x_i, x_j) = \frac{B \sum_{h=1}^B x_{i,h} x_{j,h} - \sum_{h=1}^B x_{i,h} \sum_{h=1}^B x_{j,h}}{\sqrt{B \sum_{h=1}^B x_{i,h}^2 - (\sum_{h=1}^B x_{i,h})^2} \sqrt{B \sum_{h=1}^B x_{j,h}^2 - (\sum_{h=1}^B x_{j,h})^2}} \quad (3.8)$$

$\rho(x_i, x_j)$ 表示样本对的相关性，表达样本曲线形状的相近程度。为了方便比较，这里我们将相似度距离定义为公式 (3.9)。

$$r(x_i, x_j) = 1 - \rho(x_i, x_j) \quad (3.9)$$

原始的 SLIC 中的参数 m ，主要是由最后的相似度度量公式需要融合“光谱信息”和“空间信息”这两种完全对立的属性的共同影响而引起的。与这种思维完全不同的是，改进的无参 SLIC 的相似度并不需要这两种属性的作用强度，而是分别从光谱总体差异 $d_{spec}(x_i, x_j)$ 、光谱形状相关性差异 $r(x_i, x_j)$ 和空间距离差异 $d_{spat}(x_i, x_j)$ 三个角度去考虑待

确定的样本像元与种子点像元的相似程度。最后，通过对三种相似度进行投票决策，有 2 种及其以上的相似度认为 x_i 属于第 j 个种子点像素，则将 x_i 的编码设置为 j 。

改进的 SLIC 切割技术大致可以表达为如下：

步骤一：初始化种子像元（也叫聚类中心）、设置搜索步长 s 。移动种子点至其摩尔领域内梯度最小的像元上。

步骤二：根据公式（3.6）、（3.7）和（3.9）为待确定像元进行编码。

步骤三：更新每一个聚类中心。

步骤四：返回至步骤二，直到第 t 次迭代的聚类中心与对应的第 $t-1$ 次的聚类中心的偏移距离小于某一指定的阈值。

3.4 本章分类框架说明

第 2 章给我们展示了一个未利用空间信息的原始高光谱数据集分类的框架。但由于未对数据集进行“降噪”处理，因此分类精度相对而言较低，且容易遇到分类瓶颈。本章则是针对第 2 章的分类缺陷，先利用不连续保持松弛技术对原始数据集的特征波段进行迭代平滑；然后，将平滑后的数据集投入到 5 层交叉验证支持向量机分类器中进行训练和测试得到分类结果图；最后，利用本章提出的改进的无参超像素进行后处理纠正分类图，以获得更佳分类结果。其流程大致如图 3.2：

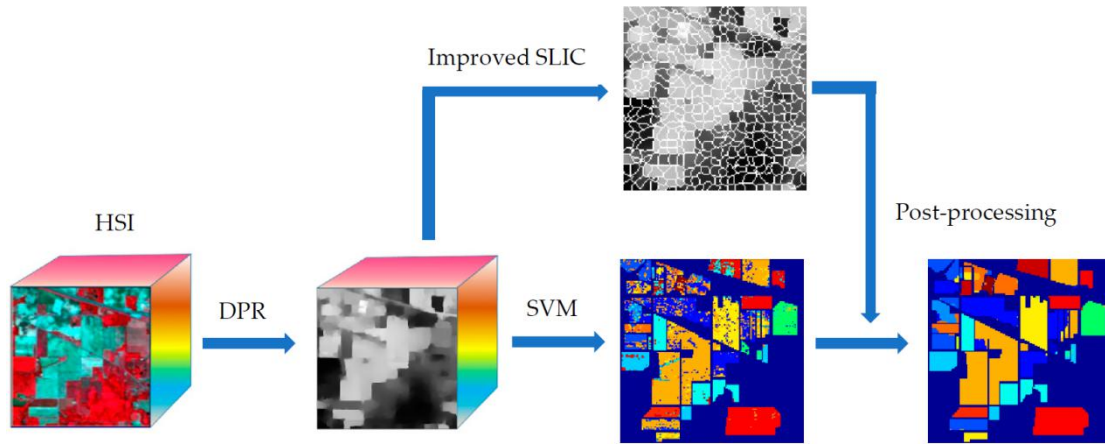


图 3.2 本章分类框架流程图

Fig 3.2 Flow chart of classification framework in this chapter

3.5 实验设置与结果分析

3.5.1 实验设置说明

为了验证本章所提出方法（DPR-SVM-SP）的高效性，三个标准的高光谱影像数据集将依旧作为本次实验的研究对象。有关该数据集的详细介绍，见 1.5.1 实验数据说明部分。本次实验我们分别比较了原始 SVM、SVM 结合本章提出的无参超像素后处理

(SVM-SP)、DPR 预处理结合 SVM 与 PCA 降维后的原始超像素切割(DPR-SVM-POS)以及 DPR 预处理结合 SVM 与改进后的超像素切割 (DPR-SVM-SP) 等方法。在 Indian Pines 数据集中, 每类标记了 5%作为训练集; 在 Pavia University 和 Salinas 数据集中每类仅标记 1%作为训练集; 剩余的未标记样本作为模型的测试集, 最终以测试集的总体分类精度 (Overall accuracy, OA)、平均分类精度 (Average accuracy, AA)、卡帕系数 (Kappa, κ) 等指标来衡量各个分类框架的性能。

3.5.2 实验结果分析

表 3.1 不同的分类框架在 Indian Pines 数据集上的 10 次独立实验的分类结果, 其中超像素的步长 $s=5$, 松弛系数 $\beta = 0.9$, 标记比例为每类 5%

Tab3.1 Classification results of 10 independent experiments on Indian Pines dataset with different classification frameworks, where the superpixel step size $s=5$, relaxation coefficient $\beta = 0.9$, and the labeling ratio is 5% for each class

类别	训练/测试	SVM	SVM-SP	DPR-SVM-POS	DPR-SVM-SP
1	3/43	8.37 \pm 7.5	5.12 \pm 13.83	61.17 \pm 6.4	97.67 \pm 0
2	72/1356	61.97 \pm 4.4	77.07 \pm 6.2	93.16 \pm 0.4	96.35 \pm 0.1
3	42/788	46.13 \pm 2.8	59.49 \pm 5.4	91.17 \pm 0.7	92.57 \pm 0.2
4	12/225	25.47 \pm 5.5	32.36 \pm 14.5	84.67 \pm 0.6	75.47 \pm 0.9
5	25/458	79.91 \pm 3.7	85.33 \pm 5.9	93.21 \pm 0.2	90.46 \pm 0.3
6	37/693	94.14 \pm 2.2	96.54 \pm 2.3	99.86 \pm 0	100.0 \pm 0
7	2/26	33.46 \pm 14.5	60.77 \pm 35.5	90.00 \pm 2.0	100.0 \pm 0
8	24/454	94.47 \pm 2.5	96.83 \pm 3.3	98.94 \pm 0.1	98.75 \pm 0.1
9	1/19	4.74 \pm 8.8	2.11 \pm 6.3	60.00 \pm 2.7	100.00 \pm 0
10	49/923	64.60 \pm 4.5	75.84 \pm 5.4	91.51 \pm 0.2	91.75 \pm 0.2
11	123/2332	80.64 \pm 2.7	93.07 \pm 1.8	98.81 \pm 0	97.62 \pm 0.1
12	30/563	37.90 \pm 6.5	54.51 \pm 12.2	85.61 \pm 1.7	94.23 \pm 0.1
13	11/194	95.15 \pm 2.8	98.19 \pm 0.7	99.07 \pm 0.3	99.07 \pm 0.2
14	64/1201	95.50 \pm 1.2	99.45 \pm 1.0	97.94 \pm 0.1	100.00 \pm 0
15	20/366	31.86 \pm 6.2	38.36 \pm 12.2	100.00 \pm 0	99.76 \pm 0.1
16	5/88	58.41 \pm 7.5	84.77 \pm 14.4	95.68 \pm 0.5	90.34 \pm 0.6
OA	—	71.04 \pm 1.3	81.01 \pm 2.3	95.09 \pm 0.1	96.00 \pm 0.1
AA	—	57.05 \pm 5.2	66.24 \pm 8.8	90.05 \pm 1.0	95.25 \pm 0.2
κ	—	66.54 \pm 1.5	78.02 \pm 2.7	94.39 \pm 0.2	95.43 \pm 0.1

根据表 3.1 我们不难看出, 仅仅使用光谱信息作为辨别不同地物类型的 SVM 分类器的分类精度是最低的。而与 SVM 所不同的是, SVM-SP 则进一步利用所提出的无参超像素切割技术对原始 SVM 的分类图进行“纠正”, 这种空间信息的利用使得模型的总体分类精度直接提升了近 10 个百分点。尽管如此, 第 1 类地物与第 9 类地物的分类精度依然是很低的, 甚至不到 10%, 这种现象一方面可能是由于该类别的样本容量过小, 使得模型缺乏对该类别地物的辨别能力, 因此在测试集中表现出较差的精度; 另一方面,

也有可能是这 2 种地物的光谱曲线与其他类别有很大的相似性（在 1.5.1 实验数据说明部分，已经明确该数据集中的各种地物并不是相互排斥的），使得样本在其特征空间中的分离性较差所导致。为了解决高光谱影像分类过程中常见的“噪音”问题，本章在进行 SVM 分类之前，先对原始数据集进行了“不连续保持平滑（DPR）”然后对分类后的结果图进行了无参超像素纠正。其分类精度能超越 90%，达到 96% 的分类精度，与此同时第 1 类和第 9 类的分类精度有了极为显著的提高。而所提的无参超像素纠正精度与原始 SLIC 的纠正精度相比，高了近 1%，这很有可能是原始 SLIC 需要 PCA 降至 3 维，而降维又是一个信息有损变换的过程导致的。不同的分类框架对 Indian Pines 数据集的分类结果如图 3.3。

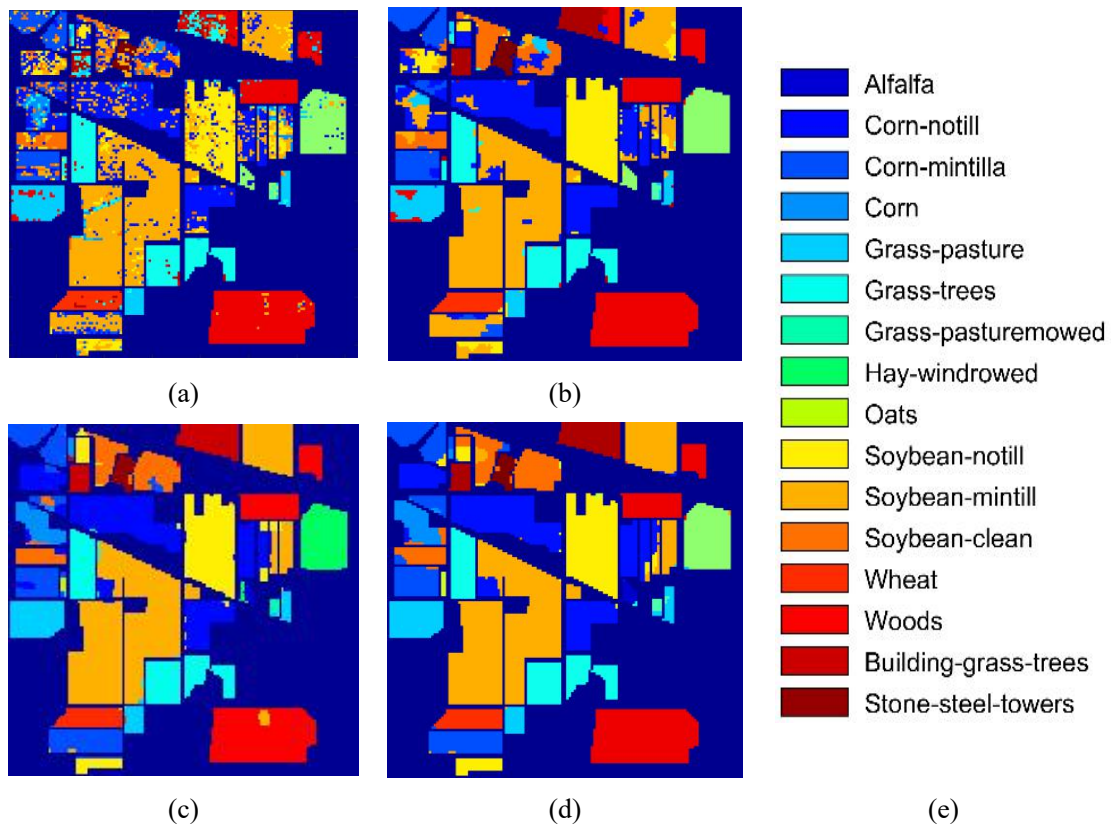


图 3.3 各分类框架在 Indian Pines 数据集上的分类结果。(a) SVM；(b) SVM-SP($s = 5$)；(c) DPR-SVM-POS($m = 15, s = 5, \beta = 0.9$)；(d) DPR-SVM-SP($s = 5, \beta = 0.9$)；(e) 图例。

Fig 3.3 The classification results of various classification frameworks on the Indian Pines dataset. (a) SVM；(b) SVM-SP($s = 5$)；(c) DPR-SVM-POS($m = 15, s = 5, \beta = 0.9$)；(d) DPR-SVM-SP($s = 5, \beta = 0.9$)；(e) Label.

表 3.2 不同的分类框架在 Pavia University 数据集上的 10 次独立实验的分类结果，其中超像素的步长 $s=9$, 松弛系数 $\beta = 0.2$ 标记比例为每类 1%

Table 3.2 The classification results of 10 independent experiments on the Pavia University dataset of different classification frameworks, where the superpixel step size $s=9$ and the relaxation coefficient $\beta = 0.2$ The labeling ratio is 1% per category

类别	训练/测试	SVM	SVM-SP	DPR-SVM-POS	DPR-SVM-SP
1	67/6564	85.85 \pm 2.2	97.47 \pm 1.0	96.86 \pm 0.2	97.60 \pm 0.1
2	187/18462	96.78 \pm 1.1	99.30 \pm 0.8	99.25 \pm 0	99.90 \pm 0
3	21/2078	61.01 \pm 4.1	72.51 \pm 9.6	90.74 \pm 0.9	93.43 \pm 0.1
4	31/3033	83.90 \pm 4.6	87.44 \pm 3.1	93.83 \pm 0.1	94.95 \pm 0.1
5	14/1331	96.81 \pm 3.3	99.71 \pm 0.1	99.77 \pm 0	97.92 \pm 0.1
6	51/4978	71.53 \pm 4.6	78.97 \pm 7.7	99.90 \pm 0	98.88 \pm 0.1
7	14/1316	77.31 \pm 6.2	93.37 \pm 4.5	99.02 \pm 0	85.91 \pm 0.1
8	37/3645	82.56 \pm 3.9	95.11 \pm 2.7	92.15 \pm 0.8	96.72 \pm 0.1
9	10/937	99.63 \pm 0.4	98.59 \pm 0.1	99.26 \pm 0	91.28 \pm 0.1
OA	—	87.67 \pm 1.1	93.92 \pm 1.2	97.55 \pm 0.1	97.70 \pm 0.1
AA	—	83.93 \pm 3.4	91.39 \pm 3.3	96.75 \pm 0.2	95.18 \pm 0.1
κ	—	83.44 \pm 1.5	91.82 \pm 1.7	96.75 \pm 0.1	97.06 \pm 0.1

从表 3.2 中, 我们可以看出仅使用 SVM 对影像进行分类时只能达到 87.67% 的精度, 而当使用本章提出的无参超像素进行分类后处理后提升了 6 个百分点左右。而当进一步对原始数据集先进行 DPR 平滑预处理再分类并使用所提超像素方法纠正, 精度提升了大约 10%, 达到了 97.7%。而原始 SLIC 纠正的结果和本文算法相比, 并无很大区别, 这可能和该数据集的简单性是相关的。这种简单主要来自两点: 一方面是数据类型较少仅有 9 类, 另一方面是每类的光谱曲线差异较大, 如图 3.4:

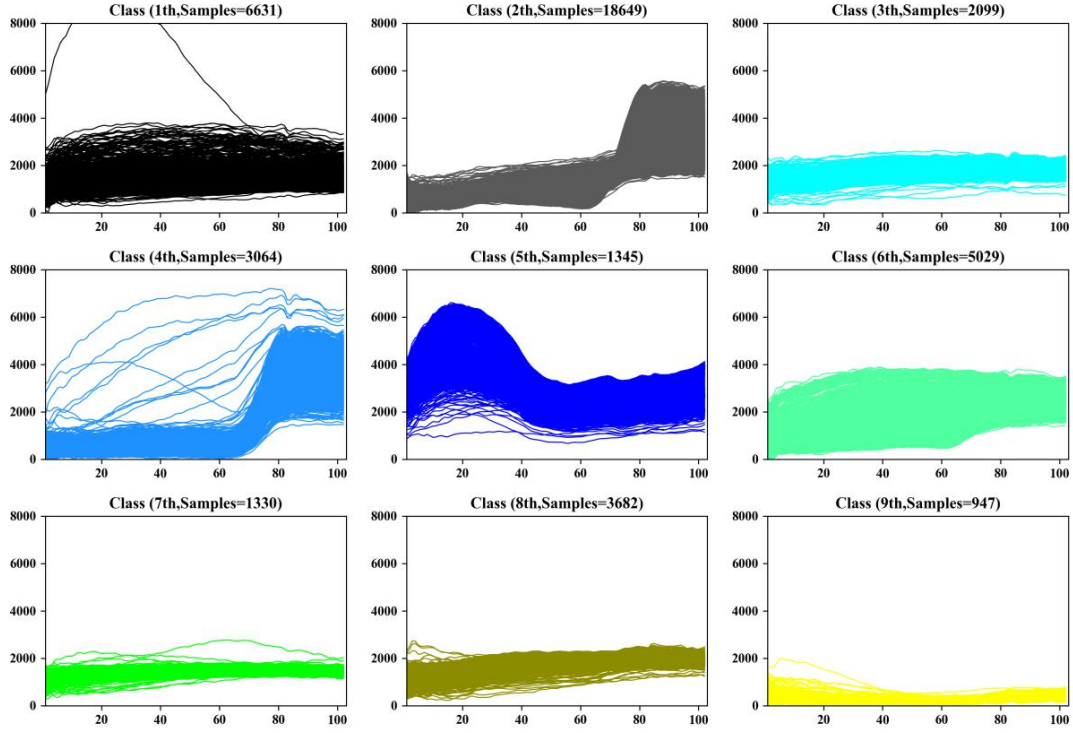


图 3.4 Pavia University 数据集每类地物的光谱曲线图

Fig 3.4 Spectral curves of each class in the Pavia University dataset

结合 Pavia University 数据集的真实地物分布与实验统计的结果，我们发现即使对于零碎的斑块地物依然能够获得较好的分类结果。这说明了我们所提出的切割方法对于空间上分布不规整的数据集仍然有较好的适应性。具体的分类结果如图 3.5。



 图 3.5 各分类框架在 Pavia University 数据集上的分类结果。(a) SVM; (b) SVM-SP($s = 9$); (c) DPR-SVM-POS($m = 15, s = 9, \beta = 0.2$); (d) DPR-SVM-SP($s = 9, \beta = 0.2$); (e) 图例。

 Fig 3.5 The classification results of various classification frameworks on the Pavia University dataset. (a) SVM; (b) SVM-SP($s = 9$); (c) DPR-SVM-POS($m = 15, s = 9, \beta = 0.2$); (d) DPR-SVM-SP($s = 9, \beta = 0.2$); (e) Label.

表 3.3 不同的分类框架在 Salinas 数据集上的 10 次独立实验的分类结果, 其中超像素的步长 $s=15$, 松弛系数 $\beta = 0.9$ 标记比例为每类 1%

Tab3.3 The classification results of 10 independent experiments on the Salinas dataset with different classification frameworks, where the superpixel step size $s=15$ and the relaxation coefficient $\beta = 0.9$ The labeling ratio is 1% for each class

类别	训练/测试	SVM	SVM-SP	DPR-SVM-POS	DPR-SVM-SP
1	21/1988	97.81 \pm 1.0	100.00 \pm 0	100.00 \pm 0	100.00 \pm 0
2	38/3688	99.31 \pm 0.4	100.00 \pm 0	100.00 \pm 0	100.00 \pm 0
3	20/1956	92.32 \pm 4.9	99.15 \pm 2.7	98.53 \pm 0	100.00 \pm 0
4	14/1380	98.52 \pm 0.8	98.01 \pm 0.1	84.47 \pm 1.0	94.91 \pm 0.1
5	27/2651	96.68 \pm 1.2	94.66 \pm 0.1	82.72 \pm 0.7	99.77 \pm 0.1
6	40/3919	99.55 \pm 0.3	99.59 \pm 0.1	99.80 \pm 0	100.00 \pm 0
7	36/3543	99.28 \pm 0.2	99.86 \pm 0.1	100.00 \pm 0	100.00 \pm 0
8	113/11158	83.85 \pm 5.2	93.37 \pm 1.4	99.00 \pm 0	98.01 \pm 0.1
9	63/6140	98.95 \pm 0.5	99.88 \pm 0.1	100.00 \pm 0	100.00 \pm 0
10	33/3245	86.63 \pm 1.9	93.41 \pm 5.7	97.90 \pm 0	99.69 \pm 0
11	11/1057	87.71 \pm 5.2	97.36 \pm 4.8	94.93 \pm 0.1	99.53 \pm 0
12	20/1907	98.00 \pm 1.0	98.04 \pm 0.7	85.82 \pm 0.1	99.33 \pm 0.1
13	10/906	98.01 \pm 0.8	98.14 \pm 0.1	74.19 \pm 0.2	98.04 \pm 0.1
14	11/1059	90.01 \pm 2.9	96.81 \pm 0.1	68.06 \pm 0.1	96.22 \pm 0.1
15	73/7195	58.65 \pm 4.7	65.93 \pm 9.0	98.49 \pm 0	99.62 \pm 0.1
16	19/1788	93.87 \pm 3.0	93.37 \pm 4.9	100.00 \pm 0	97.67 \pm 0.1
OA	—	88.71 \pm 0.9	92.81 \pm 1.5	96.46 \pm 0.1	99.16 \pm 0.1
AA	—	92.45 \pm 2.1	95.47 \pm 1.8	92.74 \pm 0.1	98.92 \pm 0.1
κ	—	87.40 \pm 1.0	91.97 \pm 1.7	96.06 \pm 0.1	99.06 \pm 0.1

表 3.3 展示了不同的分类框架在 Salians 数据集上独立运行 10 次的分类结果。我们可以清楚地看到原始的 SVM 分类器对于第 15 类地物的辨别能力是很差的, 在该类上的分类精度不到 60%。而 Salians 数据集在支撑空间上的分布又是很规整的, 因此判断该类地物中很有可能存在大量的噪音样本, 并严重影响了模型的训练, 因为 SP 的加入也未能使模型精度得到显著的提升, 仅保持在 66%左右, 说明了该区域存在较多的误分样本。而 DPR 的引进, 使得模型在该类上的精度直接提升了 30 多个百分点, 这也恰恰说明了作为数据预处理的 DPR 算法, 的确在利用地物边界进行保持平滑的过程中能够很好地降低噪音和提升模型的识别能力。而由于原始的 SLIC 在进行 PCA 降维后, 部分类别之间的分界线并不清晰使得切割的时候空间信息和光谱信息在边界处的作用强度相近, 导致原始影像切割的边缘召回率低, 本文所提的无参超像素则自适应于高维空间, 并达到了 99.16%的分类精度。具体的分类结果如图 3.6。

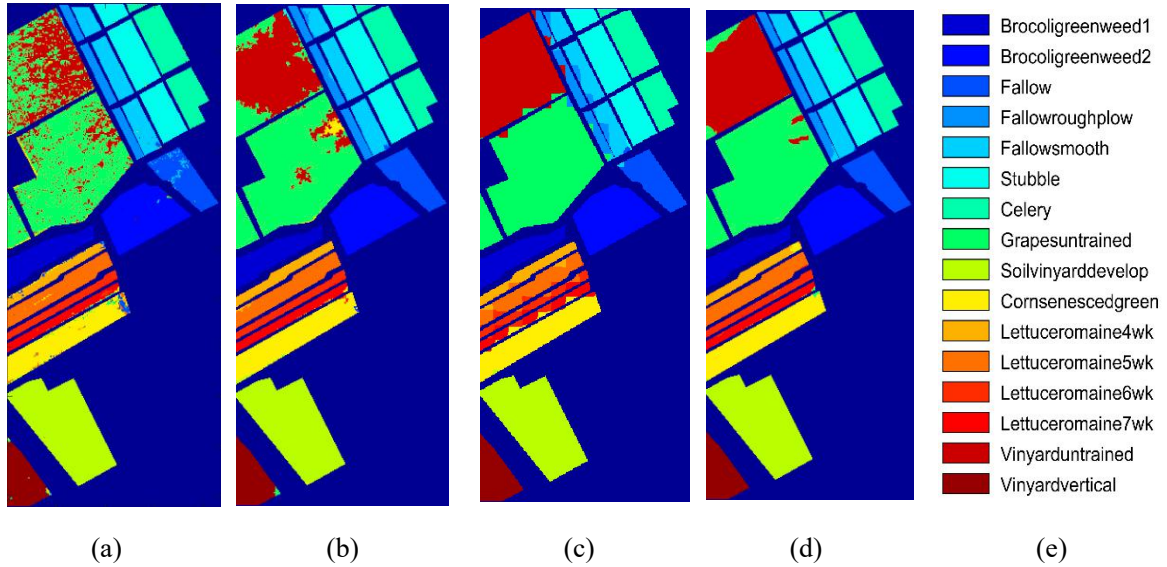


图 3.6 各分类框架在 Salinas 数据集上的分类结果。(a) SVM；(b) SVM-SP($s = 15$)；(c)DPR-SVM-POS($m = 15, s = 15, \beta = 0.9$)；(d)DPR-SVM-SP($s = 15, \beta = 0.9$)；(e) 图例。

Fig 3.5 The classification results of various classification frameworks on the Salinas dataset.

(a) SVM；(b) SVM-SP($s = 15$)；(c)DPR-SVM-POS($m = 15, s = 15, \beta = 0.9$)；(d)DPR-SVM-SP($s = 15, \beta = 0.9$)；(e) Label.

以上的实验结果表明：增加了空间信息确实能够对分类的结果有进一步的改善。这里的改进的 SLIC 技术和 DPR 技术我们都可以理解为一种特殊的空间信息的参与。为了更进一步地证明本章所提分类框架的高效性，这里我们分别对比了以下经典的谱空分类方法。它们分别是：结合拓展形态学和超像素的 SVM 分类框架^[57]（EMP-SP-SVM）、多尺度超像素结合子空间的 SVM^[58]（MSP-SVM_{sub}）、超像素级别的稀疏模型^[59]（SBDSM）、超像素与极限学习机分类器^[60]（SP-ELM）、基于超像素的空间金字塔表示^[61]（SP-SPR）、超像素级别的多核学习低秩排序^[62]（SP-MKL-LRR）、切割堆叠自编码器^[63]（S-SAE）、谱空相关切割与分类^[64]（SoCRATE）和超像素级别的主成分降维与分类^[65]（SuperPCA）。这些方法基本上都使用了超像素技术并且使用了谱空信息，具体的对比结果如下表：

表 3.4 本章实验及其对比试验在三个数据集上的分类结果

Tab.3.4 Classification results of experiments and comparative experiments on three data sets in this chapter

对比试验				DPR-SVM-SP	提升幅度
	数据集名称	标记比例	OA	OA	%
SP-SPR	IP	10%	97.24	97.14±0.44	-0.10
	PU	250	98.54	98.61±0.21	0.07
SP-MKL-LRR	IP	10%	96.90	97.14±0.44	0.24
	PU	15%	93.97	97.70±0.01	3.73
SBDSM	IP	10%	97.12	97.14±0.44	0.02
	PU	250	97.33	98.61±0.21	1.28
	SA	1%	99.37	99.16±0.01	-0.21
SP-ELM	IP	10%	97.78	97.14±0.44	-0.64
	PU	300	98.17	98.95±0.21	0.78
MSP-SVMsub	IP	15	84.01	86.72±2.59	2.71
	PU	100	97.57	97.54±0.89	-0.03
EMP-SP-SVM	PU	50	91.61	93.74±1.47	2.10
	SA	50	94.01	97.23±0.71	3.22
SoCRATE	IP	5%	98.18	96.00±0.04	-2.18
	PU	1%	93.44	97.70±0.01	4.26
	SA	1%	98.64	99.16±0.01	0.52
S-SAE	IP	10%	96.66	97.14±0.44	0.48
	PU	5%	96.66	98.81±0.23	2.15
SuperPCA	IP	30	94.62	95.52±0.21	0.90
	PU	30	91.30	92.64±1.23	1.34
	SA	30	98.97	98.12±0.76	-0.85

从表 3.4 中我们可以发现，所提出的方法与各对比试验之间的差异并不是很大。这主要是因为各个对比试验都是目前较为先进的分类体系，但总体上而言本章的框架依然有略微的优势。尤其是在 Pavia University 数据集上，本章的分类方法的在相同的标记的状态的情况下有较为明显的增益。例如：与 SP-MKL-LRR 框架相比，本章算法高出 3.73 个百分点，与 SBDSM 框架相比，本章算法高出 1.28 个百分点，与 EMP-SP-SVM 框架相比，本章算法高了 2.1%，与 S-SAE 框架相比，本章算法高了 2.15% 等。这种差异的来源可能主要包括 2 个方面：一方面是在对数据进行平滑预处理时加入了边缘约束使得平滑后的数据在类内具有较好的均质性且在类间具有较好的分离性，另一方面可能是本章所提出的改进的无参超像素能够针对高维数据进行更精确的切割从而使得在后处理纠正时能够进一步提升分类结果。

3.5.3 实验参数分析

在本章实验中主要的参数有数据预处理阶段 DPR 技术中的边缘检测算子类型；另

一个则是后处理阶段超像素的尺度，也就是切割步长的设置。对于这 2 个参数的实验讨论结果如图 3.7-3.8。




图 3.7 各边缘检测算子对分类精度的影响

Fig 3.7 Influence of each edge detection operator on classification accuracy




图 3.8 超像素切割尺度对分类精度的影响

Fig 3.8 The effect of superpixel cutting scale on classification accuracy

从图 3.7 中，可知在 Indian Pines 数据集中，当 $\beta = 0.9$ 时分类精度达到了顶峰，该参数表征了对原始数据的平滑程度 ($1 - \beta$) 则表征对原始数据的保留程度。同时，当边缘检测算子是 Roberts 算子时取得最佳结果，说明交叉算子更适合 Indian Pines 数据集的实际空间分布状态和光谱的复杂性（在数据说明中指出部分类别并不是严格相互排斥的），能够进一步增强类内的均质性和类间的分离性从而提升分类精度；而 Pavia University 数据集类别较少、类间可分离性较大、空间分布较为零散，因此 Canny 算子更能适应于这种不规则的边缘的检测并在 $\beta = 0.7$ 时取得最佳的分类精度；在 Salinas 数据集中，由于地物分布很规整且可分离性较好，因此 Roberts 依然能够更加准确地找到地物边界并在 $\beta = 0.9$ 时取得了最高的分类精度。此外超像素的尺度也会很大程度地影响实验结果，如图 3.8。因为较大的尺度意味着欠分割，这种状态下极有可能存在很多的混合像元；而当尺度过小的时候，可能会受到小斑块噪音的影响而无法得到纠正。最终，在穷举实验下，改进后的无参超像素在 Indian Pines、Pavia University 和 Salinas 三个数据集上的最佳切割尺度分别是 $s=5$ 、 $s=9$ 和 $s=15$ 。

3.6 本章小结

本章提出了一种新的无参超像素切割技术，该方法能够避免讨论因融合空间信息和光谱信息而引入的参数 m ，且能够自适应到高维影像无需降维处理，从而最大程度地利用了原有信息。此外，DPR 保边滤波能够有效地进行数据预处理，使得平滑后的数据集可以在类的内部更加均质，在类之间的可分离性进一步拉大，显著地增强了像素级别的分类器的分类性能。这种框架虽然可以获得非常可观的识别精度，但依然是像素级别的谱空分类器。下一章中，我们将引入一种新的超像素块合并策略，实现真正意义上的超像块级别的合并归类。

4 一种新的超像素级高光谱图像的光谱-空间分类方法

虽然超像素分割为高光谱图像(HSI)分类提供了有力的工具,但由于超像素的自适应大小和形状的特点,在超像素水平上对 HSI 进行分类仍然是一个具有挑战性的问题。此外,超像素的这些特性以及噪声像素的出现,使得适当地测量两个超像素之间的相似性成为一种的方法。在假设超像素内的像素属于同一类且概率较高的前提下,本章介绍了一种新的超像素级别(SSC-SL)的光谱空间 HSI 分类方法。首先,通过引入一种新的相似性和排序技术,改进了一种简单的线性迭代聚类(SLIC)算法。专门为 HSI 设计的 SLIC 可以直接将具有任意维数的 HSI 分割成超像素,而无需事先进行主成分分析。此外,还新引入了超像素到超像素的相似性。定义的相似性与超像素的形状无关,减弱了噪声像素对相似性的影响。最后,通过根据最近的标记超像素标记每个未标记的超像素来完成分类任务。在所提出的超像素级别分类方案中,每个超像素被视为一个样本。这显然大大减少了待分类的样本数据量。在三个真实的高光谱数据集上的实验结果表明,所提出的光谱-空间分类方法在分类精度方面优于几种比较先进的分类方法。

4.2 改进的无参超像素

与上一章超像素算法所不同的是,本章对该算法进行了进一步的改造。使得该算法的理论性更清晰。 $HSI = (x_1, x_1, \dots, x_N) \subset R^B$ 表示具有 N 个样本点的高光谱数据集,每个样本点 x_i 可以表示成 $x_i = (x_{i,1}, x_{i,2}, \dots, x_{i,B})^T$, B 表示该数据集所包含的波段数量。因此,每两个样本点之间的光谱相似度我们可以表示成公式(4.1)。

$$S_{spec}(x_i, x_j) = (1 - \rho_{i,j}) [\sum_{k=1}^B (x_{i,k} - x_{j,k})^2]^{\frac{1}{2}} \quad (4.1)$$

这里的 $\rho_{i,j}$ 是皮尔森相关系数,可由公式(3.8)计算得到。理论上讲,公式(4.1)的这种度量方式能够更好地表征两样本点之间的相似程度。

假设在样本点 x_i 的有效邻域内有 k 种子点, c_1, c_2, \dots, c_k , 对于本章的超像素则执行如下三个步骤实现对各个样本点的重编码。

步骤一: 根据公式(4.1)计算样本对之间的光谱相似度并升序排列得到公式(4.2)

$$S_{spec}(x_i, c'_1) \leq S_{spec}(x_i, c'_2) \leq \dots \leq S_{spec}(x_i, c'_k) \quad (4.2)$$

这里的 c'_1, c'_2, \dots, c'_k 是原始像素点 c_1, c_2, \dots, c_k 的重排列, 因此光谱近邻的指标 $I_{spec}(x_i, c_j)$ 就可以由公式(4.2)获得。

步骤二: 根据公式(3.7)计算样本对之间的空间距离并升序排列得到公式(4.3)

$$S_{spat}(x_i, c''_1) \leq S_{spat}(x_i, c''_2) \leq \dots \leq S_{spat}(x_i, c''_k) \quad (4.3)$$

这里的 $c''_1, c''_2, \dots, c''_k$ 是原始像素点 c_1, c_2, \dots, c_k 的另一种重排列, 因此空间近邻的指标 $I_{spat}(x_i, c_j)$ 就可以由公式(4.3)获得。

基于公式(4.2)产生的光谱相似度和基于公式(4.3)产生的空间近邻性, 一个新

的指标如公式（4.4）

$$I(x_i, c_j) = I_{spec}(x_i, c_j) + I_{spat}(x_i, c_j) \quad (4.4)$$

若 $I(x_i, c_j)$ 在 $I(x_i, c_m)$ ($m = 1, 2, \dots, k$) 中处于最小, 则将像素 x_i 编码为第 j 个超像素, 如公式（4.5）。

$$\text{Label}(x_i) = \arg \min_{m=1,2,\dots,k} \{I(x_i, c_m)\} \quad (4.5)$$

4.3 局部平均伪近邻

局部平均伪近邻^[66]可以理解为 KNN 算法^[67]、局部平均 k 近邻^[68]和伪近邻^[69]的加强改进版。对于一个高光谱影像而言, 使用本章提出的超像素技术可以将其切割成 M 块, 表示为: $HSI = S_1 \cup S_2 \cup \dots \cup S_M$ 。假设 S_i 由 n_i 个像素构成, 则 $S_i = (x_1^i, x_2^i, \dots, x_{n_i}^i)$ 。那么, 超像素 S_i 与超像素 S_p 的相似度则可以通过公式（4.6）—公式（4.8）计算得到。

步骤一: 根据公式（4.1）计算像素 x_i^i 与超像素 S_p 的每个像素点 x_j^p 之间的光谱相似性。然后将计算所得的结果按照升序排列, 并记录下对应的序号, 再利用该序号对 S_p 的每个像素点进行重新排序。

步骤二: 利用 S_p 中的前 m 个样本, 求像元 x_i^i 的平均向量 \bar{x}_m^p , 如公式（4.6）。

$$\bar{x}_m^p = \frac{1}{m} \sum_{j=1}^m x_j^p \quad (4.6)$$

$S_{spec}(x_i^i, \bar{x}_1^p), S_{spec}(x_i^i, \bar{x}_2^p), \dots, S_{spec}(x_i^i, \bar{x}_{n_p}^p)$ 是由公式（4.1）计算出来的相似度。

步骤三: 根据公式（4.7），计算像素点 x_i^i 与超像素块 S_p 的相似度 $s(x_i^i, S_p)$

$$s(x_i^i, S_p) = \sum_{m=1}^{n_p} \frac{1}{m} S_{spec}(x_i^i, \bar{x}_m^p) \quad (4.7)$$

步骤四: 对计算的 $s(x_1^i, S_p), s(x_2^i, S_p), \dots, s(x_{n_i}^i, S_p)$ 进行重新排序得 $s(x_{1*}^i, S_p), s(x_{2*}^i, S_p), \dots, s(x_{n_i*}^i, S_p)$ 。最后, 超像素 S_i 与超像素 S_p 的相似度 $s(S_i, S_p)$ 则可以由公式（4.8）计算获得。

$$s(S_i, S_p) = s(x_{1*}^i, S_p) + \frac{1}{2} s(x_{2*}^i, S_p) + \dots + \frac{1}{n_i} s(x_{n_i*}^i, S_p) \quad (4.8)$$

4.4 所提出的 SSC-SL 算法

基于超像素局部均质的性质, 我们对原始的高光谱影像进行随机标记。结合超像素的切割图（假设共产生 M 个超像素），利用投票原则对超像素进行标记。若假设有 h 个超像素被标记, 则标记的超像素集表示为: $S^L = \{S_1^L, S_2^L, \dots, S_h^L\}$; 则剩下的未标记的超像素集表示为: $S^U = \{S_{h+1}^U, S_{h+2}^U, \dots, S_{h+M}^U\}$ 。对于每个未标记的超像素 $S_i^U \in S^U$, 计算它与已标记的超像素 S_p^L 的相似度, 最后 S_i^U 将按照公式 4.9）进行归并分类。

$$\text{Class}(S_i^U) = \arg_{p=1,2,\dots,h} \min\{s(S_i^U, S_p^L)\} \quad (4.9)$$

4.5 实验设置与结果分析

4.5.1 实验设置说明

为了证明本章所提的超像素归并方法的有效性,该框架分别在 Indian Pines、Pavia University 和 Salinas 三个标准的高光谱数据集上做了仿真实验。其中,在 Indian Pines 和 Pavia University 数据集上的训练比例是 10%,在 Salinas 数据集上是 1%。同时,为了避免随机标记所产生的影响,所有的仿真测试均进行 10 次独立重复实验。最后,我们使用总体分类精度 (Overall Accuracy, OA)、平均分类精度 (Average Accuracy, AA) 和卡帕系数 (Kappa, κ) 三个指标对实验进行了分析与比较。比较对象主要涵盖了 Support vector machine (SVM) ^[70], edge preserving filtering-based classifier (EPF) ^[71], image fusion and recursive filtering (IFRF) ^[72], SuperPCA approach^[65] 和 PCA-SLIC 等。

4.5.2 实验结果与分析

表 4.1 不同的分类方法在 Indian Pines 数据集上的分类结果

Tab.4.1 Classification results of different classification methods on Indian Pines dataset

类别	训练/测试	SVM	EPF	IFRF	SuperPCA	PCA-SLIC	SSC-SL
1	5/41	49.76 ±16.7	51.22 ±40.2	94.63 ±7.0	95.61± 1.5	100 ± 0	100±0
2	143/1285	67.87±2.7	81.5±4.2	91.27 ±0.7	93.6±2.3	95.86±2.4	96.91±2.5
3	83/747	54.11±2.2	60.48±3.5	94 ± 2.8	95.57±3.7	95.66±3.4	96.13±4.2
4	24/213	38.87±7.7	66.95 ±25.6	87.51 ±6.6	87.23±6.7	93.01 ±7.6	93.21±6.58
5	49/434	88.48±3.0	94.45±1.3	96.08 ±1.7	95.83±2.5	95.85 ±3.2	96.17±2.8
6	73/657	96.41±1.4	99.85±0.2	99.09 ±0.7	96.74±2.8	97.42 ±1.9	98.85±0.4
7	3/25	79.6±7.7	96.8±1.7	87.6 ±14.8	96.4±1.3	90.71 ± 6.9	93.57±2.3
8	48/430	97.37±1.4	100±0	100±0	99.02±1.8	99.79±0	100±0
9	2/18	26.67±9.4	2.22±7.0	15±21.1	80±25.8	100±0	100±0
10	98/874	65.94±3.1	77.25±2.7	89.99±2.6	92.95±2.7	93.37±1	93.27±2.7
11	246/2209	84.83±1.0	96.57±0.8	98.47±0.6	98.33±1.4	97.76±1.2	98.21±1.1
12	60/533	64.43±5.12	93.73±8.2	90.51±4.6	92.35±2. 6	94.2±2.4	94.35±2.8
13	21/184	97.34±2.2	99.3±0.3	99.41±0.2	97.39±1.1	98.02±1.87	98.69±0.46
14	127/1138	96.57±0.6	99.48±0.4	99.68±0.3	99.13±0.9	98.62±0.98	99.49±0.38
15	39/347	49.31±7	73.31±10.9	96.89±1.9	91.96±5.5	95.9±3.01	96.61±3.68
16	10/83	88.07±4.7	99.28±1.9	98.68±1.3	83.73±16.3	97.69±5.19	97.74±0.79
OA	—	77.63±0.6	88.34±1.1	95.49±0.3	95.79±0.5	96.61±1.23	97.18±1.26
AA	—	71.6±4.7	80.77±6.8	89.93±4.2	93.49±4.9	96.49±2.28	97.07±2.45
κ	—	0.74 ±0.7	0.87 ±1.3	0.95±0.3	0.95±0.6	0.96±1.32	0.965±1.37

通过表 4.1,我们不难发现仅使用光谱信息作为区别样本依据的 SVM 方法获得了最低的分类精度,仅有 77.63%的正确率;而 EPF 则相对提升了约 10 个百分点,这主要是因为该方法在后期使用了保边滤波的策略对分类结果进行了进一步的优化;而本章所提

出的 SSC-SL 方法则相对于原始 SVM，提升了近 20%的准确率，同时在该数据集的测试样本中的识别率也优于 IFRF、Super PCA 和 PCA-SLIC。从分类结果上看，本章所提出的方法能够有效地结合并充分地利用影像的光谱信息和空间信息并在合并的过程中能够有效地抑制噪音数据的影响，图 4.1 展示了各种方法的分类结果。




图 4.1 不同的分类方法在 Indian Pines 数据集上的分类结果图。

(a) 真实地物图 (b)SVM (c)EPF (d)IFRF (e)SuperPCA (f)PCA-SLIC (g)SSC-SL

Fig 4.1 Classification results of different classification methods on the Indian Pines dataset. (a)Label (b)SVM (c)EPF (d)IFRF (e)SuperPCA (f)PCA-SLIC (g)SSC-SL

表 4.2 不同的分类方法在 Pavia University 数据集上的分类结果

Tab.4.2 Classification results of different classification methods on the Pavia University dataset

类别	训练/测试	SVM	EPF	IFRF	SuperPCA	PCA-SLIC	SSC-SL
1	664/5967	91.68±0.55	99.67±0.21	98.42±0.21	95.55±0.46	99.6±0.23	99.62±0.2
2	1865/16784	97.4±0.3	99.94±0.02	99.93±0.05	99.3±0.07	99.64±0.22	99.77±0.13
3	210/1889	70.05±2.22	72.32±5.26	91.08±4.18	95.74±0.85	99.02±0.53	97.98±0.58
4	307/2757	93.82±0.95	98.23±0.66	94.85±0.86	83.71±1.63	97.29±0.75	97.36±0.58
5	135/1210	99.45±0.18	99.93±0.03	99.63±0.18	91.23±1.25	96.68±2.17	99.78±0.04
6	503/4526	76.69±1.25	94.21±1.71	99.8±0.07	98.21±0.37	99.97±0.04	99.8±0.12
7	133/1197	82.87±0.96	94.05±1.2	98.52±0.56	98.47±0.42	99.92±0	98.55±0.93
8	369/3313	88.37±1.32	98.86±0.3	89.36±1.74	97.21±0.36	99.23±0.35	98.66±0.38
9	95/852	98.88±0.38	98.09±0.63	57.56±4.6	95.82±0.79	99.25±0.71	99.65±0.11
OA	—	91.35±0.18	97.43±0.24	96.98±0.19	95.03±0.69	99.31±0.09	99.35±0.09
AA	—	88.8±0.9	95.03±1.11	92.13±1.38	96.77±0.17	98.96±0.56	99.02±0.34
κ	—	0.8844±0.23	0.9658±0.32	0.96±0.26	0.957±0.23	0.9913±0.12	0.9915±0.12

Pavia University 数据集相对于 Indian Pines 数据集有更少地物类型和良好的光谱分辨率以及地面分辨率等。因此如表 4.2，即使是仅使用光谱信息的 SVM 分类器也能取得一个较好的分类效果(91.35%)。但使用谱-空结合的策略则分类精度又有了进一步的提升，都在 95%以上。其中本章方法在该数据集上相较于 EPF 大约提升了 2%，说明无参超像素在切割原始影像时，依然保持较高的“边缘召回率”，同时这种超像素块之间的相似度度量能够有效地削弱“椒盐现象”。而 EPF 则得益于其保边滤波对分类结果的优化，结果优于 IFRF 与 Super PCA。图 4.2 展示了各种方法的分类结果。




图 4.2 不同的分类方法在 Pavia University 数据集上的分类结果图。

(a)真实地物图 (b)SVM (c)EPF (d)IFRF (e)SuperPCA (f)PCA-SLIC (g)SSC-SL

Fig 4.2 Classification results of different classification methods on the Indian Pines dataset.

(a)Label (b)SVM (c)EPF (d)IFRF (e)SuperPCA (f)PCA-SLIC (g)SSC-SL

表 4.3 不同的分类方法在 Salinas 数据集上的分类结果

Tab.4.3 Classification results of different classification methods on the Salinas dataset

类别	训练/测试	SVM	EPF	IFRF	SuperPCA	PCA-SLIC	SSC-SL
1	21/1988	97.64±1.32	99.43±0.63	100±0	98.61±4.39	100±0	99.95±0.01
2	38/3688	98.81±0.19	99.86±0.08	99.34±0.47	98±2.86	99.7±0	99.59±0.32
3	20/1956	84.92±4.77	83.64±5.08	99.95±0.15	98.99±0.2	99.59±0.7	99.86±0.13
4	14/1380	98.96±0.4	99.37±0.34	96.63±1.84	94.51±4.95	89.45±9.3	90.17±8.6
5	27/2651	97.26±1.15	99.55±0.28	99.27±0.27	95.95±5.8	97.26±1.08	98.74±0.26
6	40/3919	99.56±0.11	99.97±0.02	99.92±0.03	96±5.1	99.92±0	99.9±0.01
7	36/3543	99.33±0.25	99.74±0.02	99.66±0.2	96.64±2.27	99.92±0.02	99.92±0.02
8	113/11158	88.53±2.05	91.35±1.9	92.83±0.81	97.74±1.59	97.83±1.18	99.1±0.23
9	63/6140	98.54±0.8	99.5±0.32	99.98±0	97.91±3.54	99.89±0.18	99.68±0.29
10	33/3245	87.34±4.17	92.07±3.35	99.67±0.22	95.88±2.2	95.33±3.9	97.51±0.62
11	11/1057	90.67±1.85	97.02±1.38	90.59±4.39	73.8±22.74	94.4±3.98	96.69±4.25
12	20/1907	99.76±0.31	100±0	100±0.02	89.24±8.71	95.11±0.91	98.58±1.06
13	10/906	97.64±0.61	97.79±0.22	81.45±2.9	92.41±9.23	89.67±6.89	97.39±0.06
14	11/1059	90.93±4.02	94.24±0.86	92.6±1.32	83.9±10.31	88.59±6.91	95.75±0.11
15	73/7195	55.39±4.96	62.68±5.37	93.97±1.84	96.66±3.92	94.98±2.41	95.5±1.8
16	19/1788	95.35±3.74	97.71±1.87	98.98±0.86	92.25±4.77	98.66±2.4	99.78±0.01
OA	—	89.16±0.68	91.68±0.75	96.8±0.27	95.90±0.62	97.39±0.56	98.41±0.13
AA	—	92.54±1.92	94.62±1.36	96.55±0.96	93.66±5.8	96.27±2.49	98.01±1.1
κ	—	0.879±0.76	0.9071±0.85	0.9644±0.3	0.9543±0.69	0.9710±0.63	0.982±0.15

表 4.3 展示了 6 种方法在 Salinas 数据集上的分类结果。从总体分类精度指标上看，本章所提方法均优于其他主流方法。其中 EPF 的分类精度是 91.68，相对于原始 SVM 仅仅提升了约 2 个百分点。这很有可能是该数据集原本就很规整，边缘在此处对分类结果的优化效果并不明显。而 IFRF 则得益于其迭代平滑的过程，使得噪音数据得到良好的处理。同时，从表 4.3 中可以看出，本章所提方法在几乎在每类地物上的正确识别率均达到 95%以上。具体的分类结果如图 4.3。




图 4.3 不同的分类方法在 Salinas 数据集上的分类结果图。

(a) 真实地物图 (b)SVM (c)EPF (d)IFRF (e)SuperPCA (f)PCA-SLIC (g)SSC-SL

Fig 4.3 Classification results of different classification methods on the Salinas dataset.

(a)Label (b)SVM (c)EPF (d)IFRF (e)SuperPCA (f)PCA-SLIC (g)SSC-SL

4.5.3 实验参数分析

在本章中，所涉及的全部参数仅有 2 个，分别是超像素切割步长(Step)和训练比例。

图 4.4 展示了不同切割尺度下的三个数据集的总体分类精度。其中 Indian Pines 数据集，在标记 10% 的情况下，最高分类精度达到了 97.52%，此时对应的 $\text{step}=5$ ，这也是本章对比试验的参数取值，从曲线上可以看出当切割尺度变大时，分类精度发生急剧的下降，这种现象主要是由于 Indian Pines 数据集自身较小，且类别较多，存在较多的小地物类型，大尺度下容易造成过切分的现象，同时小尺度又受噪音样本的影响而无法得到适当的纠正；而与 Indian Pines 不同的是，Salinas 数据集则尺寸较大，且地物边界规整，地物的光谱信息相对于 Indian Pines 分离性也较大，因此在步长从 3 到 13 变化时，分类精度都呈现上升的趋势，而继续增加超像素的切割尺度时，开始出现了由过切分现象，纠正精度也因之逐渐下降；Pavia University 数据集则在 $\text{step}=7$ 处取得了最佳分类精度，因为虽然该数据的尺寸较大，但是地物较为零碎，且存在不规则带状分布居多，这对超像素的切割会产生一定的影响，因此最佳的步长并不像 Salinas 规整数据集那样大。此外，图 4.5 展示了不同标记比例对各实验的影响，从分类结果上看，本章所提出的方法在各个数据集上均优于各个对比试验。




图 4.4 不同切割尺度下的各个数据集的分类精度

Fig 4.4 Classification accuracy of each data set at different cutting scales




图 4.5 不同标记比例对各个实验的影响

Fig 4.5 The effect of different marker ratios on each experiment

4.6 本章小结

本章给出了一种新的无参超像素的公式化表达方法,该方法被实验证明了能够很好地自适应到高光谱影像,且无需降维、无需参数。同时,提出了一种新的超像素块之间的相似度量方法,该方法能够有效地降低噪音样本对超像素之间相似度的影响,因此能够较好地解决超像素块级别的归并问题。这种归并方式,区别于原始的像素级别的分类方法,以及利用光谱-空间信息平滑、纠正的过渡方法

5 总结与展望

5.1 工作总结

本文针对目前高光谱影像在分类过程中, 存在的波段间冗余度高、样本容量大、噪声点众多以及在分类过程中如何有效利用空间信息的等方面问题, 展开了以下三个方面的研究。

在本研究的第 2 章, 我们提出了一种基于仿生智能的优化算法, 利用该方法结合子空间对香农熵目标函数进行了优化求解, 最后使用像素水平的分类器 SVM 对降维后的结果进行了分类, 通过与经典的降维算法的对比, 我们可以发现本章所提的降维-分类框架在同等条件下能够取得更好的分类效果, 然而该方法框架仅仅使用了光谱信息而不对空间信息加以利用, 因此与后续方法相比分类精度较低。但值得注意的是, 最原始的 SVM 分类器保留了最大的泛化性, 因为该分类器不仅仅支持像素的识别还支持非图像的数据序列的分类。

在本研究的第 3 章, 我们提出了一种新的无参超像素的度量方式, 该方法能够自适应到高光谱影像, 无需降维、无需调参; 此外, 为了进一步提升模型的识别率, 我们还对原始数据做了松弛平滑处理, 该方法不仅仅考虑到了地物的空间信息, 还很大程度上中和了地物的边缘信息, 也正是得益于对地物空间信息的进一步发掘利用, 使得本章所提出的算法打破了原有的“像素级别-谱信息”分类方法的瓶颈, 在各个实验数据集上都有显著的提升。

在本研究的第 3 章, 我们致力于提出一种集合之间相似度度量的方法。基于对第 2 章的无参超像素的进一步改进和公式化, 我们利用局部平均伪近邻的思想去衡量超像素块之间的相似度, 由于在计算超像素之间相似度的过程中, 我们将距离较大的样本点排到了最后, 也就意味着分配的权重最低, 因此在度量集合相似度时能够有效地抑制噪声数据的影响。通过比较, 我们所提出的方法在各个数据集上也都不劣于在高光谱影像邻域中的主流分类框架。

5.2 展望

虽然本研究所提出的降维和分类方法在分类精度方面相较几个流行的分类框架均有一定的提升, 但仍然受到诸多的限制。其中包括实验中所采用的数据集仅限于公开的三幅标准高光谱影像, 这种限制虽然方便了理论与对比, 但在实际应用中可能对复杂的地物覆盖依然缺乏适应性。主要表现在: 更大的场景影像、更多的地物类型辨别、以及更复杂的成像环境和地物分布等。因此, 对如何提升高光谱影像的分类精度, 我们在将来的工作中拟对以下三个问题进行进一步的研究。

(1) 恰当的数据预处理与后处理能够有效改善分类结果。值得注意的是, 这里的

数据预处理与后处理可以宏观地分为两种：一种是不对原始数据做变换的(如第 2 章的波段选择)，另一种是对原始数据进行变换的(如不连续保持松弛、卷积神经网络的卷积提取层、各种滤波等)。只要是分类前对数据的操作，我们可以统一称为数据预处理。通常情况下，数据预处理的本质在于促进类内各样本的均质性和扩大类间的可分离性。这种操作能够改变原始数据在特征空间中的分布。例如，在本研究的第 3 章中，就是利用该原理显著提升了模型的表达能力。此外，对比试验中的 EPF 方法，也是通过分类后处理进一步优化分类结果的。因此，在 HSI 分类工作中采用合适的预处理和后处理操作，是高光谱图像分类方法中值得进一步研究的问题之一。

(2)，高光谱影像的边缘检测方法将会对分类工作产生极其重要的影响。这里的边缘检测并不是指单波段检测后的叠加，而是基于样本向量定义出的新的边缘梯度方法。也正是由于该工作的困难性，使得目前高光谱边缘检测主要依赖的还是单波段的叠加，这种叠加往往会加重由于边缘定位不准确而产生的“伪边”现象。但是，一旦当我们大致检测出了影像的边缘，那么结合超像素技术和样本集合间相似度度量方法，无监督分类应用于高光谱影像将会成为可能，这将大大提升模型的泛化性、摆脱标记样本的约束，并且该方法从理论上讲能够保证较高的分类精度。

最后，针对高光谱影像应用专题构建迁移学习模型。当下，迁移学习由于其高效性而被广泛应用在计算机视觉当中，并逐渐地往高光谱领域发展。而这里的迁移学习是指借鉴计算机视觉领域的迁移学习思想，针对高光谱遥感某一应用专题(例如“高光谱农业遥感”)而创建的迁移学习网络。我们知道，传统的迁移学习主要是利用已经具备识别某些识别能力的网络权重，从中截取部分并针对自己关心的邻域进行再训练和优化的过程。当下发达的遥感硬件保障了可靠的数据来源，我们可以根据我国农作物的分类采集大量的地物影像，然后构建一套只针对农作物识别的网络系统并对其进行充分的训练。那么，当我们需要对某一地区的农作物进行识别的时候，我们就可以很快地利用先前已经训练好的模型进行再训练以适应具体的环境。

参考文献

- [1] Landgrebe D A , Serpico S B , Crawford M M , et al. Introduction to the special issue on analysis of hyperspectral image data[J]. IEEE Transactions on Geoscience and Remote Sensing, 2001, 39(7):1343-1345.
- [2] Yuen P W , Richardson M . An introduction to hyperspectral imaging and its application for security, surveillance and target acquisition[J]. The Imaging Science Journal, 2010, 58(5):241-253.
- [3] Sun G, Zhang A, Ren J, et al. Gravitation-Based Edge Detection in Hyperspectral Images[J]. Remote Sensing, 2017, 9(6):592.
- [4] Zabalza, J, Qing, C, Yuen, P, Sun, et al. Fast implementation of two-dimensional singular spectrum analysis for effective data classification in hyperspectral imaging. Journal of the Franklin Institute, 2018, 355(4), 1733–1751.
- [5] Wang, C.; Ren, J.; Wang, H.; Zhang, Y.; Wen, J. Spectral-spatial classification of hyperspectral data using spectral-domain local binary patterns[J]. Multimed. Tools Appl. 2018, 77(22):29889–29903.
- [6] Zabalza J , Ren J , Wang Z , et al. Singular Spectrum Analysis for Effective Feature Extraction in Hyperspectral Imaging[J]. IEEE Geoscience and Remote Sensing Letters, 2014, 11(11):1886-1890.
- [7] Cao F , Yang Z , Ren J , et al. Extreme Sparse Multinomial Logistic Regression: A Fast and Robust Framework for Hyperspectral Image Classification[J]. Remote Sensing, 2017, 9(12): 1255.
- [8] Ellis R J , Scott P W . Evaluation of hyperspectral remote sensing as a means of environmental monitoring in the St. Austell China clay (kaolin) region, Cornwall, UK[J]. Remote Sensing of Environment, 2004, 93(1-2):118-130.
- [9] Manfreda S, McCabe M, Miller P, et al. On the Use of Unmanned Aerial Systems for Environmental Monitoring[J]. Remote Sensing, 2018, 10(4): 641.
- [10] De Morsier F, Borgeaud M, Gass V, et al. Kernel Low-Rank and Sparse Graph for Unsupervised and Semi-Supervised Classification of Hyperspectral Images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2016, 54(6): 3410–3420.
- [11] Hughes G. On the mean accuracy of statistical pattern recognizers[J]. IEEE Transactions on Information Theory, 1968, 14(1): 55–63
- [12] Ma D, Yuan Y, Wang Q. Hyperspectral Anomaly Detection via Discriminative Feature Learning with Multiple-Dictionary Sparse Representation[J]. Remote Sensing. 2018, 10(5): 745.
- [13] Zhao C , Li X , Ren J , et al. Improved sparse representation using adaptive spatial support for effective target detection in hyperspectral imagery[J]. International Journal of Remote Sensing, 2013, 34(24):8669-8684.
- [14] Feng J , Jiao L C , Zhang X , et al. Hyperspectral Band Selection Based on Trivariate Mutual Information and Clonal Selection[J]. IEEE Transactions on Geoscience and Remote Sensing, 2014, 52(7):4092-4105.
- [15] Feng J , Jiao L , Liu F , et al. Unsupervised feature selection based on maximum information and minimum redundancy for hyperspectral images[J]. Pattern Recognition, 2016, 51(C):295-309.
- [16] Rasti B, Scheunders P, Ghamisi P, et al. Noise Reduction in Hyperspectral Imagery: Overview and Application[J]. Remote Sensing, 2018, 10(3): 482.
- [17] Tan K , Li E , Du Q , et al. An efficient semi-supervised classification approach for hyperspectral imagery[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2014, 97(11):36-45.

- [18] Gao H, Yao D, Wang M, et al. A Hyperspectral Image Classification Method Based on Multi-Discriminator Generative Adversarial Networks[J]. *Sensors*, 19(15):3269.
- [19] Tu B, Zhang X, Wang J, et al. Spectral-Spatial Hyperspectral Image Classification via Non-local Means Filtering Feature Extraction[J]. *Sensing and Imaging*, 2018, 19(1):11.
- [20] Bruzzone L, Serpico S B. A technique for feature selection in multiclass problems[J]. *International Journal of Remote Sensing*, 2000, 21(3):549-563.
- [21] 张集民. 高光谱遥感在草原监测中的应用[J]. *畜牧兽医科学(电子版)*, 2017(09):87.
- [22] Feng J, Jiao L, Liu F, et al. Unsupervised feature selection based on maximum information and minimum redundancy for hyperspectral images[J]. *Pattern Recognition*, 2016, 51(C):295-309.
- [23] Benediktsson J A, Palmason J A, Sveinsson J R. Classification of hyperspectral data from urban areas based on extended morphological profiles[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2005, 43(3): 480-491.
- [24] Liao W, Pizurica A, Philips W, et al. A fast iterative kernel PCA feature extraction for hyperspectral images[C] // *IEEE International Conference on Image Processing*. IEEE, 2010.
- [25] Zabalza, J., Ren, J., Zheng, J., Zhao, H., Qing, C., Yang, Z., ... Marshall, S. (2016). Novel segmented stacked autoencoder for effective dimensionality reduction and feature extraction in hyperspectral imaging. *Neurocomputing*, 185, 1–10.
- [26] Licciardi, G.; Frate, F.D.; Duca, R. Feature reduction of hyperspectral data using autoassociative neural networks algorithms. In *Proceedings of the 2009 IEEE International Geoscience and Remote Sensing Symposium (IGARSS)*, Cape Town, South Africa, 12–17 July 2009; pp. 176–179.
- [27] Tao, C.; Pan, H.; Li, Y.; Zou, Z. Unsupervised spectral-spatial feature learning with stacked sparse autoencoder for hyperspectral imagery classification. *IEEE Geosci. Remote Sens. Lett.* 2015, 12, 2438–2442.
- [28] Feng J, Jiao L C, Zhang X, et al. Hyperspectral Band Selection Based on Trivariate Mutual Information and Clonal Selection[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2014, 52(7):4092-4105.
- [29] Cao, X., Xiong, T., & Jiao, L. (2016). Supervised Band Selection Using Local Spatial Information for Hyperspectral Image. *IEEE Geoscience and Remote Sensing Letters*, 1–5.
- [30] Wang, Q., Zhang, F., & Li, X. (2018). Optimal Clustering Framework for Hyperspectral Band Selection. *IEEE Transactions on Geoscience and Remote Sensing*, 56(10): 1–13.
- [31] Shukla, U. P., & Nanda, S. J. (2018). A Binary Social Spider Optimization algorithm for unsupervised band selection in compressed hyperspectral images. *Expert Systems with Applications*, 97, 336–356.
- [32] Yuan Y, Zheng X, Lu X. Discovering diverse subset for unsupervised hyperspectral band selection[J]. *IEEE Transactions on Image Processing*, 2016, 26(1): 51-64.
- [33] Zhong N, Dong J, Ohsuga S. Using Rough Sets with Heuristics for Feature Selection[J]. *Journal of Intelligent Information Systems*, 2001, 16(3):199-214.
- [34] Chang Y L, Chen K S, Huang B, et al. A parallel simulated annealing approach to band selection for high-dimensional remote sensing images[J]. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 2011, 4(3): 579-590.
- [35] Ghamisi P, Benediktsson J A. Feature selection based on hybridization of genetic algorithm and particle swarm optimization[J]. *IEEE Geoscience and remote sensing letters*, 2014, 12(2): 309-313.
- [36] Mirjalili, S.; Mirjalili, S.M.; Lewis, A. GreyWolf Optimizer. *Adv. Eng. Softw.* 2014, 69, 46–61.
- [37] Karaboga, D.; Ozturk, C. A novel clustering approach: Artificial Bee Colony (ABC) algorithm.

Appl. Soft Comput. 2011, 11, 652–657.

[38] Ghamisi, P.; Couceiro, M.S.; Martins, F.M.L.; Benediktsson, J.A. Multilevel Image Segmentation Based on Fractional-Order Darwinian Particle Swarm Optimization. *IEEE Trans. Geosci. Remote Sens.* 2014, 52, 2382–2394.

[39] Achanta R, Shaji A, Smith K, et al. Compared to State-of-the-Art Superpixel Methods[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2012, 34(11):2274-2282.

[40] Zhang, L.; Su, H.; Shen, J. Hyperspectral Dimensionality Reduction Based on Multiscale Superpixelwise Kernel Principal Component Analysis. *Remote Sens.* 2019, 11, 1219.

[41] Winkler R, Klawonn F, Kruse R. Fuzzy c-means in high dimensional spaces[J]. *International Journal of Fuzzy System Applications (IJFSA)*, 2011, 1(1): 1-16.

[42] Zhang D, Ji M, Yang J, et al. A novel cluster validity index for fuzzy clustering based on bipartite modularity[J]. *Fuzzy Sets and Systems*, 2014, 253: 122-137.

[43] Dunn J C. A fuzzy relative of the ISODATA process and its use in detecting compact well-separated clusters[J]. 1973.

[44] Mirjalili S, Mirjalili S M, Lewis A. Grey Wolf Optimizer[J]. *Advances in Engineering Software*, 2014, 69:46-61.

[45] Bazi Y, Melgani F. Toward an Optimal SVM Classification System for Hyperspectral Remote Sensing Images[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2006, 44(11):3374-3385.

[46] Feng J, Jiao L C, Zhang X, et al. Hyperspectral Band Selection Based on Trivariate Mutual Information and Clonal Selection[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2014, 52(7):4092-4105.

[47] Ghamisi P, Couceiro M S, Benediktsson J A. A Novel Feature Selection Approach Based on FODPSO and SVM[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2015, 53(5):2935-2947.

[48] Rodarmel C, Shan J. Principal Component Analysis for Hyperspectral Image Classification[J]. *Surveying and Land Information Systems*, 2002, 62.

[49] Zhang F, Wang Q, Li X. Optimal Neighboring Reconstruction for Hyperspectral Band Selection[C]//IGARSS 2018-2018 IEEE International Geoscience and Remote Sensing Symposium. IEEE, 2018: 4709-4712.

[50] Xie F, Li F, Lei C, et al. Unsupervised band selection based on artificial bee colony algorithm for hyperspectral image classification[J]. *Applied Soft Computing*, 2019, 75: 428-440.

[51] Xie F, Lei C, Li F, et al. Unsupervised hyperspectral feature selection based on fuzzy c-means and grey wolf optimizer[J]. *International journal of remote sensing*, 2019, 40(9): 3344-3367.

[52] Yu H, Gao L, Li J, et al. Spectral-spatial hyperspectral image classification using subspace-based support vector machines and adaptive Markov random fields[J]. *Remote Sensing*, 2016, 8(4): 355.

[53] Liu S, Jiao L, Yang S. Hierarchical sparse learning with spectral-spatial information for hyperspectral imagery denoising[J]. *Sensors*, 2016, 16(10): 1718.

[54] Li W, Prasad S, Fowler J E. Hyperspectral image classification using Gaussian mixture models and Markov random fields[J]. *IEEE Geoscience and Remote Sensing Letters*, 2013, 11(1): 153-157.

[55] Li J, Bioucas-Dias J M, Plaza A. Spectral-spatial hyperspectral image segmentation using subspace multinomial logistic regression and Markov random fields[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2011, 50(3): 809-823.

[56] Li J, Khodadadzadeh M, Plaza A, et al. A discontinuity preserving relaxation scheme for spectral-spatial hyperspectral image classification[J]. *IEEE Journal of Selected Topics in Applied Earth*

Observations and Remote Sensing, 2015, 9(2): 625-639.

[57] Liu T, Gu Y, Chanussot J, et al. Multimorphological superpixel model for hyperspectral image classification[J]. IEEE Transactions on geoscience and remote sensing, 2017, 55(12): 6950-6963.

[58] Yu H, Gao L, Liao W, et al. Multiscale superpixel-level subspace-based support vector machines for hyperspectral image classification[J]. IEEE Geoscience and Remote Sensing Letters, 2017, 14(11): 2142-2146.

[59] Fang L, Li S, Kang X, et al. Spectral-spatial classification of hyperspectral images with a superpixel-based discriminative sparse model[J]. IEEE Transactions on Geoscience and Remote Sensing, 2015, 53(8): 4186-4201.

[60] Duan W, Li S, Fang L. Spectral-spatial hyperspectral image classification using superpixel and extreme learning machines[C]//Chinese Conference on Pattern Recognition. Springer, Berlin, Heidelberg, 2014: 159-167.

[61] Fan J, Tan H L, Toomik M, et al. Spectral-spatial hyperspectral image classification using super-pixel-based spatial pyramid representation[C]//Image and Signal Processing for Remote Sensing XXII. International Society for Optics and Photonics, 2016, 10004: 100040W.

[62] Zhan T, Sun L, Xu Y, et al. Hyperspectral Classification via Superpixel Kernel Learning-Based Low Rank Representation[J]. Remote Sensing, 2018, 10(10).

[63] Paul S, Nagesh Kumar D. Spectral-spatial classification of hyperspectral data with mutual information based segmented stacked autoencoder approach[J]. Isprs Journal of Photogrammetry & Remote Sensing, 2018, 138:265-280.

[64] Appice A, Malerba D. Segmentation-aided classification of hyperspectral data using spatial dependency of spectral bands[J]. ISPRS journal of photogrammetry and remote sensing, 2019, 147: 215-231.

[65] Jiang J, Ma J, Chen C, et al. SuperPCA: A superpixelwise PCA approach for unsupervised feature extraction of hyperspectral imagery[J]. IEEE Transactions on Geoscience and Remote Sensing, 2018, 56(8): 4581-4593.

[66] Gou J, Zhan Y, Rao Y, et al. Improved pseudo nearest neighbor classification[J]. Knowledge-Based Systems, 2014, 70:361-375.

[67] Cover T, Hart P. Nearest neighbor pattern classification[J]. IEEE transactions on information theory, 1967, 13(1): 21-27.

[68] Mitani Y, Hamamoto Y. A local mean-based nonparametric classifier[J]. Pattern Recognition Letters, 2006, 27(10): 1151-1159.

[69] Zeng Y, Yang Y, Zhao L. Pseudo nearest neighbor rule for pattern classification[J]. Expert Systems with Applications, 2009, 36(2): 3587-3595.

[70] Melgani F, Bruzzone L. Classification of hyperspectral remote sensing images with support vector machines[J]. IEEE Transactions on geoscience and remote sensing, 2004, 42(8): 1778-1790.

[71] Kang X, Li S, Benediktsson J A. Spectral-spatial hyperspectral image classification with edge-preserving filtering[J]. IEEE transactions on geoscience and remote sensing, 2013, 52(5): 2666-2677.

[72] Kang X, Li S, Benediktsson J A. Feature extraction of hyperspectral images with image fusion and recursive filtering[J]. IEEE Transactions on Geoscience and Remote Sensing, 2013, 52(6): 3742-3752.

[73] Lu T, Li S, Fang L, et al. Set-to-Set Distance-Based Spectral-Spatial Classification of Hyperspectral Images[J]. IEEE Transactions on Geoscience & Remote Sensing, 2016, 54(12):7122-7134.

[74] Xie F, Lei C, Yang J, et al. An Effective Classification Scheme for Hyperspectral Image Based on

Superpixel and Discontinuity Preserving Relaxation[J]. Remote Sensing, 2019, 11(10): 1149.

[75] Xie F, Lei C, Jin C, et al. A Novel Spectral–Spatial Classification Method for Hyperspectral Image at Superpixel Level[J]. Applied Sciences, 2020, 10(2): 463.

[76] Jia S, Deng B, Huang Q. An efficient superpixel-based sparse representation framework for hyperspectral image classification[J]. International Journal of Wavelets, Multiresolution and Information Processing, 2017, 15(06): 1750061.

[77] Zhang S, Li S, Fu W, et al. Multiscale superpixel-based sparse representation for hyperspectral image classification[J]. Remote Sensing, 2017, 9(2): 139.

[78] Cao J, Chen Z, Wang B. Deep convolutional networks with superpixel segmentation for hyperspectral image classification[C]//2016 IEEE International Geoscience and Remote Sensing Symposium (IGARSS). IEEE, 2016: 3310-3313.

攻读硕士学位期间发表学术论文情况

1. Xie F, Lei C, Jin C, et al. A Novel Spectral–Spatial Classification Method for Hyperspectral Image at Superpixel Level[J]. Applied Sciences, 2020, 10(2): 463.
2. Xie F, Lei C, Yang J, et al. An Effective Classification Scheme for Hyperspectral Image Based on Superpixel and Discontinuity Preserving Relaxation[J]. Remote Sensing, 2019, 11(10): 1149.
3. Xie F, Lei C, Li F, et al. Unsupervised hyperspectral feature selection based on fuzzy c-means and grey wolf optimizer[J]. International journal of remote sensing, 2019, 40(9): 3344-3367.
4. Xie F, Li F, Lei C, et al. Unsupervised band selection based on artificial bee colony algorithm for hyperspectral image classification[J]. Applied Soft Computing, 2019, 75: 428-440.
5. Xie F, Li F, Lei C, et al. Representative band selection for hyperspectral image classification[J]. ISPRS International Journal of Geo-Information, 2018, 7(9): 338.
6. 谢福鼎,雷存款,李芳菲等.基于模糊 c 均值算法和人工蜂群算法的无监督波段选择[J].系统科学与数学,2018,38(12):1417-1428.

致 谢

“时间就像顽皮的孩子，一刻也不肯驻足”。转眼间，三年的研究生生活即将告一段落。这里，我想深刻并真诚地感谢我在攻读硕士研究生期间所有给予我帮助和关心的人们。

首先，感谢我即将离开的母校辽宁师范大学。感谢母校为我提供的一切资源，让我在这样优越的环境中能够安心地钻研学术并取得一系列的科研成果。百年师大，仿佛一片肥沃的土地时刻孕育着我们；百年的历史积淀，处处彰显着文化的气息，这给予了我无尽的骄傲与自豪。

其次，我要恳切地感谢我的指导老师谢福鼎教授。谢老师严谨的科研精神、犀利的研究视角和尽善尽美的做人风格一直鼓舞着我。我研究生所取得的一切成就无不凝聚着老师的心血。一直以来老师都鼓励我“成绩差不要紧、只要肯做、肯钻研”、“能不能做出来是能力问题，而做不做是态度问题”、“要尽可能准确、清晰、简洁地阐明自己观点”这样的话语给予了无尽的自信与温暖，使我终身受益。谢老师对我的帮助与关怀，我将铭记于心！

此外，还由衷感谢王方雄老师、柯丽娜老师、杨俊老师、金翠老师、侯英姿老师、黄凤荣老师、魏东岚老师等。感谢各位老师在学习上拓展了我的视野、授予了更多的技能，在生活中的给予我热心的帮助与无微不至的关怀。

感谢姚娆师姐、盖虹羽师姐、于珊珊师姐、李芳菲师姐、胡冬翠师姐、张帅师哥、赫佳妮、常宗鸿、刘梦滢、张莹、高全杉、李旭、赵子昕等同学的帮助和鼓舞。同窗之情我将永记于心。

最后，感谢为我默默付出的父母。感谢您们的养育之恩和一直以来对我学习上的支持。二十年来，您们为了我付出了太多、做出了太大的牺牲，你们的恩情将会是我一生都无法报答完的。

雷存款

2020年5月